



УНИВЕРЗИТЕТ У НИШУ  
ЕЛЕКТРОНСКИ ФАКУЛТЕТ



# **Анализа, оптимизација и доменска адаптација Whisper модела за аутоматско препознавање говора на српском језику**

Мастер рад

Студијски програм: Вештачка интелигенција и машинско учење

Студент:

Александар Јовановић, бр. инд. 2120

Ментор:

Проф. Јелена Николић

Ниш, Октобар 2026. година

Универзитет у Нишу  
Електронски факултет

**АНАЛИЗА, ОПТИМИЗАЦИЈА И ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА  
ЗА АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА НА СРПСКОМ ЈЕЗИКУ**

**ANALYSIS, OPTIMIZATION, AND DOMAIN ADAPTATION OF THE WHISPER  
MODEL FOR AUTOMATIC SPEECH RECOGNITION IN SERBIAN**

Мастер рад  
Студијски програм: Вештачка интелигенција и машинско учење  
Студент: Александар Јовановић, бр. инд. 2120  
Ментор: Проф. Јелена Николић

Задатак: *Задатак овог мастер рада је анализа и оптимизација Whisper и Faster-Whisper система за аутоматско препознавање говора на српском језику. Испитује се утицај различитих модела, квантизације, параметара транскрипције и услова снимања на тачност, брзину и потрошњу ресурса, након чега се врши избор одговарајуће конфигурације. Посебан део рада обухвата доменску адаптацију Whisper модела на српски говор из области пољопривреде и евалуацију адаптираног модела на новом говорнику.*

Датум пријаве рада:  
Датум предаје рада:  
Датум одбране рада:

Комисија за оцену и одбрану:

---

1. Проф. Јелена Николић, Председник Комисије

---

2.

---

3.

# АНАЛИЗА, ОПТИМИЗАЦИЈА И ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА ЗА АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА НА СРПСКОМ ЈЕЗИКУ

## САЖЕТАК

У овом мастер раду анализиран је Whisper модел за аутоматско препознавање говора, са посебним фокусом на српски језик и оптимизацију система за извршавање на CPU уређајима. Поред оригиналне Whisper имплементације, испитан је Faster-Whisper заснован на CTranslate2 механизму, са циљем анализе односа између тачности транскрипције, брзине обраде и потрошње рачунарских ресурса. За главни експериментални део формиран је скуп од 40 природних говорних снимака на српском језику, који обухвата три говорника и снимке различитог трајања.

На почетку експерименталне анализе извршено је директно поређење оригиналног Whisper и Faster-Whisper система на основу WER метрике, времена транскрипције, RTF вредности и потрошње меморије. Након тога испитан је утицај величине модела, INT8 и FLOAT32 квантизације, Beam Search параметра, VAD алгоритма, позадинског шума и различитих SNR вредности. Извршено је и контролисано поређење препознавања српског и енглеског говора и симулација streaming транскрипције са различитим величинама аудио сегмената.

На основу добијених резултата развијен је поступак за аутоматски избор конфигурације применом вишекритеријумске оптимизације, Pareto анализе и анализе осетљивости. Као најповољнији однос тачности, брзине и измерене меморијске захтевности издвојена је Faster-Whisper Small INT8 конфигурација, са просечним WER-ом од 22,43% и просечним RTF-ом од 0,327. Резултати засебних експеримената искоришћени су и за избор одговарајућих Beam Search, VAD и streaming подешавања.

Посебан део рада посвећен је доменској адаптацији Whisper модела за српски говор из области пољопривреде. За ову намену формиран је скуп од 800 аудио записа, од којих је 675 коришћено за обучавање, 75 за валидацију и 50 за тестирање. Тест скуп садржи говор четвртог говорника који није учествовао у обучавању, чиме се испитује и способност генерализације адаптираног модела на новог говорника. **(Након завршетка експеримента овде додајем)**

Сprovedена анализа показује да избор одговарајуће величине модела, квантизације и параметара транскрипције омогућава прилагођавање Faster-Whisper система различитим захтевима практичне примене. Главни допринос рада представља систематска анализа и оптимизација Whisper система за српски говор, аутоматски избор конфигурације и његова доменска адаптација за специфичну област.

**Кључне речи:** аутоматско препознавање говора, Whisper, Faster-Whisper, српски језик, оптимизација, доменска адаптација.

# ANALYSIS, OPTIMIZATION, AND DOMAIN ADAPTATION OF THE WHISPER MODEL FOR AUTOMATIC SPEECH RECOGNITION IN SERBIAN

## ABSTRACT

This master's thesis analyzes the Whisper model for automatic speech recognition, with a particular focus on the Serbian language and system optimization for CPU-based execution. In addition to the original Whisper implementation, Faster-Whisper, based on the CTranslate2 framework, was evaluated to analyze the trade-off between transcription accuracy, processing speed, and computational resource usage. For the main experimental part, a dataset of 40 natural Serbian speech recordings was created, comprising three speakers and recordings of different durations.

The experimental analysis began with a direct comparison between the original Whisper and Faster-Whisper systems using the WER metric, transcription time, RTF, and memory consumption. The effects of model size, INT8 and FLOAT32 quantization, the Beam Search parameter, VAD, background noise, and different SNR levels were then investigated. A controlled comparison of Serbian and English speech recognition was also performed, together with a simulation of streaming transcription using different audio segment sizes.

Based on the obtained results, a procedure for automatic configuration selection was developed using multi-criteria optimization, Pareto analysis, and sensitivity analysis. The Faster-Whisper Small INT8 configuration provided the most favorable trade-off between accuracy, speed, and measured memory requirements, achieving an average WER of 22.43% and an average RTF of 0.327. Results from separate experiments were also used to select appropriate Beam Search, VAD, and streaming settings.

A separate part of the thesis focuses on domain adaptation of the Whisper model for Serbian speech in the field of agriculture. For this purpose, a dataset of 800 audio recordings was created, with 675 recordings used for training, 75 for validation, and 50 for testing. The test set contains speech from a fourth speaker who was not included in the training set, allowing the generalization ability of the adapted model to be evaluated on an unseen speaker. ()

The conducted analysis shows that selecting an appropriate model size, quantization method, and transcription parameters enables the Faster-Whisper system to be adapted to different practical requirements. The main contributions of this thesis are a systematic analysis and optimization of the Whisper system for Serbian speech, an automatic configuration selection procedure, and domain adaptation for a specific application domain.

**Keywords:** automatic speech recognition, Whisper, Faster-Whisper, Serbian language, optimization, domain adaptation.

## СПИСАК КОРИШЋЕНИХ СКРАЋЕНИЦА И ОЗНАКА

### СКРАЋЕНИЦЕ

ASR — аутоматско препознавање говора (**A**utomatic **S**peech **R**ecognition)  
AI — вештачка интелигенција (**A**rtificial **I**ntelligence)  
ML — машинско учење (**M**achine **L**earning)  
DNN — дубока неуронска мрежа (**D**eep **N**eural **N**etwork)  
RNN — рекурентна неуронска мрежа (**R**ecurrent **N**eural **N**etwork)  
LSTM — мрежа са дугом краткорочном меморијом (**L**ong **S**hort-**T**erm **M**emory)  
CTC — конекционистичка временска класификација (**C**onnectionist **T**emporal **C**lassification)  
STFT — кратковремена Фуријеова трансформација (**S**hort-**T**ime **F**ourier **T**ransform)  
MFCC — Mel-фреквенцијски кепстрални коефицијенти (**M**el-**F**requency **C**epstral **C**oefficients)  
WER — стопа грешке на нивоу речи (**W**ord **E**rror **R**ate)  
CER — стопа грешке на нивоу карактера (**C**haracter **E**rror **R**ate)  
RTF — фактор реалног времена (**R**ead-**T**ime **F**actor)  
VAD — детекција говорне активности (**V**oice **A**ctivity **D**etection)  
SNR — однос сигнал–шум (**S**ignal-**t**o-**N**oise **R**atio)  
CPU — централна процесорска јединица (**C**entral **P**rocessing **U**nit)  
GPU — графичка процесорска јединица (**G**raphics **P**rocessing **U**nit)  
RAM — радна меморија (**R**andom **A**ccess **M**emory)  
RSS — величина дела меморије процеса у физичкој меморији (**R**esident **S**et **S**ize)  
TTFR — време до добијања првог резултата (**T**ime **t**o **F**irst **R**esult)  
INT8 — осмобитни целобројни формат података (**8**-bit **I**nteger)  
FLOAT32 — 32-битни формат са покретним зарезом (**32**-bit **F**loating **P**oint)  
HMM — скривљени марковљеви модели (**H**idden **M**arkov **M**odel)  
GMM — гаусов мешовити модел (**G**aussian **M**ixture **M**ode)  
WAV — формат звучне датотеке (**W**aveform **A**udio **V**-file **F**ormat)

### ОЗНАКЕ

S — број замена речи (Substitutions)  
D — број изостављених речи (Deletions)  
I — број уметнутих речи (Insertions)  
N — укупан број речи у референтном тексту  
 $T_{obrada}$  — време потребно за обраду аудио записа  
 $T_{audio}$  — трајање аудио записа  
Q — матрица упита (Query) у Attention механизму  
K — матрица кључева (Key) у Attention механизму  
V — матрица вредности (Value) у Attention механизму  
 $d_k$  — димензија вектора кључева у Attention механизму  
 $S_{WER}$  — нормализовани скор WER метрике у вишекритеријумској оптимизацији  
 $S_{RTF}$  — нормализовани скор RTF метрике  
 $S_{RAM}$  — нормализовани скор меморијске захтевности

## САДРЖАЈ

|                                                                              |           |
|------------------------------------------------------------------------------|-----------|
| <b>1. УВОД.....</b>                                                          | <b>8</b>  |
| 1.1. Предмет, мотивација и циљ рада .....                                    | 8         |
| 1.2. Истраживачка питања и доприноси рада .....                              | 10        |
| 1.3. Организација рада .....                                                 | 11        |
| <b>2. АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА.....</b>                                | <b>14</b> |
| 2.1. Основни принципи и развој ASR система.....                              | 14        |
| 2.2. Обрада и представљање говорног сигнала.....                             | 15        |
| 2.3. Модели дубоког учења за препознавање говора.....                        | 17        |
| 2.4. Метрике за евалуацију ASR система .....                                 | 18        |
| <b>3. WHISPER АРХИТЕКТУРА .....</b>                                          | <b>22</b> |
| 3.1. Transformer и Encoder–Decoder архитектура.....                          | 22        |
| 3.2. Архитектура и начин рада Whisper модела .....                           | 23        |
| 3.3. Тренинг, вишејезичност и варијанте Whisper модела.....                  | 24        |
| <b>4. FASTER-WHISPER И CTRANSLATE2 .....</b>                                 | <b>26</b> |
| 4.1. Faster-Whisper и CTranslate2 механизам.....                             | 26        |
| 4.2. Квантизација и оптимизација извршавања .....                            | 27        |
| 4.3. Beam Search и Voice Activity Detection.....                             | 29        |
| 4.4. Streaming и обрада говора у реалном времену .....                       | 30        |
| <b>5. ЕКСПЕРИМЕНТАЛНА МЕТОДОЛОГИЈА .....</b>                                 | <b>32</b> |
| 5.1. Хардверско и софтверско окружење .....                                  | 32        |
| 5.2. Формирање и структура аудио скупова података .....                      | 33        |
| 5.3. Припрема и претпроцесирање аудио записа .....                           | 35        |
| 5.4. Методологија евалуације и мерења перформанси .....                      | 37        |
| <b>6. ПОРЕЂЕЊЕ WHISPER И FASTER-WHISPER СИСТЕМА .....</b>                    | <b>39</b> |
| 6.1. Поставка експеримента .....                                             | 39        |
| 6.2. Анализа тачности и брзине транскрипције .....                           | 40        |
| 6.3. Анализа потрошње меморије .....                                         | 41        |
| 6.4. Анализа резултата према трајању и говорницима .....                     | 42        |
| <b>7. ЕКСПЕРИМЕНТАЛНА АНАЛИЗА И ОПТИМИЗАЦИЈА FASTER-WHISPER СИСТЕМА.....</b> | <b>46</b> |
| 7.1. Утицај величине модела.....                                             | 46        |
| 7.2. Утицај позадинског шума и SNR вредности.....                            | 49        |

|                                                                    |           |
|--------------------------------------------------------------------|-----------|
| 7.3. Поређење српског и енглеског говора.....                      | 51        |
| 7.4. Утицај Beam Search параметра .....                            | 52        |
| 7.5. Утицај квантизације на перформансе.....                       | 54        |
| 7.6. Утицај Voice Activity Detection алгорита.....                 | 56        |
| 7.7. Streaming и real-time транскрипција .....                     | 59        |
| <b>8. АУТОМАТСКИ ИЗБОР ОПТИМАЛНЕ КОНФИГУРАЦИЈЕ .....</b>           | <b>62</b> |
| 8.1. Вишекритеријумска оптимизација .....                          | 62        |
| 8.2. Рангирање и Pareto анализа конфигурација .....                | 63        |
| 8.3. Анализа осетљивости .....                                     | 65        |
| 8.4. Избор препоручене конфигурације .....                         | 66        |
| <b>9. ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА ЗА СРПСКИ ЈЕЗИК .....</b> | <b>69</b> |
| <b>10. ДИСКУСИЈА И ОГРАНИЧЕЊА ИСТРАЖИВАЊА.....</b>                 | <b>69</b> |
| <b>11. ЗАКЉУЧАК И ПРАВЦИ БУДУЋЕГ РАДА .....</b>                    | <b>69</b> |
| <b>12. ЛИТЕРАТУРА .....</b>                                        | <b>70</b> |

# 1. УВОД

## 1.1. Предмет, мотивација и циљ рада

Последњих година системи за аутоматско препознавање говора (енгл. *Automatic Speech Recognition – ASR*) имају све већу примену у различитим областима. Развој дубоког учења и доступност великих количина говорних података омогућили су развој модела који могу са великом тачношћу да претварају говор у текст. Овакви системи се данас користе за аутоматску транскрипцију, титловање аудио и видео садржаја, гласовне асистенте, контакт центре, образовне платформе и друге примене у којима је потребна аутоматска обрада говора.

Један од познатијих модела за аутоматско препознавање говора је Whisper, који је развила компанија OpenAI. Whisper је заснован на Transformer архитектури и обучен је на великој количини разноврсних аудио података. Подржава велики број језика и може да се користи за транскрипцију говора у различитим условима снимања. Једна од његових предности је то што исти модел може да се примени и на језике за које није посебно обучаван, међу којима је и српски језик. Whisper се углавном анализира као вишејезички модел заснован на Transformer архитектури, са могућношћу примене на различите језике и услове снимања. [1]

Иако Whisper постиже добре резултате, један од проблема приликом његове практичне примене представљају време потребно за обраду аудио записа и потрошња меморије. Ово је посебно важно када се модел покреће на рачунару без снажне графичке картице или када је потребно обрадити већу количину аудио материјала у кратком временском периоду.

Као једно од решења за овај проблем развијен је Faster-Whisper, имплементација Whisper модела која користи CTranslate2 механизам за оптимизовано извршавање Transformer модела. Faster-Whisper не представља нови модел за препознавање говора, већ омогућава ефикасније извршавање постојећих Whisper модела. CTranslate2 подржава различите оптимизације, међу којима су квантизација, ефикасније коришћење меморије и оптимизоване операције приликом инференције. На овај начин могуће је смањити време обраде и меморијске захтеве, што је посебно значајно за извршавање модела на процесору. [6], [7]

Перформансе система за аутоматско препознавање говора не зависе само од тога да ли се користи Whisper или Faster-Whisper. На резултате могу да утичу величина модела, начин квантизације, параметри декодирања, присуство позадинског шума, језик, карактеристике говорника, примена детекције говорне активности и начин на који се аудио сигнал дели на сегменте. Поред тачности транскрипције, у практичним системима важни су и време извршавања, латенција, фактор реалног времена и потрошња меморије.

Посебан део овог рада односи се на примену Whisper модела на српски језик. Иако Whisper подржава српски језик, постоји простор за детаљније испитивање његовог понашања на српском говору. У првобитном прочитању овог рада уочена је

значајна разлика између резултата добијених на енглеском и српском говору, али је анализа била заснована на малом броју аудио записа. Због тога је у овом раду експериментална анализа проширена на већи број природних аудио записа и на више фактора који могу да утичу на рад система.

Предмет овог рада је анализа, оптимизација и доменска адаптација Whisper модела за аутоматско препознавање говора на српском језику. За основну експерименталну анализу формиран је скуп од 40 природних аудио записа на српском језику, различитог садржаја и трајања, које су снимила три говорника. Овај скуп се користи за систематско испитивање различитих конфигурација Whisper и Faster-Whisper система.

У оквиру експерименталног дела анализирано је основно поређење оригиналног Whisper и Faster-Whisper система, утицај величине модела, квантизације, позадинског шума и различитих SNR вредности, језика, *Beam Search* параметра и алгоритма за детекцију говорне активности (*Voice Activity Detection – VAD*). Посебан експеримент односи се на поделу дужих аудио записа на мање сегменте и симулацију рада система у реалном времену. Резултати се посматрају кроз више показатеља, као што су Word Error Rate (WER), време обраде, Real-Time Factor (RTF), латенција и потрошња RAM меморије.

На основу резултата ових експеримената извршен је и аутоматски избор конфигурације Faster-Whisper система. При избору се не посматра само једна метрика, већ се истовремено узимају у обзир тачност транскрипције, брзина рада и меморијски захтеви. На овај начин могуће је упоредити различите конфигурације и одредити ону која представља добар компромис за коришћено хардверско окружење и испитивани скуп података.

Други важан део рада представља доменска адаптација Whisper модела за српски језик у домену пољопривреде. За овај део рада формиран је посебан скуп од укупно 800 аудио записа на српском језику, чији садржај обухвата пољопривредне теме и терминологију. Скуп за обучавање садржи 675 аудио записа три различита говорника, док је за валидацију издвојено 75 аудио записа. За завршно тестирање формиран је посебан скуп од 50 аудио записа четвртог говорника, чији говор није присутан у скупу за обучавање. Оваква подела омогућава да се, поред прилагођавања пољопривредном домену, провери и способност модела да препознаје доменски специфичан говор особе коју није чуо током обучавања.

На формираном пољопривредном говорном скупу извршена је доменска адаптација, односно *fine-tuning* Whisper модела. Основни и адаптирани модел евалуирају се под истим условима како би њихови резултати могли директно да се упореде. Поред укупне тачности транскрипције, посматра се и препознавање речи и израза карактеристичних за пољопривредни домен. Општи скуп српског говора користи се и за проверу понашања адаптираног модела ван домена на коме је додатно обучаван.

Основни циљ рада је да се кроз више контролисаних експеримената испита како различити фактори утичу на тачност, брзину и захтеве за рачунарским ресурсима Whisper и Faster-Whisper система, као и да се одреди конфигурација која даје добар однос између

ових карактеристика приликом препознавања српског говора. Такође, циљ је да се испита доменска адаптација Whisper модела на сопственом скупу српског говора из области пољопривреде и да се упореде основни и доменски прилагођени модел.

На тај начин рад обухвата три повезане целине: анализу Whisper и Faster-Whisper система, оптимизацију њиховог рада и доменску адаптацију за пољопривредни говор на српском језику. Експерименти омогућавају да се систем посматра не само са становишта тачности транскрипције, већ и са становишта брзине, потребних ресурса и могућности прилагођавања конкретној области примене.

## 1.2. Истраживачка питања и доприноси рада

На основу предмета и циљева рада дефинисана су истраживачка питања која се односе на тачност, брзину и практичну примену Whisper и Faster-Whisper модела за препознавање говора на српском језику. Посебна пажња посвећена је факторима који могу да утичу на квалитет транскрипције и ефикасност извршавања, као и могућности прилагођавања модела специфичном домену.

Основно истраживачко питање рада је:

У којој мери је могуће оптимизовати Whisper систем за аутоматско препознавање говора на српском језику са становишта тачности, брзине и потрошње рачунарских ресурса и какав ефекат има доменска адаптација модела на говор из области пољопривреде?

Из основног питања произилази неколико конкретнијих питања која су испитана у експерименталном делу рада:

- Какве разлике постоје између оригиналног Whisper и Faster-Whisper система у погледу тачности транскрипције, времена извршавања, RTF вредности и потрошње RAM меморије?
- Како величина Whisper модела утиче на однос између тачности транскрипције и брзине извршавања?
- У којој мери различити типови позадинског шума и SNR вредности утичу на тачност препознавања говора?
- Какве разлике у резултатима постоје приликом препознавања српског и енглеског говора у контролисаним условима?
- Како вредност *Beam Search* параметра утиче на WER и време потребно за транскрипцију?
- У којој мери INT8 квантизација може да смањи време извршавања и захтеве за ресурсима у односу на FLOAT32 начин извршавања?
- Какав утицај примена VAD алгорита има на брзину и тачност транскрипције?
- Како различите величине аудио сегмената утичу на латенцију, RTF и тачност приликом симулиране обраде говора у реалном времену?

- Да ли је могуће на основу више различитих метрика аутоматски изабрати конфигурацију која представља добар компромис између тачности, брзине и потрошње ресурса?
- Какав утицај доменска адаптација има на препознавање српског говора из области пољопривреде и колико се адаптирани модел успешно примењује на говорника који није био присутан у скупу за обучавање?

Први допринос представља формирање и коришћење скупа од 40 природних аудио записа на српском језику са три говорника, различитог садржаја и трајања. На истом скупу могуће је контролисано поређење више конфигурација и анализа резултата не само у целини, већ и према говорницима и трајању аудио записа.

Други допринос представља проширена анализа фактора који утичу на рад Faster-Whisper система. Поред величине модела и позадинског шума, анализирани су квантизација, *Beam Search*, VAD и сегментација аудио сигнала. На тај начин систем није посматран само кроз тачност транскрипције, већ истовремено кроз WER, време извршавања, RTF, латенцију и потрошњу меморије.

Посебан допринос представља анализа симулиране streaming транскрипције, у којој су дужи аудио записи подељени на сегменте различитог трајања. На овај начин испитан је практичан проблем избора величине сегмента, односно однос између брзине добијања резултата и тачности транскрипције.

Следећи допринос је развој поступка за аутоматски избор конфигурације Faster-Whisper система. Резултати више експеримената обједињени су тако да се конфигурације могу поредити на основу више критеријума. Поред основног рангирања, коришћене су Pareto анализа и анализа осетљивости на различите тежине критеријума, чиме је омогућено да се избор конфигурације не заснива само на једној метрици.

Значајан допринос рада представља и доменска адаптација Whisper модела за српски говор из области пољопривреде. За потребе адаптације формиран је посебан скуп од 800 аудио записа, од којих је 675 намењено обучавању, 75 валидацији и 50 завршном тестирању. Посебно је значајно што тест скуп садржи говор четвртог говорника који није учествовао у обучавању модела. На тај начин евалуација није ограничена само на препознавање познатих гласова, већ обухвата и проверу генерализације адаптираног модела на новог говорника.

Сви наведени доприноси заједно омогућавају да се Whisper систем анализира од основног препознавања српског говора, преко оптимизације инференције и рада у условима ограничених ресурса, до прилагођавања модела конкретном домену.

### 1.3. Организација рада

Рада је организован у дванаест поглавља која постепено обухватају теоријске основе, експерименталну методологију, резултате спроведених експеримената и доменску адаптацију модела.

Након уводног поглавља, у другом поглављу приказане су основне карактеристике система за аутоматско препознавање говора. Представљен је развој ASR система, основни поступци обраде говорног сигнала, модели дубоког учења који се користе за препознавање говора и метрике за њихову евалуацију.

У трећем поглављу описан је Whisper модел. Представљене су Transformer и encoder-decoder архитектура, начин обраде аудио сигнала, основне карактеристике обучавања и вишејезичности модела, као и различите величине Whisper модела.

Четврто поглавље посвећено је Faster-Whisper имплементацији и CTranslate2 механизму. Описане су технике које омогућавају ефикаснију инференцију, укључујући квантизацију и оптимизацију меморије, као и *Beam Search*, VAD и поступци који су значајни за обраду говора у реалном времену.

У петом поглављу представљена је експериментална методологија. Описани су хардверско и софтверско окружење, главни скуп природног српског говора, додатни скупови коришћени у појединачним експериментима, начин припреме аудио записа и поступак мерења тачности и перформанси система.

Шесто поглавље садржи основно поређење оригиналног Whisper и Faster-Whisper система. Поређење је извршено са становишта тачности транскрипције, времена извршавања, RTF вредности и потрошње меморије, уз додатну анализу резултата према говорницима и трајању аудио записа.

У седмом поглављу приказана је главна експериментална анализа и оптимизација Faster-Whisper система. Испитан је утицај величине модела, позадинског шума и SNR вредности, језика, *Beam Search* параметра, квантизације и VAD алгоритма. У оквиру истог поглавља анализирана је и симулирана streaming транскрипција са различитим величинама аудио сегмената.

Осмо поглавље обједињује резултате претходних експеримената кроз поступак аутоматског избора конфигурације. Различите конфигурације пореде се на основу више критеријума, а додатно су примењене Pareto анализа и анализа осетљивости како би се испитала стабилност избора при различитим приоритетима.

У деветом поглављу описана је доменска адаптација Whisper модела за српски језик у области пољопривреде. Приказани су формирање и подела доменског говорног скупа, поступак додатног обучавања модела и методологија поређења основног и адаптираног модела, са посебним освртом на препознавање пољопривредне терминологије и генерализацију на новог говорника.

У десетом поглављу дата је заједничка дискусија добијених резултата и наведена су главна ограничења спроведеног истраживања.

У једанаестом поглављу изведени су закључци рада и наведени могући правци даљег развоја и истраживања.

На крају рада, у дванаестом поглављу, наведена је литература коришћена приликом израде теоријског и експерименталног дела рада.

## 2. АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА

### 2.1. Основни принципи и развој ASR система

Аутоматско препознавање говора (енгл. *Automatic Speech Recognition – ASR*) представља област вештачке интелигенције чији је основни задатак претварање говорног сигнала у текстуални облик. Улаз у ASR систем представља аудио сигнал који садржи говор, док је излаз текстуална секвенца која одговара изговореном садржају. Иако је овај поступак једноставан са становишта корисника, препознавање говора представља сложен проблем јер се говор разликује у зависности од говорника, брзине изговора, акцента, језика, квалитета снимка и присуства позадинског шума.

Развој система за аутоматско препознавање говора траје више деценија. Први системи појавили су се средином двадесетог века и могли су да препознају само ограничен број речи или цифара. Њихове могућности биле су знатно мање од могућности савремених система, а препознавање је углавном било ограничено на унапред дефинисан речник и контролисане услове снимања.

Значајан напредак остварен је применом статистичких метода. Током осамдесетих и деведесетих година широко су коришћени скривени Марковљеви модели (HMM) у комбинацији са Гаусовим моделима мешавина (GMM). HMM модели коришћени су за описивање временске структуре говорног сигнала, док су GMM модели служили за статистичко представљање акустичких карактеристика. Овакав приступ дуго је представљао стандард у области аутоматског препознавања говора, али је захтевао више одвојених компоненти и пажљиву припрему карактеристика сигнала.

Појава дубоког учења довела је до значајне промене у развоју ASR система. Дубоке неуронске мреже омогућиле су моделима да сложене карактеристике говора уче директно из података, чиме је постепено смањена потреба за ручним пројектовањем појединих делова система. Посебно значајну улогу имале су рекурентне неуронске мреже (RNN) и њихова варијанта LSTM, које су погодне за обраду секвенцијалних података и омогућавају коришћење информација из претходних делова говорног сигнала. [3]

Следећи значајан корак представља развој Transformer архитектуре. За разлику од класичних рекурентних мрежа, Transformer се заснива на механизму пажње (*Attention*), који омогућава моделу да одреди који су делови улазне секвенце значајни приликом обраде одређеног елемента. Овај приступ омогућава ефикаснију обраду дугих секвенци и боље моделовање зависности између различитих делова сигнала. Transformer архитектура представља основу Whisper модела који се користи у овом раду. [2]

Без обзира на разлике између појединих архитектура, основни поступак аутоматског препознавања говора може се представити кроз неколико корака. Најпре се говор снима микрофоном и претвара у дигитални аудио сигнал. Након тога се врши припрема сигнала и формирање репрезентације погодне за обраду моделом. Модел анализира добијене карактеристике, а у последњој фази декодер генерише највероватнију текстуалну секвенцу.

Поједностављено, поступак се може представити на следећи начин:

говор → аудио сигнал → претпроцесирање → представљање аудио сигнала → ASR модел  
→ декодирање → текст

Код традиционалних система ови кораци су често били реализовани као више одвојених компоненти. Савремени *end-to-end* системи обједињују велики део поступка у оквиру једног модела који учи везу између аудио сигнала и одговарајуће текстуалне секвенце. Whisper припада управо овој групи система.

На рад ASR система утиче велики број фактора. Иста реченица може звучати различито када је изговарају различите особе, а додатне разлике настају услед брзине говора, пауза, нагласка и начина изговора. Поред карактеристика говорника, значајан утицај имају микрофон, просторија у којој је снимак направљен и присуство различитих врста позадинског шума. Због тога се квалитет ASR система не може поуздано проценити на основу само једног говорника или малог броја идеалних аудио записа.

За практичну примену важна је и брзина рада система. Висока тачност није довољна уколико је за транскрипцију потребно знатно више времена од трајања самог аудио записа. Ово је посебно важно код система који треба да обрађују говор у реалном времену. Због тога се савремени ASR системи анализирају и са становишта односа између тачности, времена обраде и потребних рачунарских ресурса. Управо овај однос представља један од главних предмета експерименталне анализе у овом раду.

## 2.2. Обрада и представљање говорног сигнала

Пре него што аудио сигнал може да се користи као улаз у модел за аутоматско препознавање говора, потребно га је представити у облику погодном за рачунарску обраду. Људски говор у физичком облику представља континуиран звучни талас, док рачунар ради са дискретним дигиталним вредностима. Због тога је први корак снимање и дигитализација говорног сигнала.

Приликом дигитализације аналогни сигнал се узоркује у одређеним временским интервалима. Број узорака који се узимају у једној секунди представља фреквенцију узорковања (*sampling rate*) и изражава се у херцима. На пример, фреквенција узорковања од 16 kHz значи да се у једној секунди формира 16.000 узорака аудио сигнала. На тај начин се континуирани говор претвара у низ нумеричких вредности које рачунар може да обрађује.

Добијени аудио сигнал може да садржи делове тишине, разлике у јачини звука и различите врсте шума. Због тога се пре даље обраде, у зависности од система, могу применити поступци као што су нормализација сигнала, уклањање или смањивање шума, промена фреквенције узорковања и сегментација аудио записа.

Сам временски облик аудио сигнала није увек најпогоднији за анализу особина говора. Важне информације налазе се и у његовом фреквенцијском садржају, односно у

томе које су фреквенције присутне у одређеном тренутку. Због тога се у обради говора често користи кратковремена Фуријеова трансформација (STFT).

Основна идеја STFT поступка је да се аудио сигнал подели на кратке временске оквири и да се за сваки од њих анализира фреквенцијски садржај. На тај начин добија се информација о томе како се фреквенцијске компоненте сигнала мењају током времена. Ово је важно код говора јер се његове карактеристике непрестано мењају током изговарања различитих гласова и речи.

Резултат овакве анализе може се представити помоћу спектрограма. Спектрограм представља временско-фреквенцијску репрезентацију аудио сигнала: једна оса представља време, друга фреквенцију, док вредности унутар спектрограма описују интензитет појединих фреквенцијских компоненти. На овај начин модел добија много погоднији приказ структуре говорног сигнала него када би се посматрао само оригинални таласни облик.

У системима за препознавање говора често се користи и Mel скала, која је формирана тако да боље одговара начину на који човек доживљава разлике у фреквенцији. На спектар сигнала примењује се скуп Mel филтера, чиме се добија Mel спектрограм. Уместо равномерног представљања целог фреквенцијског опсега, већи значај се даје расподели која је ближа перцепцији људског слуха.

Следећи корак може бити логаритамска трансформација вредности Mel спектрограма, чиме се добија лог-Mel спектрограм. Оваква репрезентација је погодна за примену дубоких неуронских мрежа и користи се као улаз у Whisper модел. [1]

Поред спектрограма, у традиционалним системима за препознавање говора често су коришћени Mel Frequency Cepstral Coefficients (MFCC). Они представљају компактнији опис спектралних карактеристика говорног сигнала и дуго су били један од стандардних начина представљања говора у ASR системима. Развој дубоког учења омогућио је моделима да све већи део потребних карактеристика науче директно из спектралних репрезентација, због чега модели као што је Whisper користе лог-Mel спектрограм као улаз.

За Whisper систем поступак се зато поједностављено може представити као:

аудио сигнал → узорковање и припрема → STFT → Mel филтерска банка → лог-Mel спектрограм → Whisper encoder → decoder → транскрипција [1], [5]

Начин припреме аудио сигнала има директан утицај на касније препознавање говора. Позадински шум мења спектралне карактеристике сигнала, дуги периоди тишине повећавају количину аудио материјала који се обрађује, док неправилна сегментација може довести до губитка контекста или дела изговорене речи. Због тога су у експерименталном делу овог рада посебно анализирани позадински шум, детекција говорне активности и сегментација аудио сигнала. На тај начин се испитује не само сам модел, већ и утицај начина на који се говорни сигнал припрема и прослеђује систему за транскрипцију.

## 2.3. Модели дубоког учења за препознавање говора

Примена дубоког учења значајно је променила начин на који се развијају системи за аутоматско препознавање говора. За разлику од традиционалних приступа, код којих је систем био подељен на више засебних компоненти, савремени модели могу да науче сложену везу између аудио сигнала и одговарајућег текста на основу великог броја примера.

Један од првих значајнијих приступа заснованих на дубоком учењу биле су дубоке неуронске мреже (DNN). Оне су коришћене за акустичко моделирање и постепено су замениле GMM моделе у многим ASR системима. Њихова предност била је могућност учења сложенијих зависности у говорном сигналу, али саме по себи нису биле довољно погодне за моделовање дужих временских зависности које су карактеристичне за говор.

За обраду секвенцијалних података значајну примену добиле су рекурентне неуронске мреже (RNN). Код њих се информација из претходних корака преноси на наредне кораке, што омогућава да се приликом анализе тренутног дела сигнала узме у обзир и претходни контекст. Ова особина је важна код препознавања говора, јер значење и препознавање одређеног гласа или речи често зависе од онога што је претходно изговорено.

Класичне RNN мреже имају потешкоће при учењу зависности које обухватају већи број временских корака. Као једно од решења развијене су Long Short-Term Memory (LSTM) мреже. LSTM користи посебне механизме којима контролише које информације треба задржати, а које одбацити. На тај начин може успешније да обрађује дуге секвенце и због тога је дуго представљао важан приступ у системима за препознавање говора. [3]

Даљи развој довео је до све веће примене end-to-end модела. Основна идеја овог приступа је да се што већи део процеса препознавања обједини у један модел. Уместо засебног пројектовања великог броја компоненти, модел се обучава на паровима аудио записа и одговарајућих транскрипата и учи како да из улазног говора генерише текст.

У оквиру end-to-end приступа користе се различити начини повезивања аудио сигнала и текста. Један од њих је Connectionist Temporal Classification (CTC), који омогућава обучавање модела без потребе да се унапред зна тачно временско поравнање сваког дела аудио сигнала са одговарајућим карактером или речју. Ово је значајно јер аудио запис и текст имају различите дужине и не постоји једноставна веза између сваког аудио оквира и једног текстуалног симбола. [4]

Други приступ заснива се на encoder-decoder архитектури. Encoder обрађује улазни сигнал и формира његову унутрашњу репрезентацију, док decoder на основу те репрезентације генерише излазну текстуалну секвенцу. У комбинацији са механизмом пажње, decoder може приликом генерисања текста да користи различите делове информација добијених из улазног сигнала.

Посебно значајан корак у развоју савремених ASR система представља примена Transformer модела. За разлику од RNN и LSTM архитектура, Transformer се не ослања на класичну рекурентну обраду секвенце, већ користи механизам пажње. То омогућава ефикасније моделовање зависности између различитих делова улазних података и представља основу великог броја савремених модела за обраду језика и говора. [2]

Whisper, који представља основу експерименталног дела овог рада, користи управо encoder-decoder Transformer архитектуру. Улазни аудио се претвара у лог-Mel спектрограм и прослеђује encoder-у, док decoder генерише одговарајућу текстуалну секвенцу. Исти модел подржава више задатака, укључујући препознавање језика, транскрипцију и превођење говора на енглески језик.

Једна од важних карактеристика Whisper приступа је начин обучавања. Модел је обучен на приближно 680.000 сати вишејезичних и вишенаменских аудио података, што му омогућава примену на различитим језицима и типовима аудио садржаја без обавезног додатног обучавања за сваки појединачни скуп података. [1]

Whisper је доступан у више величина, од мањих модела који захтевају мање ресурса до већих модела који имају знатно већи број параметара. На пример, оригинална породица обухвата Tiny, Base, Small, Medium и Large моделе. Разлике у величини директно утичу на рачунарске захтеве, али и на могућности модела. Управо због тога је у експерименталном делу овог рада посебно испитан однос између величине Whisper модела, тачности препознавања и времена извршавања.

Поред коришћења већ обученог модела, савремени приступ омогућава и његово додатно обучавање на специфичном скупу података. Овај поступак, познат као fine-tuning, омогућава да се знање већ обученог модела прилагоди одређеном језику, говорном стилу или домену. У овом раду такав приступ је примењен за доменску адаптацију Whisper модела на српски говор из области пољопривреде. Детаљан поступак припреме података, обучавања и евалуације адаптираног модела приказан је у деветом поглављу.

## 2.4. Метрике за евалуацију ASR система

За поређење система за аутоматско препознавање говора није довољно посматрати само добијени текст. Потребне су метрике којима се резултати различитих модела и конфигурација могу изразити бројчано и упоредити под истим условима. У овом раду посматрају се две основне групе показатеља: метрике тачности транскрипције и метрике перформанси система.

### Word Error Rate (WER)

Основна метрика за процену тачности у овом раду је Word Error Rate (WER). Она показује колико се речи у добијеној транскрипцији разликује од познатог референтног текста. WER је уједно једна од стандардних метрика за поређење ASR система.

Израчунава се на основу три врсте грешака:

- S (Substitutions) – број замењених речи,
- D (Deletions) – број изостављених речи,
- I (Insertions) – број додатих речи.

Ако је са  $N$  означен укупан број речи у референтном тексту, WER се израчунава као:

$$WER = \frac{S+D+I}{N}$$

Добијена вредност се најчешће изражава процентуално. Мања вредност означава бољу транскрипцију, док WER од 0% значи да се транскрипција у потпуности поклапа са референтним текстом.

На пример, ако референтни текст садржи 100 речи, а систем направи 5 замена, 3 изостављања и 2 додавања, добија се:

$$WER = \frac{5+3+2}{100} = 0,10 = 10\%$$

Важно је напоменути да WER може бити и већи од 100%. То се дешава када модел генерише велики број речи које не постоје у референтном тексту, односно када број замена, брисања и нарочито уметања постане већи од броја референтних речи. Ова особина WER метрике је значајна приликом анализе веома деградираних аудио сигнала.

Пре израчунавања WER вредности потребно је водити рачуна и о нормализацији текста. Разлике у интерпункцији, великим и малим словима или начину записивања одређених речи могу повећати WER иако суштинска разлика у препознатом говору није велика. И оригинални Whisper рад указује на овај проблем и примењује стандардизацију текста пре израчунавања WER метрике. [1]

### **Character Error Rate (CER)**

Поред грешака на нивоу речи, тачност транскрипције може се анализирати и на нивоу појединачних карактера помоћу метрике Character Error Rate (CER).

Принцип израчунавања је исти као код WER метрике:

$$CER = \frac{S_c + D_c + I_c}{N_c}$$

где  $S_c$ ,  $D_c$  и  $I_c$  представљају број замена, изостављања и додавања карактера, док  $N_c$  представља број карактера у референтном тексту.

CER омогућава детаљнији увид у грешке код речи које су делимично исправно препознате. На пример, једна погрешно препозната реч може представљати целу грешку приликом израчунавања WER метрике, иако се разликује од исправне речи само у једном или два слова. Због тога WER и CER могу заједно да дају потпунију слику квалитета транскрипције.

### **Време транскрипције**

Поред тачности, у овом раду значајно је време потребно за транскрипцију аудио записа. Оно представља време од покретања обраде до добијања резултата транскрипције и изражава се у секундама.

Ова вредност омогућава директно поређење различитих имплементација, величина модела и начина квантизације. Ипак, само време транскрипције није увек довољно за поређење, јер аудио записи могу имати различито трајање. Због тога се користи и RTF метрика.

### **Real-Time Factor (RTF)**

Real-Time Factor (RTF) представља однос времена потребног за обраду и трајања аудио записа:

$$RTF = \frac{t_{обрада}}{t_{аудио}}$$

где  $t_{обрада}$  представља време потребно за транскрипцију, а  $t_{аудио}$  трајање аудио записа.

Ако аудио запис траје 60 секунди, а систем га обради за 15 секунди, добија се:

$$RTF = \frac{15}{60} = 0,25$$

Вредност  $RTF < 1$  значи да систем обрађује аудио брже од његовог реалног трајања.  $RTF = 1$  означава обраду приближно брзином реалног времена, док  $RTF > 1$  значи да је за обраду потребно више времена од трајања аудио сигнала.

RTF је посебно користан у овом раду јер омогућава поређење брзине обраде аудио записа различитих дужина.

### **Потрошња RAM меморије**

Приликом локалног покретања ASR модела важан показатељ представља и потрошња RAM меморије. Већи модели и начини извршавања са већом нумеричком прецизношћу могу захтевати значајно више меморије, што ограничава њихову примену на слабијем хардверу.

У овом раду меморијска потрошња посматра се пре свега приликом поређења оригиналног Whisper и Faster-Whisper система, као и различитих величина модела и начина квантизације. При тумачењу ових резултата потребно је узети у обзир да се мери меморија процеса у коме се модел извршава, па добијене вредности представљају практично мерење у коришћеном окружењу, а не апсолутну величину самог модела.

### **Латенција**

Код обраде говора у реалном времену поред укупног времена транскрипције важна је и латенција. Она описује кашњење између пријема дела аудио сигнала и добијања одговарајућег резултата.

Ова метрика постаје посебно важна када се аудио не обрађује као један комплетан запис, већ се дели на мање сегменте. Мањи сегменти могу омогућити раније добијање првих резултата, али истовремено могу смањити количину контекста доступног моделу и тиме погоршати тачност. Због тога се код streaming приступа латенција посматра заједно са WER и RTF вредностима.

Ниједна од наведених метрика сама по себи није довољна за потпуну оцену ASR система. Конфигурација са најмањим WER-ом може истовремено бити сувише спора или захтевати превише меморије, док најбржи модел може имати неприхватљив број грешака. Због тога се у експерименталном делу рада резултати анализирају кроз више метрика, а њихово заједничко посматрање касније представља основу за избор одговарајуће конфигурације система.

## 3. WHISPER АРХИТЕКТУРА

### 3.1. Transformer и Encoder–Decoder архитектура

Whisper је заснован на Transformer архитектури, која је постала једна од основних архитектура за обраду секвенцијалних података. За разлику од RNN и LSTM мрежа, Transformer не захтева класичну рекурентну обраду елемената секвенце један по један. Његов кључни део представља механизам пажње (*Attention*), који омогућава моделу да приликом обраде једног дела секвенце узме у обзир и друге њене делове.

Основу механизма пажње чине три представе: Query (Q), Key (K) и Value (V). На основу њих модел одређује колики значај треба доделити различитим деловима улазне секвенце. Механизам пажње може се представити изразом:

$$Attention(Q,K,V)=softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

Матрице Query и Key користе се за одређивање повезаности између елемената секвенце, док Value садржи информације које се на основу израчунатих тежина даље користе. Делјење са  $\sqrt{d_k}$  спречава да вредности скаларних производа постану превелике са повећањем димензионалности вектора. [2]

У пракси Transformer користи Multi-Head Attention, односно више механизма пажње који раде паралелно. На овај начин различите главе могу да науче различите односе између делова секвенце. Поред механизма пажње, Transformer блокови садрже потпуно повезане слојеве, резидуалне везе и нормализацију, који заједно омогућавају стабилно обучавање дубљих мрежа. [2]

Whisper користи Encoder–Decoder Transformer архитектуру. Ова организација подразумева да модел има два главна дела са различитим улогама. Encoder је задужен за обраду улазног аудио сигнала, док decoder на основу информација добијених од encoder-а генерише текстуалну секвенцу.

Encoder добија репрезентацију говорног сигнала и претвара је у низ унутрашњих репрезентација које описују важне особине аудио садржаја. Механизам *self-attention* омогућава му да повеже информације из различитих делова улазног сигнала. На пример, информација из једног дела изговорене реченице може да буде значајна за правилно тумачење неког каснијег дела.

Decoder има другачији задатак. Он постепено формира транскрипцију, при чему се текст не генерише као целина, већ токен по токен. Приликом избора следећег токена decoder користи претходно генерисане токене и информације које је добио од encoder-а. На тај начин се акустичка информација из аудио сигнала повезује са текстуалним контекстом.

Оваква архитектура је погодна за препознавање говора јер улазна и излазна секвенца не морају имати исту дужину. Неколико секунди аудио сигнала може да садржи различит број речи и токена, па модел сам учи везу између говорног и текстуалног садржаја.

### 3.2. Архитектура и начин рада Whisper модела

Whisper представља *end-to-end* систем за препознавање говора заснован на описаној Encoder–Decoder Transformer архитектури. Основни поступак рада може се представити као:

аудио сигнал → лог-Mel спектрограм → encoder → decoder → текстуална транскрипција

Први корак представља припрема аудио сигнала. Whisper стандардно ради са аудио сигналом фреквенције узорковања од 16 kHz. Аудио се затим претвара у лог-Mel спектрограм, који представља улаз у неуронску мрежу. Начин формирања овакве репрезентације описан је у претходном поглављу, па се овде пажња усмерава на њену даљу обраду унутар Whisper модела. [1], [5]

Пре уласка у Transformer блокове, спектрограм пролази кроз почетне конволуционе слојеве. Њихов задатак је да обраде локалне карактеристике спектрограма и припреме одговарајућу репрезентацију за encoder. Пошто Transformer сам по себи нема информацију о редоследу елемената, репрезентацији се додају и информације о позицији.

Добијена секвенца затим пролази кроз више Transformer блокова encoder-а. У сваком блоку механизам пажње анализира односе између различитих делова аудио сигнала. На излазу encoder-а добија се репрезентација која више није само спектрални приказ аудио сигнала, већ садржи информације које модел користи за препознавање његовог говорног садржаја. Основна структура овог поступка наведена је и у претходном раду.

Decoder на основу ове репрезентације генерише транскрипцију. Процес почиње посебним токенима који моделу задају контекст задатка, на пример језик и врсту операције која треба да се изврши. Након тога се текст генерише токен по токен све док модел не дође до ознаке завршетка секвенце.

Токени не морају да одговарају целим речима. Једна реч може бити представљена једним или већим бројем токена, у зависности од начина на који је присутна у речнику модела. Овакав приступ омогућава коришћење истог система токенизације над великим бројем различитих речи и језика. [1]

Приликом генерисања транскрипције модел за сваки следећи токен формира расподелу вероватноћа могућих кандидата. Начин избора између њих зависи и од поступка декодирања. Једноставнији приступ бира највероватнији наредни токен, док Beam Search истовремено задржава више могућих секвенци и током декодирања тражи

повољнију целокупну секвенцу. Утицај овог параметра на тачност и време транскрипције посебно је испитан у експерименталном делу рада.

Whisper не користи ову архитектуру искључиво за класичну транскрипцију. Задатак се моделу задаје помоћу посебних токена, што омогућава препознавање језика, транскрипцију на изворном језику, превођење говора на енглески и генерисање временских ознака. Због тога више задатака може да се реализује у оквиру исте архитектуре.

Важно је истаћи да Faster-Whisper не мења основну архитектуру и обучене параметре Whisper модела. Главна разлика налази се у начину извршавања, јер Faster-Whisper користи CTranslate2 и његове оптимизације. Због тога се архитектура Whisper модела разматра одвојено од оптимизација инференције, које су предмет наредног поглавља.

### 3.3. Тренинг, вишејезичност и варијанте Whisper модела

Једна од главних карактеристика Whisper модела је начин на који је обучаван. Уместо обучавања искључиво на мањим, пажљиво припремљеним скуповима говорних података, за Whisper је коришћен велики број аудио записа прикупљених са интернета и њихових текстуалних описа.

Оригинални Whisper модели обучени су на приближно 680.000 сати аудио података. Скуп садржи енглески и вишејезички говор, као и примере који се користе за задатак превођења говора на енглески језик. Велика количина и разноврсност података један су од разлога због којих модел може да ради са различитим говорницима, језицима и условима снимања. Ова карактеристика Whisper тренинга наведена је и у полазном раду. [1]

Whisper је обучаван као модел са више задатака. Различити задаци представљени су у заједничком формату помоћу посебних токена. На овај начин исти модел учи да препозна језик, транскрибује говор, преводи одговарајући садржај и одређује временске ознаке. Ово је практично јер није потребно користити потпуно одвојен модел за сваки од ових задатака.

За овај рад посебно је значајна вишејезичност Whisper модела. Српски језик је подржан у вишејезичким варијантама модела, па је могуће користити већ обучени Whisper без претходног обучавања сопственог модела од почетка. Ипак, количина и структура тренинг података нису исте за сваки језик, због чега се квалитет препознавања може разликовати између језика. Управо је то један од разлога зашто се у овом раду српски говор посебно анализира.

Whisper је доступан у више величина. У експерименталном делу овог рада коришћене су четири основне варијанте: Tiny, Base, Small и Medium. Оне се разликују по броју параметара, броју Transformer слојева и потребним рачунарским ресурсима. Поред њих постоје и веће варијанте из породице Large. Подела на више величина омогућава избор модела у зависности од конкретне примене и расположивог хардвера. [5]

Мањи модели имају мањи број параметара и захтевају мање ресурса, због чега су погодни за бржу инференцију. Са повећањем величине модела расту меморијски и рачунарски захтеви, али већи капацитет модела може да омогући прецизније препознавање сложенијег говора. Из тог разлога се избор модела не своди једноставно на коришћење највеће доступне варијанте, већ зависи од односа између захтеване тачности и расположивих ресурса. Тај однос се у овом раду не претпоставља унапред, већ се испитује експериментално.

Поред директног коришћења већ обучених модела, Whisper се може додатно прилагодити одређеном скупу података применом поступка fine-tuning-a. При томе се полази од већ научених параметара модела, а обучавање се наставља на новом скупу аудио записа и одговарајућих транскрипата. На тај начин није потребно обучавати ASR модел од почетка, што би захтевало далеко већу количину података и рачунарских ресурса.

У овом раду ова могућност је искоришћена за доменску адаптацију на српски говор из области пољопривреде. Полази се од већ обученог Whisper модела, а додатним обучавањем модел се излаже већем броју примера који садрже пољопривредне појмове и начин њихове употребе у српском језику. Циљ таквог поступка није формирање новог ASR модела од почетка, већ прилагођавање постојећег модела конкретном домену. Сам поступак fine-tuning-a, структура формираног скупа и начин евалуације основног и адаптираног модела детаљније су приказани у поглављу посвећеном доменској адаптацији.

## 4. FASTER-WHISPER И CTRANSLATE2

### 4.1. Faster-Whisper и CTranslate2 механизам

Иако Whisper модели могу да постигну добру тачност транскрипције, њихово извршавање може бити захтевно, посебно када се користе већи модели или када се инференција обавља на CPU-у. Оригинална имплементација заснована на PyTorch-у није првенствено развијена са циљем минималног времена извршавања и потрошње меморије. Због тога су развијене алтернативне имплементације које користе исте обучене Whisper моделе, али оптимизују начин њиховог извршавања.

Faster-Whisper представља имплементацију Whisper модела која за инференцију користи библиотеку CTranslate2. Основна идеја није промена начина на који Whisper препознаје говор нити обучавање новог модела, већ ефикасније извршавање постојећег модела. Ово је важно за практичну примену, јер омогућава да се Whisper користи са мањим временом обраде и другачијим захтевима за рачунарским ресурсима.

CTranslate2 је библиотека намењена ефикасној инференцији Transformer модела. За разлику од општих оквира за дубоко учење, који морају да подрже и обучавање и велики број различитих архитектура, CTranslate2 је усмерен на извршавање већ обучених модела. То омогућава примену оптимизација које су посебно прилагођене инференцији.

Да би Whisper модел могао да се користи у Faster-Whisper систему, његови параметри се конвертују у формат који подржава CTranslate2. При томе се не мења основна Encoder–Decoder Transformer архитектура описана у претходном поглављу. Конвертовани модел и даље садржи научене параметре Whisper модела, али се они чувају и извршавају у облику који је прилагођен CTranslate2 механизму.

Поступак се поједностављено може представити на следећи начин:

Whisper модел → конверзија у CTranslate2 формат → Faster-Whisper → оптимизована инференција → транскрипција

Приликом транскрипције Faster-Whisper најпре припрема аудио сигнал у облику који Whisper модел очекује, након чега CTranslate2 извршава encoder и decoder део мреже. На излазу се добијају токени који се затим претварају у текстуалну транскрипцију. Са становишта корисника резултат је исти тип излаза као код оригиналног Whisper система, док се главне разлике налазе у начину на који се операције модела извршавају.

Једна од важних предности CTranslate2 механизма је могућност ефикаснијег извршавања на различитим типовима хардвера. Библиотека садржи оптимизације за CPU и GPU, а начин извршавања може се прилагодити доступном уређају. Ово је значајно у случају овог рада, јер је главни део анализе усмерен на CPU извршавање, односно на могућност практичног коришћења ASR система без ослањања на снажну графичку картицу.

Faster-Whisper подржава и различите начине рачунске прецизности, као што су FLOAT32 и INT8. Тиме се омогућава да се иста основна архитектура извршава са различитим односом између прецизности израчунавања, брзине и потребних ресурса. Ова особина је посебно важна за експерименте у овом раду, јер омогућава да се у контролисаним условима испита утицај квантизације.

Поред самог извршавања модела, Faster-Whisper омогућава подешавање параметара који утичу на процес транскрипције, као што су језик, *Beam Search* и примена VAD алгорита. Због тога он представља погодну основу за испитивање не само брзине извршавања, већ и начина на који различита подешавања утичу на укупан рад система.

У овом раду Faster-Whisper се зато не посматра као другачији ASR модел у односу на Whisper, већ као оптимизован начин извршавања Whisper модела. Оваква разлика је важна приликом тумачења резултата. Евентуалне разлике у брзини не представљају последицу потпуно другачије неуронске архитектуре, већ начина имплементације и оптимизације инференције. Са друге стране, мање разлике у добијеним транскрипцијама могу настати због различитих имплементационих детаља и подешавања декодирања, због чега се у експериментима пореде и тачност и перформансе система. [6], [7]

## 4.2. Квантизација и оптимизација извршавања

Једна од најзначајнијих могућности које CTranslate2 пружа јесте квантизација модела. Квантизација представља поступак коришћења нумеричких формата ниже прецизности за чување параметара и извршавање одређених операција модела. Циљ је смањење количине података који се обрађују и ефикасније коришћење расположивог хардвера.

Параметри неуронских мрежа се уобичајено могу представљати бројевима са покретним зарезом, на пример у FLOAT32 формату. У том случају за представљање једне вредности користе се 32 бита. Код квантизације се параметри могу представити са мањим бројем битова. За овај рад посебно је значајан INT8 формат, у коме се користе осмобитне целобројне вредности.

Основна идеја може се приказати поређењем:

FLOAT32  $\rightarrow$  32 бита по вредности

INT8  $\rightarrow$  8 бита по вредности

То не значи да ће цео модел у реалном систему аутоматски користити тачно четири пута мање RAM меморије. Поред самих тежина модела, током извршавања постоје и активације, привремени подаци, библиотеке и други делови процеса који заузимају меморију. Ипак, мања нумеричка репрезентација омогућава смањење меморијског оптерећења параметара и може да убрза операције на хардверу који има ефикасну подршку за INT8 израчунавања.

Приликом квантизације потребно је вредности из оригиналног опсега пресликати у мањи број могућих вредности. Због тога квантизована репрезентација није потпуно идентична оригиналној. Теоријски, губитак прецизности може да утиче и на излаз модела, па је приликом практичне примене потребно проверити да ли добијено убрзање оправдава евентуалну промену тачности транскрипције.

Управо због тога се у овом раду INT8 не посматра само као начин за постизање веће брзине. Квантизација се анализира истовремено са становишта времена извршавања, RTF вредности, потрошње меморије и WER метрике. На тај начин може да се утврди да ли смањење нумеричке прецизности доноси практичну корист без значајног нарушавања квалитета препознавања.

Поред квантизације, CTranslate2 примењује и друге оптимизације извршавања. Оне се односе на ефикаснију реализацију операција које се велики број пута понављају у Transformer моделу, боље коришћење процесорских ресурса и смањивање непотребних операција приликом инференције.

Важан део оптимизације представља и управљање меморијом. Код великих неуронских мрежа није важно само колико меморије заузимају параметри модела, већ и колико се привремених података ствара током извршавања. Ефикасније коришћење и поновна употреба меморијских области могу да смање додатне трошкове који настају током инференције.

На CPU-у је значајно и ефикасно коришћење доступних процесорских инструкција и паралелног извршавања. Операције над матрицама представљају велики део израчунавања у Transformer моделима, па њихова оптимизована имплементација може значајно да утиче на укупно време транскрипције. Ефекат ових оптимизација зависи и од конкретног процесора, величине модела и изабраног начина израчунавања.

Из тог разлога није исправно очекивати да INT8 увек донесе исто убрзање или исто смањење меморијске потрошње. Практични ефекат зависи од модела, дужине аудио записа, хардвера и осталих подешавања система. Због тога се стварна корист квантизације у овом раду утврђује мерењем, а не само на основу теоријских карактеристика нумеричких формата.

Посебно је важно разликовати оптимизацију модела за инференцију од његовог додатног обучавања. CTranslate2 и INT8 квантизација не мењају знање модела на начин на који то чини *fine-tuning*. Њихов циљ је да већ обучени модел буде ефикасније извршен. Доменска адаптација из области пољопривреде, са друге стране, мења параметре модела кроз додатно обучавање на новом скупу података. На тај начин су у овом раду раздвојена два различита приступа побољшању ASR система: оптимизација начина извршавања и прилагођавање самог модела специфичном домену. [7]

### 4.3. Beam Search и Voice Activity Detection

Поред избора модела и начина квантизације, на рад Faster-Whisper система утичу и параметри који одређују начин декодирања и припреме аудио сигнала. У овом раду посебно су разматрани Beam Search и Voice Activity Detection (VAD), јер оба механизма могу да утичу на однос између тачности транскрипције и времена потребног за обраду.

Приликом генерисања транскрипције Whisper decoder за сваки корак одређује вероватноће могућих наредних токена. Најједноставнији приступ је да се у сваком кораку изабере само токен са највећом вероватноћом. Овакав поступак је брз, али локално највероватнији избор не мора увек да доведе до најбоље целокупне текстуалне секвенце.

Beam Search представља поступак декодирања код кога се истовремено задржава више могућих кандидата за транскрипцију. Параметар *beam size* одређује број кандидата који остају у разматрању током генерисања текста. Након сваког корака кандидати се проширују новим токенима, оцењују се добијене секвенце, а задржава се ограничен број најбоље оцењених. [6]

На пример, код вредности *beam size* = 1 практично се прати само један кандидат. Код вредности *beam size* = 5 током декодирања задржава се више могућих секвенци, па модел има већу могућност да избегне избор који је у једном тренутку деловао највероватније, али касније доводи до лошије транскрипције.

Повећање вредности овог параметра, међутим, повећава и број операција које decoder мора да изврши. Због тога већи *beam size* може да побољша резултат декодирања, али истовремено повећава време транскрипције. Такође, повећавање броја кандидата не значи да ће се тачност стално побољшавати. После одређене вредности добитак може постати веома мали или потпуно изостати, док време извршавања наставља да расте. Из тог разлога је у овом раду утицај различитих вредности *beam size* испитан експериментално, а не претпостављен унапред.

Други механизам који је значајан за практичну обраду говора је Voice Activity Detection (VAD). Његов задатак је да у аудио сигналу одреди делове у којима је присутан говор и да их разликује од периода без говорне активности.

Аудио запис у реалним условима често не садржи непрекидан говор. Између реченица и речи могу да постоје паузе, а дужи снимци могу да садрже и значајне периоде тишине. Уколико се цео такав запис директно проследи ASR моделу, систем обрађује и делове у којима нема корисног говорног садржаја.

Применом VAD алгоритма најпре се проналазе сегменти са говорном активношћу, након чега се они прослеђују систему за транскрипцију. Поједностављено, поступак се може представити као:

аудио сигнал → VAD → издвајање говорних сегмената → Whisper → транскрипција

На овај начин могуће је смањити количину аудио материјала коју модел стварно обрађује. Ефекат VAD-а зато највише зависи од структуре снимка. Код аудио записа који садрже дуге периоде тишине корист може бити већа, док код готово непрекидног говора нема много материјала који се може изоставити.

Примена VAD-а ипак мора да буде довољно пажљива. Ако алгоритам погрешно процени почетак или крај говорног сегмента, може да одсече део изговорене речи или кратак део говора. То може да утиче на каснију транскрипцију. Због тога није довољно посматрати само да ли VAD смањује време обраде, већ је потребно проверити и да ли при томе долази до промене WER вредности.

У овом раду Beam Search и VAD имају различите улоге у оптимизацији система. Beam Search утиче на начин претраживања могућих текстуалних секвенци током декодирања, док VAD утиче на количину и делове аудио сигнала који се прослеђују моделу. Њихов стварни утицај на тачност и брзину анализиран је у засебним експериментима. [8]

#### 4.4. Streaming и обрада говора у реалном времену

Код класичне транскрипције комплетан аудио запис је доступан пре почетка обраде. Такав приступ је погодан за транскрипцију већ снимљених аудио и видео материјала, али није довољан за примене у којима резултат треба приказивати док особа још увек говори. У таквим случајевима потребна је обрада говора у реалном или приближно реалном времену.

Под streaming транскрипцијом подразумева се обрада аудио сигнала који пристиже постепено, уместо чекања да се заврши цео снимак. Аудио се најчешће дели на мање сегменте, односно *chunk*-ове, који се редом прослеђују ASR систему.

Основни поступак може се приказати као:

аудио ток → сегмент → транскрипција → следећи сегмент → транскрипција → ...

Један од главних проблема оваквог приступа представља избор трајања сегмента. Ако су сегменти веома кратки, систем може раније да започне обраду и корисник потенцијално брже добија први резултат. Међутим, модел тада има мање контекста на располагању. Реч или реченица може бити пресечена на граници два сегмента, а независна транскрипција кратких делова може да доведе до већег броја грешака.

Са друге стране, дужи сегменти обезбеђују више говорног контекста и по структури су ближи класичној транскрипцији целог аудио записа. Недостатак је што систем мора дуже да чека да се сегмент прикупи пре него што може да започне његову обраду. Због тога постоји компромис између латенције и тачности транскрипције.

За процену могућности рада у реалном времену значајан је RTF. Ако је за обраду једног сегмента потребно мање времена него што траје сам сегмент, систем у принципу

може да прати долазни аудио без сталног нагомилавања необрађених података. Међутим, RTF сам по себи не описује целокупно понашање streaming система.

Важна је и латенција обраде, односно време потребно да систем обради појединачни сегмент. Поред просечне вредности може се посматрати и високи перцентил, на пример P95 латенција, који показује испод које вредности се налази 95% измерених времена обраде. На тај начин се поред типичног понашања система могу уочити и повремена већа кашњења.

За кориснички доживљај значајно је и време до првог резултата (Time to First Result – TTFR). Оно показује колико времена протекне од почетка аудио тока до тренутка када је доступан први резултат транскрипције. Ова вредност зависи и од трајања изабраног сегмента, јер систем најпре мора да прикупи довољну количину аудио сигнала за његову обраду.

Уколико обрада сегмента траје дуже него што нови аудио подаци пристижу, може доћи до стварања реда чекања, односно нагомилавања необрађених сегмената. У том случају кашњење се временом повећава и систем више не може стабилно да прати говор у реалном времену. Због тога се приликом анализе streaming система, поред WER-а и RTF-а, могу посматрати и величина реда чекања и кашњење добијених резултата.

Whisper по својој основној архитектури није класичан streaming ASR модел који интерно обрађује непрекидан аудио ток без сегментације. Практичан приступ је зато да се долазни аудио дели на сегменте и да се сваки од њих обрађује Whisper или Faster-Whisper моделом. Квалитет таквог решења у великој мери зависи од начина сегментације и количине контекста доступне моделу.

У овом раду streaming је испитан кроз симулацију над унапред снимљеним дужим аудио записима, а не директним снимањем са микрофона. На тај начин је могуће контролисано поредити различите величине сегмената под истим условима. Аудио записи се деле на сегменте, који се затим независно транскрибују редоследом којим би пристизали у реалном систему.

Овакав приступ не представља потпуну имплементацију продукционог streaming система, али омогућава анализу његовог најважнијег проблема: како величина сегмента утиче на WER, RTF, латенцију, време до првог резултата и могуће нагомилавање обраде. На основу тих показатеља могуће је упоредити испитане величине сегмената и одредити која од њих у датим условима даје најприхватљивији однос између брзине добијања резултата и тачности транскрипције.

## 5. ЕКСПЕРИМЕНТАЛНА МЕТОДОЛОГИЈА

### 5.1. Хардверско и софтверско окружење

Сви главни експерименти у овом раду изведени су у локалном рачунарском окружењу са оперативним системом Windows, при чему је за извршавање Whisper и Faster-Whisper модела коришћен CPU. Овакав избор окружења омогућава анализу применљивости система на рачунару без ослањања на снажну графичку картицу, што је посебно важно приликом испитивања оптимизација које нуди Faster-Whisper. [5], [6]

Основно Python окружење организовано је помоћу Anaconda платформе, у засебном окружењу. Експерименти су развијани и извршавани кроз Jupyter Notebook, што је омогућило да се код за припрему података, покретање модела, мерење перформанси и анализу резултата организује у одвојене експерименталне целине.

За рад са оригиналним Whisper моделом коришћена је библиотека OpenAI Whisper, која модел извршава помоћу PyTorch оквира. Пошто је инференција вршена на CPU-у, оригинални Whisper је коришћен са FLOAT32 прецизношћу. За оптимизовану имплементацију коришћена је библиотека Faster-Whisper, која се ослања на CTranslate2 механизам. У зависности од експеримента, Faster-Whisper модели покретани су са INT8 или FLOAT32 начином израчунавања.

У експериментима су коришћене различите величине Whisper модела: Tiny, Base, Small и Medium. У основном поређењу оригиналног Whisper и Faster-Whisper система коришћен је Base модел, док је у експериментима посвећеним величини модела и квантизацији анализирано више варијанти. Основни benchmark са природним српским говором садржи 40 аудио записа, а поређење оригиналног Whisper и Faster-Whisper система изведено је коришћењем Base модела на CPU-у.

Поред основних библиотека за покретање модела, коришћени су NumPy и Pandas за обраду и организацију резултата, Matplotlib за графички приказ, JiWER за израчунавање WER метрике и rsutil за праћење потрошње меморије процеса. У појединим деловима рада коришћени су и алати за обраду аудио сигнала, генерисање шума, промену формата и фреквенције узорковања.

Резултати експеримената чувани су у CSV датотекама и посебним директоријумима за резултате, што је омогућило да се касније користе за заједничку анализу без поновног покретања свих модела. Ово је посебно коришћено у експерименту аутоматског избора конфигурације, где су резултати претходних експеримената обједињени и анализирани кроз више критеријума.

Хардверска конфигурација рачунара на коме су извршени главни експерименти рада је у следећем облику:

Процесор: AMD Ryzen 5 5600H with Radeon Graphics 3.30 GHz  
RAM меморија: 8.00 GB (7.34 GB usable)

Оперативни систем: Windows 64-bit  
Начин извршавања: CPU

Навођење хардверске конфигурације важно је јер измерено време транскрипције и потрошња меморије зависе од рачунара на коме се експеримент извршава. Због тога резултати брзине у овом раду представљају мерења у конкретном експерименталном окружењу, док су поређења различитих конфигурација извршена под истим условима.

## 5.2. Формирање и структура аудио скупова података

За потребе експерименталног дела рада коришћено је више аудио скупова, при чему је сваки формиран у складу са циљем одређеног експеримента. Главни скуп намењен анализи Whisper и Faster-Whisper система садржи природан говор на српском језику, док су за испитивање шума, језика, VAD алгорита и доменске адаптације коришћени додатни скупови.

### Главни скуп природног српског говора

Основни benchmark скуп садржи 40 WAV аудио записа на српском језику. Снимке су направила три различита говорника, а садржај је намерно одабран тако да обухвати различите реченице и теме. На тај начин скуп није ограничен на једну област, већ представља општи скуп српског говора намењен поређењу различитих конфигурација система.

Аудио записи су организовани у четири групе према приближном трајању. Снимци од 1 до 10 представљају кратке записе трајања приближно 5–10 секунди, снимци 11–25 средње записе од приближно 15–30 секунди, снимци 26–35 дуге записе од приближно 30–60 секунди, док снимци 36–40 представљају веома дуге записе.

Три говорника нису заступљена потпуно једнаким бројем снимака. Први говорник снимио је 13, други 13, а трећи 14 аудио записа. Оваква структура омогућава да се, поред укупних резултата, анализирају и разлике према говорнику и трајању аудио материјала.

За сваки снимак постоји познат референтни текст, односно тачан текст који је говорник читао. Референтни транскрипти користе се за поређење са текстом који генерише ASR модел и израчунавање WER вредности.

Овај скуп није дељен на train, validation и test подскупове, јер се у основном делу рада не користи за обучавање модела. Његова улога је да представља заједнички benchmark на коме се под контролисаним условима могу поредити различити модели и конфигурације.

## Додатни скупови за појединачне експерименте

Нису сви експерименти захтевали обраду свих 40 снимака. За експерименте који подразумевају већи број поновљених транскрипција формирани су подскупови главног benchmark скупа.

За анализу утицаја величине модела изабрано је 20 снимака који обухватају различита трајања и говорнике. Над њима су испитани Tiny, Base, Small и Medium модели.

За испитивање позадинског шума коришћен је подскуп од 10 природних српских снимака. На оригиналне записе програмски су додавани бели и розе шум, при различитим односима сигнала и шума. Коришћене SNR вредности биле су 20, 10, 5, 0, -5, -10 и -15 dB. Пошто су бучне варијанте настале из истих оригиналних снимака, било је могуће директно поредити транскрипцију чистог сигнала и његових деградираних верзија.

За контролисано поређење српског и енглеског језика коришћен је засебан синтетички скуп који садржи пет аудио записа на српском и пет на енглеском језику. Записи су генерисани истим приступом како би се смањио утицај различитог извора аудио сигнала и омогућило директније поређење два језика.

У експерименту са Beam Search параметром коришћен је подскуп од 15 природних српских аудио записа. Исти снимци транскрибовани су са различитим вредностима *beam size* параметра, чиме је обезбеђено да се утицај декодирања испитује над непромењеним улазним материјалом.

За анализу квантизације коришћен је цео скуп од 40 природних српских снимака. Комбиновањем четири величине модела и два начина израчунавања, INT8 и FLOAT32, добијено је осам конфигурација. Свака конфигурација тестирана је над истих 40 снимака, што је укупно дало 320 измерених транскрипција.

За анализу Voice Activity Detection алгоритма коришћене су две групе аудио записа. Једну групу чинили су синтетички енглески записи, док је друга формирана од природних српских снимака којима су контролисано додате паузе. На тај начин је било могуће поредити исте записе са укљученим и искљученим VAD механизмом. У претходно сачуваним резултатима потврђено је и тестирање пет VAD аудио записа у обе варијанте.

За експеримент симулиране streaming транскрипције коришћено је пет најдужих природних српских снимака из главног скупа. Они су погодни за овај експеримент јер омогућавају поделу на већи број узастопних сегмената. Исти аудио записи обрађивани су као целина и након поделе на сегменте различитог трајања, чиме је омогућено поређење класичне и симулиране streaming обраде.

## Скуп за доменску адаптацију

Поред benchmark скупова, формиран је засебан говорни скуп за доменску адаптацију Whisper модела на српски језик у области пољопривреде. За разлику од претходних скупова, овај скуп се користи за додатно обучавање модела.

Доменски скуп садржи укупно 800 аудио записа са одговарајућим референтним транскриптима. Садржај снимака усмерен је на пољопривреду и обухвата речи, изразе и реченице карактеристичне за овај домен.

Од укупног броја, 675 аудио записа припада скупу за обучавање и обухвата говор три различита говорника. За валидацију је издвојено 75 аудио записа, док завршни тест скуп садржи 50 аудио записа посебног четвртог говорника.

Увођење четвртог говорника само у тест скуп има важну улогу у евалуацији. Модел током fine-tuning поступка није изложен гласу тог говорника, па се завршно тестирање не врши само над новим реченицама, већ и над особом чији говор није био присутан у скупу за обучавање. На овај начин могуће је јасније раздвојити прилагођавање пољопривредној терминологији од простог прилагођавања гласовима говорника који су учествовали у обучавању.

Главни скуп од 40 природних снимака и пољопривредни скуп од 800 снимака зато имају различите улоге. Први служи као општи српски benchmark за анализу и оптимизацију, док други служи за обучавање, валидацију и тестирање доменски адаптираног модела. Ова два скупа се не мешају приликом обучавања, што омогућава да се касније провери и понашање адаптираног модела на општем српском говору.

### 5.3. Припрема и претпроцесирање аудио записа

Пре покретања експеримената било је потребно припремити аудио записе и одговарајуће референтне транскрипте тако да исти подаци могу да се користе за поређење различитих модела и конфигурација. Припрема је зависила од конкретног експеримента, али је основни принцип био да се приликом поређења мења само параметар који се испитује, док остали услови остају што је могуће више непромењени.

Главни скуп од 40 природних аудио записа на српском језику чуван је у WAV формату. За сваки аудио запис постоји одговарајући референтни текст који садржи оно што је говорник изговорио. Називи датотека организовани су тако да садрже редни број снимка и ознаку говорника, на пример 1govornik1.wav. Овакав начин именовања олакшава аутоматску обраду већег броја датотека и каснију анализу резултата према говорницима.

За сваки снимак програмски је одређено његово трајање. Ова информација се користи за израчунавање RTF метрике и за поделу снимака у групе према трајању. Сам аудио садржај главног benchmark скупа није вештачки скраћиван или продужаван за основно поређење, већ су модели тестирани над природним снимцима.

Посебна припрема била је потребна у експерименту са позадинским шумом. Полазни чисти снимци задржани су као референтна варијанта, а затим су програмски формиране њихове верзије са белим и розе шумом. Интензитет шума подешаван је преко односа сигнала и шума (*Signal-to-Noise Ratio* – *SNR*). Коришћене су вредности од 20, 10, 5, 0, –5, –10 и –15 dB. На овај начин исти говорни садржај испитиван је при различитим нивоима деградације, па промена WER вредности може директније да се повеже са присуством и јачином шума.

Припрема је била другачија и у експерименту са Voice Activity Detection алгоритмом. За природни српски део овог експеримента изабрано је пет снимака из главног скупа, а у њих су контролисано додате паузе. У сваком снимку додате су четири паузе случајног трајања између приближно 1,2 и 2,5 секунди. За генерисање је коришћено фиксно почетно стање генератора случајних бројева, чиме је обезбеђена поновљивост поступка. Тако припремљени снимци омогућавају да се VAD испита у условима у којима аудио садржи јасно присутне периоде без говора. Поред природних српских снимака, у истом експерименту коришћена је и група од пет синтетичких енглеских снимака.

Код експеримента са симулираном streaming транскрипцијом коришћено је пет најдужих снимака из главног скупа, односно записи 36–40. Сваки снимак најпре је транскрибован као целина како би се добила основна вредност за поређење, а затим је дељен на независне сегменте трајања 2, 5 и 10 секунди. Пре прослеђивања сегмената моделу аудио сигнал је доведен на фреквенцију узорковања од 16 kHz. Сегменти су затим транскрибовани редоследом којим би пристизали у реалном систему, а њихови резултати су спојени ради израчунавања WER вредности за цео снимак.

За контролисано поређење српског и енглеског језика коришћени су синтетички аудио записи формирани истим поступком. На тај начин је избегнута ситуација у којој би се један језик испитивао на природном, а други на синтетичком говору, јер би у том случају било тешко раздвојити утицај језика од утицаја начина на који је аудио настао.

Референтни и генерисани транскрипти припремани су за израчунавање WER метрике тако да разлике које нису суштински грешке у препознавању, као што су велика и мала слова или одређени интерпункцијски знаци, не утичу непотребно на резултат. Исти поступак нормализације примењиван је на референтни текст и транскрипцију модела, чиме су резултати различитих конфигурација добијени под истим условима.

Посебан поступак припреме примењен је на пољопривредни скуп за доменску адаптацију. Сваки аудио запис повезан је са тачним текстом који му одговара, јер fine-tuning захтева парове аудио записа и транскрипата. Подаци су затим организовани у одвојене скупове за обучавање, валидацију и тестирање. Тест скуп је током обучавања остао потпуно издвојен, а додатну разлику представља то што га је снимио четврти говорник који није присутан у train скупу.

На овај начин припрема података није била потпуно иста за све експерименте, већ је прилагођена ономе што се у конкретном експерименту испитује. Ипак, код свих

поређења задржан је исти основни принцип: конфигурације које се међусобно пореде добијају исти улазни аудио и исти референтни текст.

## 5.4. Методологија евалуације и мерења перформанси

Евалуација Whisper и Faster-Whisper система извршена је кроз више метрика које описују различите аспекте њиховог рада. Главни показатељ тачности је Word Error Rate (WER), док су за анализу перформанси коришћени време транскрипције, Real-Time Factor (RTF), потрошња RAM меморије и, код streaming експеримента, показатељи латенције.

WER је израчунаван поређењем референтног текста са транскрипцијом коју је генерисао модел. Као што је описано у поглављу 2.4, метрика узима у обзир замене, изостављања и додавања речи. Пошто су поједини експерименти обухватали већи број аудио записа, резултати нису анализирани само појединачно, већ су коришћене и збирне вредности.

Као основна збирна мера коришћена је просечна WER вредност по аудио записима, односно макро просек. Поред ње, у појединим експериментима израчунавана је и медијана, која је мање осетљива на појединачне снимке са веома великим бројем грешака. Коришћен је и corpus WER, код кога се грешке и број референтних речи сабирају на нивоу целог скупа пре израчунавања коначне вредности. На тај начин дужи снимци и реченице са већим бројем речи имају пропорционално већи утицај него код обичног просека WER вредности.

За мерење брзине бележено је време транскрипције сваког аудио записа. Мерење обухвата инференцију над датим снимком, док се читавање модела не посматра као део времена транскрипције. Ово је важно јер би у супротном резултат кратких снимака био у великој мери одређен временом иницијалног читавања модела, а не стварном брзином обраде говора.

Поред апсолутног времена израчунаван је RTF, као однос времена обраде и трајања аудио записа. Ова метрика омогућава поређење снимака различитих дужина. За сваки модел или конфигурацију израчунаване су просечне вредности времена и RTF-а, а код појединих експеримената анализирана је и максимална RTF вредност и проценат снимака који су обрађени са  $RTF < 1$ .

Када су две имплементације или конфигурације директно поређене, израчунавано је и убрзање (*speedup*). Оно представља однос времена спорије или основне конфигурације и времена конфигурације са којом се она пореди. На пример, приликом поређења оригиналног Whisper и Faster-Whisper система убрзање је одређено односом времена оригиналног модела и времена Faster-Whisper модела.

За процену меморијских захтева коришћена је библиотека psutil, којом је праћена RSS меморија Python процеса. Мерење је коришћено за практично поређење меморијског оптерећења различитих конфигурација у истом окружењу.

Овде постоји важно ограничење методологије. Пошто се више модела покреће у оквиру истог Jupyter процеса, Python allocator и коришћене библиотеке могу да задрже део претходно резервисане меморије. Због тога измерене RAM вредности не треба тумачити као тачну величину самог модела у меморији, већ као емпиријско мерење промене RSS меморије процеса у коришћеном окружењу. За потпуно изоловано мерење свака конфигурација би морала да се покреће у засебном процесу.

Код експеримената са више конфигурација водило се рачуна да основни параметри транскрипције остану непромењени када нису предмет испитивања. На пример, у анализи величине модела мењана је величина модела, док је код анализе Beam Search-а мењана вредност *beam size*. На тај начин се смањује број додатних фактора који би могли да утичу на резултат.

Посебна методологија коришћена је код streaming експеримента. Поред WER и RTF метрика, мерено је време обраде сваког сегмента, просечна и P95 латенција, време до првог резултата (TTFR), као и појава реда чекања када обрада сегмента не може да прати брзину пристизања аудио података. За сваку величину сегмента резултати су упоређени и са транскрипцијом целог аудио записа.

У експерименту аутоматског избора конфигурације резултати претходних мерења обједињени су кроз вишекритеријумску анализу. За главно поређење конфигурација коришћени су WER, RTF и измерена RAM меморија. Пошто ове метрике имају различите јединице и опсеге вредности, пре њиховог комбиновања извршена је нормализација. Затим су метрикама додељене тежине у складу са значајем тачности, брзине и ресурсне захтевности.

Поред основног рангирања коришћена је Pareto анализа, којом се издвајају конфигурације код којих побољшање једне карактеристике захтева погоршање најмање једне друге. Сprovedена је и анализа осетљивости са различитим расподелама тежина, како би се проверило да ли избор конфигурације значајно зависи од почетно постављених приоритета.

Евалуација доменски адаптираног модела заснована је на директном поређењу основног Whisper модела и модела након fine-tuning-а. Оба модела тестирају се над истим издвојеним пољопривредним тест скупом, који није коришћен током обучавања. Пошто тест скуп садржи четвртог говорника, овакав поступак истовремено омогућава проверу препознавања доменског садржаја и генерализације на новог говорника. Поред тога, општи српски benchmark омогућава проверу да ли се након доменске адаптације мења понашање модела на говору који није везан за пољопривреду.

Овако постављена методологија омогућава да се различити аспекти система не процењују на основу једне вредности. Тачност, брзина, меморијски захтеви и понашање у условима приближним реалном времену посматрају се одвојено, а затим се њихови резултати повезују приликом коначног избора конфигурације.

## 6. ПОРЕЂЕЊЕ WHISPER И FASTER-WHISPER СИСТЕМА

### 6.1. Поставка експеримента

Први експериментални део рада има за циљ директно поређење оригиналног Whisper система и Faster-Whisper имплементације у истим условима. Намера је да се утврди да ли оптимизације које доносе Faster-Whisper и CTranslate2 омогућавају бржу транскрипцију и мање меморијске захтеве, а да при томе не дође до значајног погоршања тачности препознавања српског говора.

За експеримент је коришћен главни benchmark скуп од 40 природних аудио записа на српском језику, који су снимила три различита говорника. Као што је описано у поглављу 5, скуп садржи кратке, средње, дуге и веома дуге записе. На тај начин поређење није ограничено само на једну дужину аудио материјала.

У основном поређењу коришћен је Whisper Base модел у три конфигурације:

1. оригинални Whisper Base,
2. Faster-Whisper Base са INT8 начином израчунавања,
3. Faster-Whisper Base са FLOAT32 начином израчунавања.

Све конфигурације извршаване су на истом CPU окружењу и над истих 40 аудио записа. Ово је важно јер омогућава директно поређење резултата без утицаја различитог тест скупа или различитог хардвера.

За сваки аудио запис мерени су WER, време транскрипције и RTF, док је потрошња RAM меморије посматрана одвојено и анализирана у поглављу 6.3. Поред резултата за појединачне снимке, израчунате су просечне вредности за цео скуп. Додатно су резултати груписани према говорнику и трајању аудио записа, што је предмет поглавља 6.4.

Као основна мера тачности коришћен је WER. За брзину су посматрани просечно време транскрипције и RTF, а за Faster-Whisper INT8 додатно је израчунато убрзање у односу на оригинални Whisper као однос њихових времена обраде.

Важно је нагласити да је циљ овог експеримента поређење конкретних имплементација под коришћеним условима, а не тврдња да једна имплементација мора у свим окружењима да буде бржа или тачнија. На измерене вредности могу да утичу процесор, верзије библиотеке, параметри декодирања и карактеристике аудио материјала. Због тога се закључци у овом поглављу односе пре свега на формирану српски benchmark и експериментално окружење овог рада.

## 6.2. Анализа тачности и брзине транскрипције

Резултати над свих 40 природних српских аудио записа показали су разлике и у тачности и у брзини између посматраних конфигурација. Збирни резултати приказани су у Табели 6.1.

**Табела 6.1.** Поређење Whisper Base и Faster-Whisper Base конфигурација

| Конфигурација               | Просечан WER [%] | Медијана WER [%] | Просечно време [s] | Просечан RTF | Убрзање у односу на Whisper |
|-----------------------------|------------------|------------------|--------------------|--------------|-----------------------------|
| Whisper Base                | 49,52            | 50,00            | 3,617              | 0,163        | 1,00×                       |
| Faster-Whisper Base INT8    | 43,08            | 42,30            | 3,275              | 0,136        | 1,10×                       |
| Faster-Whisper Base FLOAT32 | 42,95            | 45,28            | 4,930              | 0,206        | 0,73×                       |

Са становишта тачности, оригинални Whisper Base остварио је просечан WER од 49,52%, док је код Faster-Whisper INT8 конфигурације добијено 43,08%. Faster-Whisper FLOAT32 остварио је веома сличан резултат од 42,95%. У односу на оригинални Whisper, просечан WER је тако био мањи за приближно 6,44 процентна поена код INT8 и 6,58 процентних поена код FLOAT32 конфигурације.

Ова разлика, међутим, не треба аутоматски тумачити као доказ да CTranslate2 или квантизација сами по себи побољшавају способност Whisper модела да препознаје говор. Све три конфигурације засноване су на истој Base породици модела, али оригинални Whisper и Faster-Whisper не морају имати потпуно идентичне имплементационе детаље процеса декодирања. Због тога добијени резултат показује да је Faster-Whisper у конкретној поставци овог експеримента остварио нижи WER, а не да INT8 квантизација сама по себи повећава тачност модела.

Посебно је занимљиво да су Faster-Whisper INT8 и FLOAT32 дали готово идентичан просечан WER. Разлика између њих износи свега око 0,12 процентних поена, што показује да у овом експерименту прелазак на INT8 није довео до значајног погоршања просечне тачности транскрипције. Овај резултат је важан јер INT8 истовремено има предност са становишта брзине извршавања.

Када се посматра време транскрипције, оригиналном Whisper моделу било је потребно просечно 3,617 s по аудио запису. Faster-Whisper INT8 исти тест скуп обрадио је са просечним временом од 3,275 s, што одговара убрзању од приближно 1,10 пута.

Разлика је јаснија када се посматра RTF. Оригинални Whisper имао је просечан RTF од 0,163, док је Faster-Whisper INT8 остварио 0,136. Обе вредности су знатно испод 1, што значи да су обе конфигурације у просеку обрађивале аудио брже од његовог реалног

трајања. Ипак, INT8 варијанта је у коришћеном окружењу захтевала мање времена у односу на трајање улазног аудио сигнала.

Faster-Whisper FLOAT32 се понаша другачије. Иако је остварио најнижи просечан WER од 42,95%, просечно време транскрипције износило је 4,930 s, а RTF 0,206. У односу на оригинални Whisper, добијено убрзање износи само 0,73×, што у овом случају заправо означава спорије извршавање. Ово показује да употреба Faster-Whisper имплементације сама по себи не гарантује убрзање, већ резултат зависи и од изабраног начина израчунавања.

Најзначајнији резултат овог поређења зато представља Faster-Whisper INT8 конфигурација. Она је у истом експерименту постигла мањи просечан WER, мање просечно време транскрипције и нижи RTF у односу на оригинални Whisper Base. Истовремено, њена тачност је била практично на нивоу Faster-Whisper FLOAT32 варијанте, која је захтевала више времена за обраду.

Ипак, просечне вредности не приказују у потпуности понашање система. Разлике су приметне и између појединачних говорника и група различитог трајања, па се не може закључити да је исти степен побољшања присутан код сваког аудио записа. Та анализа биће детаљније приказана у поглављу 6.4.

У целини, основни експеримент показује да оптимизована Faster-Whisper имплементација са INT8 начином израчунавања представља повољнију конфигурацију од оригиналног Whisper Base модела у условима овог теста. Резултат истовремено показује зашто приликом избора ASR конфигурације није довољно посматрати само WER или само време извршавања, већ је потребно анализирати њихов међусобни однос.

### **6.3. Анализа потрошње меморије**

Поред тачности и времена транскрипције, важан аспект практичне примене ASR система представља и количина радне меморије потребна за његово извршавање. Ово је посебно значајно када се модели покрећу на рачунарима са ограниченим ресурсима или када је потребно истовремено извршавати и друге апликације.

У основном експерименту праћена је промена RSS (Resident Set Size) меморије Python процеса приликом учитавања модела. На овај начин добијена је практична процена додатне количине физичке меморије коју процес заузима након учитавања одговарајуће конфигурације.

За оригинални Whisper Base измерено је приближно 187,68 MB додатне RSS меморије, док је код Faster-Whisper Base INT8 конфигурације измерено приближно 88,75 MB.

**Табела 6.2.** Поређење измерене меморијске потрошње

| Конфигурација            | Измерена промена RSS меморије [MB] | Разлика у односу на Whisper |
|--------------------------|------------------------------------|-----------------------------|
| Whisper Base             | 187,68                             | –                           |
| Faster-Whisper Base INT8 | 88,75                              | –52,7%                      |

У посматраном окружењу Faster-Whisper INT8 је, према овом мерењу, захтевао приближно 98,93 MB мање додатне RSS меморије, односно око 52,7% мање у односу на оригинални Whisper Base.

Ова разлика је значајна са становишта практичне примене. У комбинацији са резултатима из претходног поглавља, Faster-Whisper INT8 је у основном експерименту остварио мањи WER и нижи RTF, а истовремено је измерено и мање меморијско оптерећење. На тај начин оптимизација није посматрана само кроз време извршавања, већ и кроз ресурсе потребне за рад система.

Ипак, добијене вредности потребно је пажљиво тумачити. Коришћена методологија мери RSS целог Python процеса, а не искључиво меморију коју заузимају параметри Whisper модела. На резултат могу да утичу Python окружење, учитане библиотеке, претходно резервисана меморија и начин на који различити оквири управљају меморијом.

Због тога вредности од 187,68 MB и 88,75 MB не треба представљати као апсолутну величину Whisper и Faster-Whisper модела у меморији. Оне представљају емпиријски измерену промену RSS меморије у конкретном експерименталном окружењу и пре свега служе за поређење две конфигурације под истим условима.

За прецизније одређивање меморијских захтева било би потребно сваки модел покренути у засебном, претходно очишћеном процесу и поновити мерење више пута. У оквиру овог рада постојеће мерење је довољно за практично поређење, али наведено ограничење мора се узети у обзир приликом тумачења резултата.

## 6.4. Анализа резултата према трајању и говорницима

Просечне вредности приказане у претходним поглављима дају општу слику перформанси система, али не показују да ли се модели једнако понашају за различите говорнике и различита трајања аудио записа. Због тога су резултати основног експеримента додатно груписани према ове две карактеристике.

### Анализа према трајању аудио записа

Главни скуп подељен је на четири групе: кратке, средње, дуге и веома дуге аудио записе. Резултати су приказани у Табели 6.3.

**Табела 6.3.** Резултати према трајању аудио записа

| Група      | Број | Просечно трајање [s] | WER Whisper [%] | WER FW INT8 [%] | WER FW F32 [%] | Време Whisper [s] | Време INT8 [s] | Време F32 [s] |
|------------|------|----------------------|-----------------|-----------------|----------------|-------------------|----------------|---------------|
| Кратки     | 10   | 6,96                 | 51,62           | 45,99           | 43,18          | 1,437             | 1,171          | 1,689         |
| Средњи     | 15   | 15,35                | 44,97           | 36,04           | 38,35          | 2,234             | 1,638          | 2,680         |
| Дуги       | 10   | 31,83                | 56,66           | 53,01           | 51,82          | 4,632             | 4,105          | 6,377         |
| Веома дуги | 5    | 71,66                | 44,68           | 38,52           | 38,52          | 10,092            | 10,738         | 15,266        |

Резултати показују да не постоји једноставна зависност према којој WER стално расте са повећањем трајања снимка. На пример, оригинални Whisper има највећи просечан WER код дугих снимака, 56,66%, док је код веома дугих снимака вредност мања и износи 44,68%. Слично понашање може се приметити и код Faster-Whisper конфигурација.

Ово показује да трајање само по себи није довољно да објасни тачност транскрипције. Групе садрже различите говорнике и различит говорни садржај, па на WER истовремено утичу изговор, сложеност реченице, конкретне речи и карактеристике говорника.

Ипак, Faster-Whisper конфигурације су у све четири групе оствариле мањи просечан WER од оригиналног Whisper-а. Највећа разлика између оригиналног Whisper-а и INT8 варијанте уочена је код средњих снимака, где WER опада са 44,97% на 36,04%, односно за приближно 8,94 процентна поена.

Када се посматра време извршавања, његово повећање са трајањем аудио записа је очекивано. Код кратких снимака просечно време Faster-Whisper INT8 износи 1,171 s, док код веома дугих достиже 10,738 s. Због тога је за поређење различитих дужина корисније посматрати RTF.

**Табела 6.4.** RTF према трајању аудио записа

| Група      | Whisper | Faster-Whisper INT8 | Faster-Whisper F32 |
|------------|---------|---------------------|--------------------|
| Кратки     | 0,212   | 0,174               | 0,251              |
| Средњи     | 0,148   | 0,108               | 0,177              |
| Дуги       | 0,146   | 0,130               | 0,202              |
| Веома дуги | 0,142   | 0,151               | 0,214              |

Faster-Whisper INT8 има најнижи просечни RTF код кратких, средњих и дугих снимака. Код веома дугих снимака оригинални Whisper је незнатно бољи, са RTF вредношћу 0,142 у односу на 0,151 код INT8 варијанте.

Овај резултат је важан јер показује да убрзање Faster-Whisper система није потпуно једнако за све дужине аудио материјала. Због малог броја веома дугих снимака, свега пет, није оправдано из овога изводити општи закључак да оригинални Whisper постаје ефикаснији за све веома дуге снимке. Резултат се односи на конкретан тест скуп.

### Анализа према говорницима

Други део анализе односи се на разлике између три говорника. Први и други говорник заступљени су са по 13 снимака, док трећи има 14 снимака.

**Табела 6.5.** WER и RTF резултати према говорнику

| Говорник   | Број снимака | WER Whisper [%] | WER FW INT8 [%] | WER FW F32 [%] | RTF Whisper | RTF INT8 | RTF F32 |
|------------|--------------|-----------------|-----------------|----------------|-------------|----------|---------|
| Говорник 1 | 13           | 53,28           | 45,39           | 46,15          | 0,179       | 0,144    | 0,213   |
| Говорник 2 | 13           | 32,77           | 25,68           | 25,50          | 0,134       | 0,114    | 0,173   |
| Говорник 3 | 14           | 61,58           | 57,09           | 56,17          | 0,174       | 0,148    | 0,231   |

Разлике између говорника су знатно израженије него разлике између појединих Faster-Whisper конфигурација. Код оригиналног Whisper-а просечан WER другог говорника износи 32,77%, док код трећег говорника достиже 61,58%. Разлика износи готово 29 процентних поена.

Иста појава остаје присутна и након преласка на Faster-Whisper. INT8 конфигурација има WER од 25,68% за другог, а 57,09% за трећег говорника. Према томе, промена имплементације није уклонила разлику између говорника.

Најнижи WER код све три конфигурације добијен је за говорника 2, док је највећи код говорника 3. То указује да карактеристике говорника имају значајан утицај на резултате овог benchmark скупа.

Међутим, на основу овог експеримента није могуће утврдити **због чега** је један говорник препознат успешније од другог. Потенцијални фактори могу бити брзина говора, изговор, артикулација или сложеност текста, али они у овом експерименту нису независно контролисани.

Faster-Whisper INT8 је у односу на оригинални Whisper смањио просечан WER код сва три говорника. Код говорника 1 смањење износи приближно 7,88 процентних поена, код говорника 2 око 7,10, а код говорника 3 око 4,49 процентних поена. Побољшање, дакле, није истог интензитета код свих говорника.

Са становишта брзине, Faster-Whisper INT8 има нижи просечан RTF од оригиналног Whisper-а код сва три говорника. Faster-Whisper FLOAT32 је, са друге стране, у свакој групи имао већи RTF од обе преостале конфигурације.

Анализа према трајању и говорницима показује да укупни просечан WER од 49,52% за оригинални Whisper и 43,08% за Faster-Whisper INT8 не описује у потпуности понашање система. Перформансе значајно варирају између различитих делова тест скупа, посебно између говорника. Због тога се резултати овог рада односе на формирани benchmark од 40 снимака и три говорника и не треба их директно генерализовати на све говорнике српског језика.

Истовремено, чињеница да су исти снимци транскрибовани свим конфигурацијама омогућава коректно међусобно поређење система у оквиру овог скупа. Овај основни експеримент представља полазну тачку за наредно поглавље, у коме се Faster-Whisper систем детаљније анализира кроз величину модела, шум, језик, Beam Search, квантизацију, VAD и streaming.

## 7. ЕКСПЕРИМЕНТАЛНА АНАЛИЗА И ОПТИМИЗАЦИЈА FASTER-WHISPER СИСТЕМА

Након основног поређења Whisper и Faster-Whisper система, у овом поглављу анализирају се фактори који могу да утичу на рад Faster-Whisper модела. Овде се испитује како избор модела, услови снимања и различита подешавања утичу на тачност и брзину система.

### 7.1. Утицај величине модела


Whisper је доступан у више величина које се разликују по броју параметара и рачунарским захтевима. Због тога је један од првих корака оптимизације био да се утврди колико повећање величине модела стварно доприноси тачности препознавања српског говора и колико се тиме повећава време обраде.

У овом експерименту анализирани су четири Faster-Whisper варијанте: Tiny, Base, Small и Medium. За тестирање је изабрано 20 природних српских снимака из главног скупа. Подскуп је формиран тако да садржи по пет кратких, средњих, дугих и веома дугих снимака. Сви модели тестирани су над истим аудио записима, тако да разлике у резултатима могу директно да се повежу са променом величине модела. [5]


За сваку конфигурацију мерени су просечан WER, медијана WER-а, просечно и укупно време транскрипције и просечан RTF. Добијени резултати приказани су у Табели 7.1 и на сликама 1 и 2.

**Табела 7.1.** Утицај величине Faster-Whisper модела

| Модел  | Број снимака | Просечан WER [%] | Медијана WER [%] | Просечно време [s] | Укупно време [s] | Просечан RTF |
|--------|--------------|------------------|------------------|--------------------|------------------|--------------|
| Tiny   | 20           | 63,97            | 66,54            | 2,648              | 52,963           | 0,0871       |
| Base   | 20           | 40,89            | 40,36            | 4,519              | 90,377           | 0,1405       |
| Small  | 20           | 20,02            | 19,68            | 12,194             | 243,875          | 0,3907       |
| Medium | 20           | 13,14            | 8,17             | 33,557             | 671,142          | 1,0452       |



Слика 1. Утицај велићине модела на време транскрипције



Слика 2. Утицај велићине модела на тачност транскрипције

Резултати показују веома јасну везу између величине модела и тачности транскрипције. Tiny модел има највећи просечан WER од 63,97%, док Base смањује ову вредност на 40,89%. Још већа промена добијена је код Small модела, са просечним WER-ом од 20,02%, док је Medium остварио најнижу вредност од 13,14%.

Прелазак са Tiny на Base тако смањује просечан WER за 23,08 процентних поена, са Base на Small за додатних 20,87 процентних поена, а са Small на Medium за још 6,88 процентних поена. На посматраном скупу повећање модела је, дакле, доследно доводило до боље тачности, али се добитак постепено смањује.

Са друге стране, повећање величине модела значајно повећава време обраде. Tiny моделу је у просеку било потребно само 2,648 s, Base моделу 4,519 s, Small моделу 12,194 s, а Medium моделу чак 33,557 s по снимку. Medium је тако у просеку био око 12,7 пута спорији од Tiny и око 2,75 пута спорији од Small модела.

Исти однос видљив је код RTF метрике. Tiny има просечан RTF од само 0,0871, Base 0,1405, а Small 0,3907. Све три вредности су знатно испод 1, што показује да су ови модели у просеку обрађивали аудио брже од његовог реалног трајања.

Medium модел има просечан RTF од 1,0452, што значи да му је на посматраном скупу у просеку било потребно приближно онолико времена колико траје сам аудио, односно нешто више. Са становишта CPU примене у реалном времену, ова разлика је значајна.

Резултати према групама трајања додатно потврђују да Small модел даје добар однос између тачности и времена. Његов просечан WER износи 15,46% за кратке, 27,21% за средње, 17,61% за дуге и 19,79% за веома дуге снимке, док се просечан RTF креће од 0,339 до 0,472. Medium је у већини група тачнији, али је његов RTF знатно већи и код више група се приближава или прелази вредност 1.

Код Medium модела уочен је и један изражен појединачни резултат на снимку 36govornik1.wav. За овај снимак измерено је време од 102,45 s, RTF од 1,4845 и WER од 100%. Остали веома дуги снимци код истог модела имају знатно нижи WER, па овај резултат представља изузетак у односу на остале снимке. Пошто је укључен у израчунате просеке, није накнадно уклањан из анализе. Истовремено, показује зашто је поред просечног WER-а корисно посматрати и медијану, која код Medium модела износи само 8,17%.

Анализа показује да највећи модел није аутоматски и најпрактичнији избор. Medium пружа најбољу тачност, али уз знатно веће време обраде, док је Tiny веома брз, али са високим WER-ом. У овом експерименту Small представља повољан компромис за CPU извршавање, јер смањује просечан WER на око 20%, док просечан RTF остаје испод 0,4.

Овај закључак се у овом тренутку односи само на однос величине модела и перформанси. Коначни избор конфигурације не доноси се на основу једног експеримента, већ се касније повезује са резултатима квантизације, меморијске потрошње и осталих параметара.

## 7.2. Утицај позадинског шума и SNR вредности

Препознавање говора у реалним условима често се не врши над потпуно чистим аудио сигналом. Разговор може бити снимљен у присуству саобраћаја, рада различитих уређаја, амбијенталног шума или других извора звука. Због тога је у другом експерименту испитана отпорност Faster-Whisper система на контролисано додавање позадинског шума.


За овај експеримент изабрано је 10 природних српских аудио записа са три говорника. На сваки оригинални снимак програмски су додаване две врсте шума: бели и розе шум. За обе врсте коришћено је седам SNR нивоа: 20, 10, 5, 0, -5, -10 и -15 dB.

SNR описује однос корисног говорног сигнала и шума. Виша вредност означава да је говор израженији у односу на шум, док се са смањењем SNR-а шум све више приближава или надјачава корисни сигнал. Оригинални снимци без додатог шума коришћени су као основа за поређење.

Од 10 оригиналних снимака формирано је укупно 140 варијанти са шумом, што са 10 чистих снимака даје 150 транскрипција. Просечан WER чистих снимака износио је 47,89%. Резултату си приказани у Табели 7.1 и на слици 3.

**Табела 7.2.** Просечан WER при различитим SNR вредностима

| SNR [dB] | Бели шум WER [%] | Розе шум WER [%] | $\Delta$ WER бели [pp] | $\Delta$ WER розе [pp] |
|----------|------------------|------------------|------------------------|------------------------|
| Без шума | 47,89            | 47,89            | –                      | –                      |
| 20       | 48,16            | 50,71            | +0,28                  | +2,82                  |
| 10       | 58,75            | 59,06            | +10,87                 | +11,17                 |
| 5        | 65,84            | 63,38            | +17,96                 | +15,49                 |
| 0        | 82,74            | 82,70            | +34,86                 | +34,81                 |
| -5       | 95,86            | 101,76           | +47,97                 | +53,88                 |
| -10      | 115,34           | 104,56           | +67,45                 | +56,67                 |
| -15      | 100,67           | 99,32            | +52,78                 | +51,43                 |



Слика 3. Деградација тачности у доносу на clean audio

При SNR вредности од 20 dB утицај шума је релативно мали. Код белог шума WER расте са 47,89% на 48,16%, што представља повећање од свега 0,28 процентних поена. Код розе шума добијено је нешто веће повећање од 2,82 процентна поена.

Смањењем SNR-а на 10 dB већ се уочава јаснија деградација. Просечан WER расте на 58,75% код белог и 59,06% код розе шума. На 5 dB вредности достижу 65,84% и 63,38%. То показује да систем постепено губи тачност како се енергија шума приближава енергији корисног сигнала.

На 0 dB, када су говорни сигнал и додати шум приближно на истом нивоу, просечан WER расте на око 82,7% за обе врсте шума. У односу на чист сигнал то представља погоршање од приближно 35 процентних поена.

На негативним SNR вредностима долази до веома великог пада квалитета. При -5 dB добијено је 95,86% за бели и 101,76% за розе шум, док при -10 dB WER достиже 115,34% и 104,56%.

WER вредност већа од 100% није грешка у израчунавању. Она је могућа када модел, поред замена и изостављених речи, генерише велики број додатних речи које не постоје у референтном транскрипту. Управо у условима веома јаког шума модел може да генерише погрешне делове текста на основу сигнала у коме говор више није довољно јасан.

Најнижи SNR од -15 dB дао је WER од 100,67% код белог и 99,32% код розе шума. На први поглед ове вредности делују нешто боље од резултата на -10 dB, али то не представља стварни опоравак модела. При веома јаком шуму модел у појединим

случајевима престаје да генерише већи број речи или враћа веома кратку, па чак и празну транскрипцију. Тада доминирају брисања речи, па WER може бити близу 100%, док је при нешто мањем шуму могуће генерисање великог броја погрешно уметнутих речи и WER већи од 100%.

Занимљиво је и понашање времена транскрипције. При 20, 10 и 5 dB просечно време остаје приближно око 4 секунде, док при јаком шуму може значајно да порасте. Код белог шума просечно време на -10 dB износи 21,104 s, а код розе шума чак 25,056 s. Јак шум, дакле, у појединим случајевима не утиче само на тачност већ може да доведе и до сложенијег и дужег процеса декодирања. Ипак, ни овде зависност није потпуно монотона, јер код -15 dB време поново опада, што је повезано и са случајевима у којима модел генерише мало текста.

Када се упореде бели и розе шум, не може се издвојити један тип који је доследно тежи за модел. На 5 dB розе шум има нешто мањи WER, док на -5 dB има већи. На 0 dB резултати су практично идентични. Главни фактор у овом експерименту зато није сама врста шума, већ његов интензитет у односу на говорни сигнал.

Резултати по говорницима такође показују разлике, али број снимака по говорнику у овом подскупу није једнак: четири снимка припадају првом, два другом и четири трећем говорнику. Због малог броја примера није оправдано на основу овог експеримента изводити опште закључке о отпорности појединачних говорника на шум.

У целини, експеримент показује да је Faster-Whisper релативно стабилан када је додати шум слаб, посебно при 20 dB, док се већ на 10 и 5 dB примећује јасно погоршање. Око 0 dB деградација постаје веома изражена, а на негативним SNR вредностима квалитет транскрипције се у коришћеним условима практично урушава. Ово показује да квалитет улазног аудио сигнала остаје један од важних фактора за практичну примену ASR система.

### 7.3. Поређење српског и енглеског говора

Whisper је вишејезички модел, али количина и структура података на којима је обучаван нису једнаке за све језике. Због тога је у овом експерименту испитано како се иста Faster-Whisper конфигурација понаша при транскрипцији српског и енглеског говора. [1]

Да би поређење било што контролисаније, нису коришћени природни српски снимци и синтетички енглески снимци, јер би у том случају на резултат истовремено утицали језик и начин настанка аудио сигнала. Уместо тога, формиран је скуп од пет синтетичких енглеских и пет синтетичких српских аудио записа, генерисаних коришћењем gTTS-а.

За све снимке коришћен је исти Faster-Whisper Base INT8 модел. На тај начин су модел и основни услови транскрипције остали исти, док је главна разлика између две групе била језик аудио садржаја.

Резултати су приказани у Табели 7.3.

**Табела 7.3.** Поређење резултата за енглески и српски синтетички говор

| Језик    | Број снимака | Просечан WER [%] | Медијана WER [%] | Corpus WER [%] | Просечан RTF |
|----------|--------------|------------------|------------------|----------------|--------------|
| Енглески | 5            | 3,50             | 2,70             | 3,30           | 0,076        |
| Српски   | 5            | 44,17            | 43,24            | 43,93          | 0,114        |

Разлика у тачности је веома изражена. Код енглеског говора просечан WER износио је само 3,50%, док је код српског износио 44,17%. Разлика је, дакле, 40,67 процентних поена, док је просечан WER српског скупа био око 12,62 пута већи.

Сличан однос добијен је и када се посматра corpus WER. Код енглеског он износи 3,30%, а код српског 43,93%. То показује да велика разлика није последица само начина на који се израчунава просек по појединачним снимцима.

Резултати по паровима такође показују доследну разлику. WER енглеских снимака кретао се од 0% до 9,09%, док је код одговарајућих српских снимака био између 37,14% и 53,33%. Ни у једном од пет парова српски снимак није остварио резултат близак одговарајућем енглеском снимку.

Поред тачности, уочена је и разлика у брзини. Просечан RTF за енглески износио је 0,076, а за српски 0,114. Обе вредности су испод 1, тако да је систем у оба случаја радио знатно брже од реалног трајања аудио сигнала, али је обрада српских снимака у овом тесту била нешто захтевнија.

Ипак, резултат овог експеримента не треба тумачити као општу тврдњу да Whisper на енглеском језику увек има 12 пута мањи WER него на српском. Скуп садржи свега пет снимака по језику, а оба скупа су синтетички генерисана. Поред тога, gTTS гласови и фонетске карактеристике два језика нису идентични.

Зато резултат показује да је на конкретном контролисаном синтетичком скупу Faster-Whisper Base INT8 знатно успешније транскрибовао енглески него српски говор. Овај резултат додатно оправдава детаљније испитивање Whisper система за српски језик и каснију доменску адаптацију, али сам по себи није довољан за опште поређење перформанси модела на ова два језика.

## 7.4. Утицај Beam Search параметра


Следећи експеримент испитује утицај Beam Search параметра на тачност и брзину транскрипције. За разлику од претходног експеримента, овде је коришћен природни српски говор. [6]

Из главног скупа изабрано је 15 репрезентативних снимака различитих трајања и говорника. У свим тестовима коришћен је Faster-Whisper Base INT8 модел, док је мењана само вредност параметра beam\_size. Испитане су вредности 1, 3, 5 и 10.

Оваква поставка омогућава директнију анализу Beam Search механизма, јер су модел, аудио записи, језик и остали основни услови остали исти. Резултати су приказани у Табели 7.4 и на слици 4.

**Табела 7.4.** Утицај Beam Search параметра

| Beam size | Просечан WER [%] | Медијана WER [%] | Corpus WER [%] | Просечно време [s] | Просечан RTF |
|-----------|------------------|------------------|----------------|--------------------|--------------|
| 1         | 49,09            | 51,85            | 49,03          | 2,499              | 0,1076       |
| 3         | 44,48            | 48,15            | 43,48          | 3,276              | 0,1218       |
| 5         | 43,17            | 48,15            | 43,00          | 4,045              | 0,1425       |
| 10        | 43,76            | 48,15            | 42,39          | 6,439              | 0,1988       |



**Слика 4.** Просечно време транскрипције по конфигурацији

Најједноставнија конфигурација, beam\_size = 1, била је најбржа, са просечним временом транскрипције од 2,499 s и RTF вредношћу од 0,1076. Међутим, истовремено је имала и највећи просечан WER од 49,09%.

Повећањем вредности на 3 просечан WER се смањује на 44,48%, односно за 4,61 процентни поен у односу на beam\_size = 1. Просечно време расте на 3,276 s, што представља приближно 1,31 пута дуже извршавање.

Најнижи просечан WER добијен је за `beam_size = 5` и износи 43,17%. То представља побољшање од 5,92 процентна поена у односу на вредност 1. Просечно време транскрипције износи 4,045 s, односно извршавање је око 1,62 пута спорије него код `beam_size = 1`.

Повећање на `beam_size = 10` није наставило побољшање просечног WER-а. Он износи 43,76%, што је нешто лошије од 43,17% добијених код вредности 5. Истовремено, просечно време расте на 6,439 s, што је приближно 2,58 пута дуже него код вредности 1.

Corpus WER показује нешто другачију слику. Његова најнижа вредност од 42,39% добијена је код `beam_size = 10`, у односу на 43,00% код вредности 5. Разлика износи само 0,61 процентни поен, док је време обраде код `beam_size = 10` око 59% веће него код вредности 5.

Због тога резултати показују да повећање Beam Search параметра до одређене мере доноси значајну корист, али да даље повећање има све мањи ефекат. На овом тест скупу `beam_size = 5` даје најнижи просечан WER и повољнији однос тачности и брзине, док `beam_size = 10` остварује најнижи corpus WER уз знатно већи временски трошак.

Важно је и да су све четири конфигурације имале просечан RTF знатно испод 1. Повећање Beam Search параметра, дакле, није онемогућило обраду бржу од реалног времена на овом скупу, али је постепено повећавало рачунарски трошак.

Ови резултати ће касније бити употребљени приликом аутоматског избора конфигурације. При томе се не посматра само конфигурација са најнижом грешком, већ однос између побољшања WER-а и додатног времена потребног за декодирање.

## 7.5. Утицај квантизације на перформансе

Након анализе величине модела и Beam Search параметра, испитан је утицај INT8 квантизације на перформансе Faster-Whisper система. Циљ овог експеримента био је да се утврди колико INT8 начин израчунавања може да смањи време обраде и RTF у односу на FLOAT32 и да ли ефекат зависи од величине модела. [7]

За експеримент су коришћена сва 40 природна српска аудио записа. Испитана су четири модела — Tiny, Base, Small и Medium — у две варијанте, INT8 и FLOAT32. На тај начин добијено је осам конфигурација, а свака је тестирана на истих 40 снимака. Укупно је извршено 320 транскрипција.

Основни параметри декодирања били су исти за све конфигурације: CPU извршавање, српски језик, `beam_size = 1`, температура 0 и искључен VAD. Пре мерења вршен је и *warm-up* модела како би се умањио утицај иницијалног покретања на резултате.

**Табела 7.5.** Поређење INT8 и FLOAT32 начина израчунавања

| Модел  | INT8<br>време [s] | FLOAT32<br>време [s] | Убрзање<br>INT8 | INT8<br>RTF | FLOAT32<br>RTF | Смањење<br>времена [%] |
|--------|-------------------|----------------------|-----------------|-------------|----------------|------------------------|
| Tiny   | 1,355             | 1,656                | 1,22×           | 0,069       | 0,081          | 18,18                  |
| Base   | 2,161             | 3,002                | 1,39×           | 0,110       | 0,148          | 28,02                  |
| Small  | 7,203             | 8,734                | 1,21×           | 0,327       | 0,428          | 17,53                  |
| Medium | 17,633            | 28,991               | 1,64×           | 0,832       | 1,390          | 39,18                  |

Резултати показују да је INT8 био бржи од FLOAT32 код сва четири испитана модела. Степен убрзања, међутим, није исти за све величине.

Код Tiny модела просечно време је смањено са 1,656 на 1,355 s, што представља смањење од 18,18% и убрзање од 1,22 пута. Код Base модела време опада са 3,002 на 2,161 s, односно за око 28,02%.

Small модел са FLOAT32 начином израчунавања има просечно време од 8,734 s, док INT8 варијанта захтева 7,203 s, што представља смањење од 17,53%.

Највећи ефекат квантизације уочен је код Medium модела. Просечно време транскрипције смањено је са 28,991 на 17,633 s, односно за приближно 39,18%. INT8 је у овом случају био око 1,64 пута бржи од FLOAT32 варијанте.

RTF вредности показују исти тренд. Код Medium FLOAT32 модела просечан RTF износи 1,390, док код INT8 пада на 0,832. Ово је практично важна разлика: FLOAT32 Medium је у просеку захтевао више времена него што траје аудио сигнал, док је INT8 варијанта просечно успевала да остане испод границе  $RTF = 1$ .

Ипак, анализа по појединачним снимцима показује да просечан RTF не значи да је сваки снимак обрађен брже од реалног времена. Код Medium INT8 конфигурације 80% снимака имало је RTF мањи од 1, док је код Medium FLOAT32 то важило за само 25% снимака. Tiny, Base и Small су у обе варијанте имали  $RTF < 1$  за свих 40 снимака.

Експеримент је обухватио и мерење меморије процеса. Код меморијских резултата уочено је да мерења нису потпуно стабилна између конфигурација. Пошто су модели покретани у истом Jupyter процесу, претходно алоцирана меморија и начин рада библиотека могу да утичу на RSS вредности. Због тога се меморијски резултати овог експеримента користе као емпиријски показатељи, а не као тачне величине модела у RAM-у.

На пример, при самом учитавању Base модела измерена промена RSS-а износила је приближно 91,04 MB за INT8 и 296,95 MB за FLOAT32. Са друге стране, код Medium модела добијена је необична вредност од 670,97 MB за INT8 и 535,43 MB за FLOAT32, што показује зашто ова мерења не треба тумачити као изоловану меморијску величину модела.

Овај експеримент је првенствено усмерен на латенцију и RTF, па из њега не треба самостално закључивати о утицају квантизације на тачност ако WER није израчунат у самом notebook-у. Сачуване транскрипције из овог експеримента касније су употребљене у интеграционој анализи, где је WER додатно израчунат за свих 320 транскрипција.

На основу директно измерених перформанси може се закључити да је INT8 у коришћеном CPU окружењу донео убрзање код свих испитаних величина модела, а највећи добитак добијен је код Medium модела. Резултат показује да корист од квантизације није константна, већ зависи од величине модела и начина на који конкретан CPU извршава одговарајуће операције.

У комбинацији са резултатима из поглавља 7.1, посебно је значајан Small INT8. Small модел је показао знатно бољу тачност од Base и Tiny варијанти, док INT8 омогућава његово брже извршавање у односу на FLOAT32. Ипак, коначна одлука о оптималној конфигурацији не доноси се у овом поглављу, већ након заједничке анализе WER-а, RTF-а и меморијских захтева у поглављу 8.

## 7.6. Утицај Voice Activity Detection алгоритма


У практичним аудио записима говор није увек непрекидан, већ се између речи и реченица јављају паузе различитог трајања. Обрада таквих делова не доноси корисне информације за транскрипцију, па је у овом експерименту испитано да ли употреба Voice Activity Detection (VAD) алгоритма може да смањи време обраде без погоршања тачности препознавања. [8]

Експеримент је изведен коришћењем Faster-Whisper Base INT8 модела на CPU-у. Формиране су две групе са по пет аудио записа. Прву групу чинило је пет синтетичких енглеских снимака, док је друга садржала пет природних српских снимака из главног скупа. За природни српски део коришћени су снимци 28, 32, 33, 36 и 40, којима су контролисано додате паузе како би се обезбедило присуство делова без говорне активности.


Сваки аудио запис транскрибован је у два режима: са искљученим VAD-ом (VAD OFF) и са укљученим VAD-ом (VAD ON). Време извршавања мерено је три пута по режиму како би се смањио утицај случајних варијација у времену обраде. Поред времена транскрипције посматрани су RTF и WER. Резултати су приказани у Табели 7.6 и сликама 5, 6 и 7.

Табела 7.6. Утицај VAD алгоритма на две групе аудио записа


| Скуп             | VAD<br>OFF<br>време<br>[s] | VAD<br>ON<br>време<br>[s] | Убрзање | Смањење<br>времена<br>[%] | RTF<br>OFF | RTF<br>ON | WER<br>OFF<br>[%] | WER<br>ON<br>[%] | $\Delta$ WER<br>[pp] |
|------------------|----------------------------|---------------------------|---------|---------------------------|------------|-----------|-------------------|------------------|----------------------|
| Синтетички<br>EN | 1,968                      | 1,557                     | 1,263×  | 20,85                     | 0,061      | 0,048     | 7,58              | 6,37             | −1,21                |
| ПриродниSR       | 4,302                      | 4,175                     | 1,031×  | 2,96                      | 0,080      | 0,078     | 66,28             | 65,80            | −0,48                |



Слика 5. Утицај chunk величине на WER



Слика 6. Утицај chunk величине на RTF



Слика 7. Процена времена до првог резултата

Код синтетичких енглеских снимака укључивање VAD-а смањило је просечно време обраде са 1,968 на 1,557 s, што представља смањење од 20,85%, односно убрзање од приближно 1,26 пута. Истовремено је просечан RTF смањен са 0,061 на 0,048.

Код природних српских снимака ефекат на брзину био је знатно мањи. Просечно време смањено је са 4,302 на 4,175 s, односно за 2,96%, док је RTF промењен са 0,080 на 0,078. VAD је, дакле, и у овој групи смањено време обраде, али је добитак био релативно мали.

Посебно је важно проверити да ли је уклањање делова без говора довело до погоршања транскрипције. У овом експерименту то није био случај. Код синтетичког енглеског скупа просечан WER се променио са 7,58% на 6,37%, док је код природног српског скупа промењен са 66,28% на 65,80%.

Мала смањења WER-а од 1,21 и 0,48 процентних поена не треба тумачити као доказ да VAD сам по себи повећава способност Whisper модела да препозна говор. Вероватније је да уклањање одређених периода без говора у конкретним снимцима може да утиче на сегментацију и процес декодирања. За овај рад је важније да укључивање VAD-а није довело до приметног погоршања WER-а, док је истовремено смањено време обраде.

Разлика између две групе такође показује да корист од VAD-а зависи од структуре аудио материјала. Уколико снимак садржи већи број или дуже периоде без говора, постоји више материјала који се може изоставити из обраде. Код готово непрекидног говора очекивани добитак је мањи.

Због тога се на основу овог експеримента не може тврдити да ће VAD увек донети убрзање од око 20%. Та вредност добијена је само за конкретан синтетички енглески скуп. Код природних српских снимака добитак је био око 3%, што показује да ефекат зависи од карактеристика самог снимка.

У оквиру испитаних услова резултати ипак оправдавају коришћење VAD ON као подразумеваног подешавања, јер је код обе групе забележено смањење времена, а промена WER-а није била негативна. Овај избор се касније укључује у поступак формирања препоручене конфигурације система.

## 7.7. Streaming и real-time транскрипција

Последњи експеримент у овом поглављу односи се на могућност примене Faster-Whisper система за транскрипцију у условима приближним раду у реалном времену. За разлику од класичне транскрипције, код које је моделу доступан цео аудио запис, у streaming систему аудио пристиже постепено и мора да се обрађује у мањим сегментима.

Експеримент је реализован као симулација streaming обраде над унапред снимљеним аудио записима, а не као директна транскрипција сигнала са микрофона. На овај начин омогућено је контролисано поређење различитих величина сегмената над потпуно истим аудио материјалом.

Коришћено је пет најдужих природних српских снимака из главног скупа, односно записи 36–40. Њихово трајање кретало се од приближно 62 до 82 секунде. Као модел коришћен је Faster-Whisper Base INT8 на CPU-у, са beam\_size = 1 и искљученим VAD-ом.

Најпре је сваки снимак транскрибован као целина како би се формирао full-file baseline. Након тога исти записи су подељени на независне сегменте од 2, 5 и 10 секунди, који су транскрибовани редоследом којим би пристизали у streaming систему.

Full-file транскрипција остварила је просечан WER од 43,03%, corpus WER од 42,88% и просечан RTF од 0,0699. Ове вредности представљају основу за процену колики губитак настаје услед независне обраде кратких сегмената.

**Табела 7.7.** Резултати streaming симулације

| Начин обраде | Macro WER [%] | Corpus WER [%] | Просечан RTF | Просечна chunk латенција [s] | P95 латенција [s] | TTFR [s] |
|--------------|---------------|----------------|--------------|------------------------------|-------------------|----------|
| Full-file    | 43,03         | 42,88          | 0,0699       | –                            | –                 | –        |
| Chunk 2 s    | 220,48        | 221,88         | 0,417        | 0,820                        | 1,182             | 2,773    |
| Chunk 5 s    | 126,40        | 126,43         | 0,190        | 0,933                        | 1,173             | 5,904    |
| Chunk 10 s   | 52,04         | 51,98          | 0,132        | 1,245                        | 1,445             | 11,299   |

Резултати показују веома изражен утицај величине сегмента на тачност транскрипције. Код сегмената од 2 секунде просечан WER износи чак 220,48%, што је за 177,45 процентних поена више од full-file транскрипције. Corpus WER од 221,88% показује да ова вредност није само последица начина израчунавања просека.

Овако велики WER настаје зато што се сваки кратак сегмент транскрибује независно. Модел има веома мало контекста, а речи и реченице могу бити пресечене на границама сегмената. Поред замена и брисања, јавља се и велики број уметнутих речи, па WER може значајно да пређе 100%.

Повећање сегмента на 5 секунди побољшава резултат, али просечан WER и даље износи високих 126,40%. У односу на full-file baseline то представља погоршање од 83,37 процентних поена.

Најбољи резултат међу испитаним streaming варијантама добијен је за сегменте од 10 секунди. Просечан WER износи 52,04%, а corpus WER 51,98%. У односу на full-file baseline, погоршање маско WER-а износи око 9,01 процентних поена, што је знатно мање него код сегмената од 2 и 5 секунди.

Дужи сегмент моделу обезбеђује више контекста и смањује број граница на којима се реч или реченица може прекинути. Резултати зато показују јасну корист од повећања величине сегмента са становишта тачности.

Са друге стране, краћи сегменти имају предност када се посматра време до првог резултата. За сегмент од 2 секунде просечан TTFR износи 2,773 s, за 5 секунди 5,904 s, а за 10 секунди 11,299 s. Корисник, дакле, код мањег сегмента раније добија први текстуални резултат.

Просечна латенција саме обраде једног сегмента износи 0,820 s за 2 секунде, 0,933 s за 5 секунди и 1,245 s за 10 секунди. Иако дужи сегмент захтева нешто више времена за инференцију, његов RTF је мањи, јер се већа количина аудио сигнала обрађује у једном пролазу.

Код сегмената од 5 и 10 секунди 100% обрађених сегмената имало је RTF мањи од 1, док је код сегмената од 2 секунде тај проценат износио 95,61%. Ово показује да је Faster-Whisper Base INT8 у већини случајева имао довољну брзину да обради сегмент пре него што би стигла наредна количина аудио сигнала истог трајања.

Ипак, код сегмената од 2 секунде појавило се и нагомилавање обраде. Просечна максимална вредност реда чекања износила је 0,192 s, док код сегмената од 5 и 10 секунди ред чекања није забележен. То додатно показује да веома кратки сегменти могу да повећају оптерећење система, иако појединачна транскрипција кратко траје.

У овом експерименту зато постоји јасан компромис. Сегмент од 2 секунде даје најбржи први резултат, али уз веома велики губитак тачности. Сегмент од 5 секунди

представља побољшање, али је WER и даље висок. Сегмент од 10 секунди има највећи TTFR, али убедљиво најбољу тачност и стабилан рад без реда чекања.

За додатно поређење три варијанте у notebook-у је примењен и комбиновани критеријум који узима у обзир WER, RTF, TTFR и ред чекања. Добијени резултат био је 0,8000 за 10 s, 0,6651 за 5 s и 0,2000 за 2 s, па је међу три испитане вредности сегмент од 10 секунди издвојен као најповољнији компромис.

Овај резултат не значи да је 10 секунди универзално оптимална величина сегмента за сваки streaming ASR систем. Испитане су само три вредности, на пет дужих снимака и уз независну транскрипцију сваког сегмента. Напреднији систем би могао да користи преклапање сегмената, пренос контекста из претходног сегмента, динамичку сегментацију или VAD, чиме би се посебно код краћих сегмената могла побољшати тачност.

Зато је исправан закључак да је 10 секунди најбољи избор међу испитаним величинама сегмената у реализованој streaming симулацији, а не да представља општи оптимум за Faster-Whisper.

## 8. АУТОМАТСКИ ИЗБОР ОПТИМАЛНЕ КОНФИГУРАЦИЈЕ

Претходни експерименти показали су да на рад Faster-Whisper система истовремено утиче више параметара. Већи модел може да смањи WER, али захтева више времена и ресурса, док мањи модел омогућава бржу обраду уз већи број грешака. Сличан компромис постоји и код квантизације, Beam Search параметра, VAD алгоритма и величине сегмента при streaming обради.

Због тога избор конфигурације само на основу једне метрике не би дао потпуну слику. У овом поглављу резултати претходних експеримената обједињени су у поступак аутоматског вишекритеријумског избора, чији је циљ да се пронађе конфигурација са повољним односом тачности, брзине и меморијских захтева.

### 8.1. Вишекритеријумска оптимизација

Главни део аутоматског избора заснован је на резултатима експеримента са величином модела и квантизацијом, јер је у њему свих 40 природних српских снимака обрађено помоћу истих осам конфигурација. Комбинована су четири модела — Tiny, Base, Small и Medium — са INT8 и FLOAT32 начином израчунавања.

На тај начин је обезбеђено да се модел и квантизација пореде на истом тест скупу. Укупно је на располагању било 320 транскрипција, односно 40 снимака за сваку од осам конфигурација.

У основном експерименту квантизације већ су били сачувани време обраде, RTF, меморијска мерења и транскрипти. Због тога модели нису поново покретани. Уместо тога, у овом интеграционом експерименту WER је накнадно израчунат из сачуваних транскрипата и одговарајућих референтних текстова за свих 320 резултата.

За главни избор коришћена су три критеријума:

WER — представља тачност транскрипције,

RTF — представља брзину обраде у односу на трајање аудио сигнала,

RAM — представља измерену меморијску захтевност конфигурације.

Код сва три критеријума мања вредност представља повољнији резултат. Пошто се WER изражава у процентима, RTF као однос времена, а RAM у мегабајтима, њихове вредности није могуће директно сабирати. Због тога је примењена min-max нормализација, којом је сваки критеријум претворен у скор између 0 и 1:

$$Score(x) = \frac{x_{max} - x}{x_{max} - x_{min}}$$

Оваквом трансформацијом најповољнија вредност критеријума добија скор 1, а најнеповољнија скор 0.

Након нормализације формиран је укупан пондерисани скор:

$$S=0,50S_{WER}+0,30S_{RTF}+0,20S_{RAM}$$

Највећа тежина од 50% додељена је WER-у, јер је основна функција ASR система да што тачније препозна говор. RTF учествује са 30%, док меморијска захтевност има тежину од 20%. На овај начин тачност има највећи значај, али систем не бира конфигурацију која је веома тачна ако је истовремено непрактично спора или ресурсно захтевна.


Ове тежине не представљају универзалну дефиницију оптималности. Оне представљају један практичан, уравнотежен сценарио за потребе овог рада. Због тога је касније спроведена и анализа осетљивости са другачијим расподелама тежина.

## 8.2. Рангирање и Pareto анализа конфигурација

Након израчунавања WER-а и нормализације критеријума, формирана је ранг-листа свих осам конфигурација. Резултати су приказани у Табели 8.1 и на слици 8.

**Табела 8.1.** Аутоматско рангирање Faster-Whisper конфигурација

| Ранг | Конфигурација  | Просечан WER [%] | Corpus WER [%] | Просечан RTF | RAM [MB] | Укупан скор |
|------|----------------|------------------|----------------|--------------|----------|-------------|
| 1    | Small INT8     | 22,43            | 22,22          | 0,327        | 263,80   | 0,8289      |
| 2    | Medium INT8    | 16,03            | 17,83          | 0,832        | 670,97   | 0,6841      |
| 3    | Base INT8      | 48,61            | 48,45          | 0,110        | 91,04    | 0,6727      |
| 4    | Small FLOAT32  | 22,06            | 21,90          | 0,428        | 942,61   | 0,6597      |
| 5    | Base FLOAT32   | 49,47            | 48,93          | 0,148        | 296,95   | 0,6107      |
| 6    | Medium FLOAT32 | 15,75            | 17,40          | 1,390        | 535,43   | 0,5898      |
| 7    | Tiny INT8      | 69,49            | 68,84          | 0,069        | 36,12    | 0,5000      |
| 8    | Tiny FLOAT32   | 68,39            | 67,93          | 0,081        | 156,43   | 0,4809      |



Слика 8. Тачност-брзина компромис

Највећи укупан скор од 0,8289 остварила је конфигурација Small INT8. Њен просечан WER износи 22,43%, corpus WER 22,22%, а просечан RTF 0,327. Измерена меморијска вредност износила је 263,80 MB.

Medium модели имају најбољу тачност. Medium FLOAT32 има најнижи просечан WER од 15,75%, док Medium INT8 има 16,03%. Међутим, њихове RTF вредности су знатно веће. Посебно Medium FLOAT32 има просечан RTF од 1,390, због чега у основном вишекритеријумском скору завршава тек на шестом месту.

Супротан пример представља Tiny INT8. Са RTF вредношћу од само 0,069 и измереном RAM вредношћу од 36,12 MB он је најповољнији са становишта брзине и меморије, али просечан WER од 69,49% значајно смањује његов укупан скор.

Small INT8 налази се између ова два екстрема. Његова тачност је знатно боља од Base и Tiny модела, док је истовремено значајно бржи од Medium варијанти. Управо због таквог односа резултата остварује највећи укупан скор.

Поред тежинског рангирања примењена је и Pareto анализа. Конфигурација се сматра Pareto оптималном ако не постоји друга конфигурација која је истовремено једнако добра или боља по свим критеријумима, а строго боља бар по једном од њих.

Од осам испитаних конфигурација, једино је Base FLOAT32 означен као Pareto доминиран. Остале конфигурације припадају Pareto скупу јер свака од њих има одређену предност која се плаћа погоршањем неког другог критеријума.

На пример, Medium FLOAT32 има најбољу тачност, али висок RTF. Tiny INT8 има најмањи RTF и меморијску захтевност, али највећи WER. Small INT8 нема апсолутно најбољу вредност сваке појединачне метрике, али остварује добар резултат у сва три критеријума.

Ова анализа показује зашто код оптимизације ASR система не постоји нужно једна конфигурација која је најбоља у сваком погледу. Избор зависи од тога да ли конкретна примена више захтева тачност, брзину или малу потрошњу ресурса.

При томе треба задржати ограничење наведено у претходном поглављу. RAM вредности представљају процесна RSS мерења у Jupyter окружењу и код појединих конфигурација показују неправилности. Због тога Pareto и тежинску анализу меморије треба посматрати као практичну анализу измерених вредности, а не као прецизно поређење физичке величине модела.

### 8.3. Анализа осетљивости

Пошто резултат вишекритеријумске оптимизације зависи од изабраних тежина, додатно је проверено шта се дешава када се промене приоритети система.

Формирана су три сценарија. Balanced представља основни сценарио са тежинама WER 50%, RTF 30% и RAM 20%. Accuracy сценарио даје већи значај тачности, са тежинама 70%, 20% и 10%. Resource сценарио више вреднује брзину и меморијску ефикасност, са тежинама 35% за WER, 35% за RTF и 30% за RAM.

**Табела 8.2.** Анализа осетљивости на избор тежина

| Конфигурација  | Balanced ранг | Accuracy ранг | Resource ранг |
|----------------|---------------|---------------|---------------|
| Small INT8     | 1             | 1             | 1             |
| Medium INT8    | 2             | 2             | 6             |
| Base INT8      | 3             | 5             | 2             |
| Small FLOAT32  | 4             | 3             | 7             |
| Base FLOAT32   | 5             | 6             | 3             |
| Medium FLOAT32 | 6             | 4             | 8             |
| Tiny INT8      | 7             | 7             | 4             |
| Tiny FLOAT32   | 8             | 8             | 5             |

Најважнији резултат анализе осетљивости је да Small INT8 остаје на првом месту у сва три сценарија. Његов скор износи 0,8289 у balanced, 0,8488 у accuracy и 0,8127 у resource сценарију.

Ово показује да избор Small INT8 конфигурације није последица само једне специфичне расподеле тежина. Чак и када се приоритет значајно помери ка тачности или ка ресурсима, она задржава најбољи укупан положај међу испитаним конфигурацијама.

Код осталих модела промене су знатно веће. Medium INT8 је други у balanced и accuracy сценарију, али пада на шесто место када се већи значај додели ресурсима. Разлог је његов релативно висок RTF и измерена меморијска захтевност.

Base INT8 показује супротан тренд. У accuracy сценарију заузима пето место због већег WER-а, али се у resource сценарију пење на друго место захваљујући малом RTF-у и релативно малој измереној меморијској вредности.

Анализа осетљивости зато не служи само за потврду првопласиране конфигурације, већ показује и како би се избор променио за другачију врсту примене. У систему у коме је тачност готово једини приоритет Medium варијанте постају конкурентније, док у окружењу са ограниченим ресурсима Base и Tiny модели добијају већи значај.

У условима дефинисаним овим радом, Small INT8 се ипак показао као најстабилнији компромис, јер је остао први без обзира на три испитане расподеле тежина.

## 8.4. Избор препоручене конфигурације

Главна вишекритеријумска анализа одређује оптималну комбинацију модела и квантизације. На основу 40 природних српских снимака и критеријума WER, RTF и RAM, аутоматски је изабран:

Faster-Whisper Small + INT8

За ову конфигурацију измерен је просечан WER од 22,43%, corpus WER од 22,22%, просечан RTF од 0,3272 и укупан скор од 0,8289. Конфигурација је истовремено означена као Pareto оптимална и задржала је прво место у сва три сценарија анализе осетљивости.

Међутим, модел и квантизација представљају само један део коначне конфигурације. Због тога су резултати засебних експеримената из поглавља 7 употребљени за избор Beam Search параметра, VAD подешавања и величине streaming сегмента.

За Beam Search коришћени су резултати експеримента из поглавља 7.4. У интеграционој анализи формиран је посебан скор који даје 70% значаја WER-у и 30% RTF-у. Највећи скор од 0,8852 добијен је за beam\_size = 5, испред вредности 3, 10 и 1. Због тога је вредност 5 изабрана као препоручено подешавање.

Овде је важно ограничење да је Beam Search експеримент изведен над Base INT8 моделом, а не над Small INT8 моделом који је касније изабран у главној оптимизацији. Због тога комбинација Small INT8 + beam\_size = 5 представља састављени препоручени профил на основу два одвојена контролисана експеримента, а не конфигурацију која је као целина поново тестирана над свих 40 снимака.

За VAD је коришћен резултат природног српског подскупа. Укључивање VAD-а дало је убрзање од 1,031×, односно смањење времена од 2,96%, док се WER није погоршао. На основу критеријума да VAD треба укључити када доноси убрзање без погоршања WER-а већег од 2 процентна поена, изабрано је VAD ON.

Код streaming обраде засебно су упоређени сегменти од 2, 5 и 10 секунди. У интеграционом notebook-у за овај избор коришћен је поједностављени скор заснован на WER-у, латенцији и RTF-у. Највећу вредност од 0,7000 добио је сегмент од 10 секунди, у односу на 0,6588 за 5 секунди и 0,3000 за 2 секунде. Ово је у складу и са детаљнијом анализом из поглавља 7.7, у којој је 10 секунди такође издвојено као најповољнија од три испитане вредности.

Коначни профил добијен интеграцијом резултата приказан је у Табели 8.3.

**Табела 8.3.** Аутоматски препоручена Faster-Whisper конфигурација

| Параметар       | Препоручена вредност |
|-----------------|----------------------|
| Модел           | Small                |
| Квантизација    | INT8                 |
| Уређај          | CPU                  |
| Језик           | sr                   |
| Beam size       | 5                    |
| VAD             | ON                   |
| Streaming chunk | 10 s                 |

Овако формиран профил не представља универзално најбољу Faster-Whisper конфигурацију. Он представља препоручену конфигурацију за услове испитане у овом раду: CPU извршавање, српски језик, формирани скуп природног говора и дефинисане критеријуме тачности, брзине и меморијске захтевности.

Такође, параметри коначног профила нису сви истовремено тестирани у једном заједничком експерименту. Small INT8 је изабран над свих 40 природних српских снимака, док су Beam Search, VAD и streaming сегментација испитивани у засебним контролисаним експериментима и на мањим подскуповима. Због тога коначни профил треба посматрати као интеграцију најповољнијих експериментално испитаних подешавања, а не као доказани глобални оптимум.

Главна вредност овог поступка је у томе што избор није заснован само на најнижој WER вредности или најбржем моделу. Комбиновањем више критеријума, Pareto анализе и анализе осетљивости добијен је систематичан начин избора конфигурације који узима у обзир различите захтеве практичне примене.

## **9. ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА ЗА СРПСКИ ЈЕЗИК**

- 9.1. Формирање пољопривредног говорног скупа**
- 9.2. Припрема података и fine-tuning модела**
- 9.3. Евалуација основног и адаптираног модела**
- 9.4. Анализа доменске терминологије и генерализације**

## **10. ДИСКУСИЈА И ОГРАНИЧЕЊА ИСТРАЖИВАЊА**

- 10.1. Дискусија добијених резултата**
- 10.2. Ограничења истраживања**

## **11. ЗАКЉУЧАК И ПРАВЦИ БУДУЋЕГ РАДА**

## 12. ЛИТЕРАТУРА

- [1] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, “Robust Speech Recognition via Large-Scale Weak Supervision,” *Proceedings of the 40th International Conference on Machine Learning*, vol. 202, pp. 28492–28518, 2023. Доступно: <https://proceedings.mlr.press/v202/radford23a.html>
- [2] A. Vaswani et al., “Attention Is All You Need,” *Advances in Neural Information Processing Systems*, vol. 30, 2017. Доступно: <https://arxiv.org/abs/1706.03762>
- [3] S. Hochreiter and J. Schmidhuber, “Long Short-Term Memory,” *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997. DOI: <https://doi.org/10.1162/neco.1997.9.8.1735>
- [4] A. Graves, S. Fernández, F. Gomez, and J. Schmidhuber, “Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks,” *Proceedings of the 23rd International Conference on Machine Learning*, pp. 369–376, 2006. DOI: <https://doi.org/10.1145/1143844.1143891>
- [5] OpenAI, “Whisper,” званични репозиторијум и документација. Доступно: <https://github.com/openai/whisper> (приступљено: 10. 06. 2026).
- [6] SYSTRAN, “Faster-Whisper: Faster Whisper Transcription with CTranslate2,” званични репозиторијум. Доступно: <https://github.com/SYSTRAN/faster-whisper> (приступљено: 10. 6. 2026).
- [7] OpenNMT, “CTranslate2,” званична документација. Доступно: <https://opennmt.net/CTranslate2/> (приступљено: 18. 9. 2026).
- [8] Silero, “Silero VAD,” званични репозиторијум. Доступно: <https://github.com/snakers4/silero-vad> (приступљено: 30. 8. 2026).