УНИВЕРЗИТЕТ У НИШУ
ЕЛЕКТРОНСКИ ФАКУЛТЕТ

Анализа, оптимизација и доменска адаптација Whisper модела за аутоматско препознавање говора на српском језику

Мастер рад

Студијски програм: Вештачка интелигенција и машинско учење

Студент:

Александар Јовановић, бр. инд. 2120

Ментор:

Проф. др Јелена Николић

Ниш, октобар 2026. године

Универзитет у Нишу

Електронски факултет

АНАЛИЗА, ОПТИМИЗАЦИЈА И ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА ЗА АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА НА СРПСКОМ ЈЕЗИКУ

ANALYSIS, OPTIMIZATION, AND DOMAIN ADAPTATION OF THE WHISPER MODEL FOR AUTOMATIC SPEECH RECOGNITION IN SERBIAN

Мастер рад
Студијски програм: Вештачка интелигенција и машинско учење
Студент: Александар Јовановић, бр. инд. 2120
Ментор: Проф. др Јелена Николић

Задатак: *Задатак овог мастер рада је анализа и оптимизација Whisper модела и Faster-Whisper имплементације за аутоматско препознавање говора на српском језику. Испитује се утицај величине модела, квантизације, параметара транскрипције и услова снимања на тачност, брзину и потрошњу ресурса, на основу чега се бира најпогоднија конфигурација. Посебан део рада обухвата доменску адаптацију модела Whisper на српски говор из области пољопривреде, као и евалуацију адаптираног модела на снимцима говорника који није био заступљен у подацима за обуку.*

Датум пријаве рада: 09.10.2026.

Датум предаје рада:

Датум одбране рада:

Комисија за оцену и одбрану:

1. Проф. др Јелена Николић, Председник Комисије

2.

3.

АНАЛИЗА, ОПТИМИЗАЦИЈА И ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА ЗА АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА НА СРПСКОМ ЈЕЗИКУ

САЖЕТАК

У овом мастер раду анализиран је Whisper модел за аутоматско препознавање говора, са посебним фокусом на српски језик и оптимизацију извршавања на централном процесору (CPU). Поред основне Whisper имплементације, испитан је Faster-Whisper заснован на библиотеци CTranslate2, са циљем анализе односа између тачности транскрипције, брзине обраде и потрошње рачунарских ресурса. За главни експериментални део формиран је скуп од 40 аудио записа читаног говора на српском језику, који обухвата три говорника и снимке различитог трајања.

На почетку експерименталне анализе извршено је директно поређење Whisper и Faster-Whisper система на основу стопе грешке на нивоу речи (WER), времена транскрипције, фактора реалног времена (RTF) и потрошње меморије. Након тога испитан је утицај величине модела на наведене метрике, као и утицај квантизације INT8 у односу на прецизност FP32, параметра *beam size*, детекције говорне активности (VAD) и позадинског шума при различитим вредностима односа сигнал-шум (SNR). Извршено је и контролисано поређење препознавања српског и енглеског говора и симулација транскрипције у реалном времену (енгл. *streaming*) са различитим величинама аудио сегмената.

На основу добијених резултата развијен је поступак за избор конфигурације применом вишекритеријумске оптимизације и Парето анализе. Као конфигурација са најповољнијим односом тачности, брзине и измерене меморијске захтевности издвојена је Faster-Whisper Small INT8, са просечним WER-ом од 22,43% и просечним RTF-ом од 0,351. Препоручени интегрисани профил обухвата корак обраде од 5 секунди, акустичко преклапање од једне секунде и пренос текстуалног контекста. Завршна евалуација спроведена је на 30 српских снимака из скупа FLEURS и на 40 снимака читаног српског говора. На главном скупу обрада целих снимака остварила је WER на нивоу корпуса од 23,23%, док је у сегментном режиму добијено 34,37%, уз просечан RTF од 1,358. Посебан део рада посвећен је доменској адаптацији Whisper Small модела на скупу од 800 аудио записа из области пољопривреде, подељених на 675 за обучавање, 75 за валидацију и 50 за тестирање. На тест скупу са новим говорником доменска адаптација смањила је корпусни WER са 31,01% на 17,32%, односно за 13,69 процентних поена, чиме је потврђено значајно побољшање препознавања говора.

Анализа показује да избор одговарајуће величине модела, квантизације и параметара транскрипције омогућава прилагођавање Faster-Whisper система различитим захтевима практичне примене. Главни допринос рада чине систематска анализа и оптимизација Whisper система за српски говор, избор конфигурације и доменска адаптација модела за специфичну област.

Кључне речи: аутоматско препознавање говора, Whisper, Faster-Whisper, српски језик, квантизација, оптимизација, доменска адаптација.

ANALYSIS, OPTIMIZATION, AND DOMAIN ADAPTATION OF THE WHISPER MODEL FOR AUTOMATIC SPEECH RECOGNITION IN SERBIAN

ABSTRACT

This Master's thesis investigates the Whisper model for automatic speech recognition (ASR), with a particular focus on the Serbian language and CPU-based inference optimization. In addition to the original Whisper implementation, Faster-Whisper, based on the CTranslate2 library, was evaluated to analyze the trade-offs between transcription accuracy, processing speed, and computational resource consumption. For the main experimental evaluation, a dataset comprising 40 Serbian read-speech audio recordings was created, including three speakers and recordings of varying durations.

At the beginning of the experimental analysis, a direct comparison between the Whisper and Faster-Whisper systems was conducted based on word error rate (WER), transcription time, real-time factor (RTF), and memory consumption. Subsequently, the impact of model size on these metrics was investigated, along with the effects of INT8 quantization compared with FP32 precision, the *beam size* parameter, voice activity detection (VAD), and background noise at different signal-to-noise ratio (SNR) levels. A controlled comparison of Serbian and English speech recognition was also conducted, together with a simulation of real-time transcription (streaming) using different audio segment sizes.

Based on the obtained results, a configuration selection procedure was developed using multi-criteria optimization and Pareto analysis. Faster-Whisper Small INT8 was identified as the configuration providing the most favorable trade-off between transcription accuracy, processing speed, and measured memory requirements, achieving an average WER of 22.43% and an average RTF of 0.351. The recommended integrated profile uses a 5-second processing step, 1-second acoustic overlap, and textual context transfer. Final evaluation was conducted on 30 Serbian recordings from the FLEURS dataset and 40 recordings of Serbian read speech. On the main dataset, full-recording transcription achieved a corpus-level WER of 23.23%, compared with 34.37% in streaming mode, with an average streaming RTF of 1.358. A separate part of the thesis focuses on domain adaptation of the Whisper Small model using a dataset of 800 agricultural speech recordings, divided into 675 for training, 75 for validation, and 50 for testing. On the test set featuring an unseen speaker, domain adaptation reduced the corpus-level WER from 31.01% to 17.32%, representing an absolute improvement of 13.69 percentage points, demonstrating a substantial improvement in speech recognition.

The analysis demonstrates that an appropriate selection of model size, quantization method, and transcription parameters enables the Faster-Whisper system to be adapted to different practical application requirements. The main contributions of this thesis include a systematic analysis and optimization of the Whisper system for Serbian speech, a configuration selection procedure, and domain adaptation of the model to a specific application domain.

Keywords: automatic speech recognition, Whisper, Faster-Whisper, Serbian language, quantization, optimization, domain adaptation.

СПИСАК КОРИШЋЕНИХ СКРАЋЕНИЦА И ОЗНАКА

СКРАЋЕНИЦЕ

AI − вештачка интелигенција (**A**rtificial **I**ntelligence)
ASR − аутоматско препознавање говора (**A**utomatic **S**peech **R**ecognition)
CER − стопа грешке на нивоу карактера (**C**haracter **E**rror **R**ate)
CPU − централна процесорска јединица (**C**entral **P**rocessing **U**nit)
CTC − конекционистичка временска класификација (**C**onnectionist **T**emporal **C**lassification)
DNN − дубока неуронска мрежа (**D**eep **N**eural **N**etwork)
FLEURS − скуп података за евалуацију говорних модела (**F**ew-shot **L**earning **E**valuation of **U**niversal **R**epresentations of **S**peech)
FP32 − 32-битни формат бројева са покретним зарезом (**32**-bit **F**loating **P**oint)
GMM − Гаусов модел мешавине (**G**aussian **M**ixture **M**odel)
GPU − графичка процесорска јединица (**G**raphics **P**rocessing **U**nit)
gTTS − Google синтеза говора из текста (**G**oogle **T**ext-**t**o-**S**peech)
HMM − скривени Марковљев модел (**H**idden **M**arkov **M**odel)
INT8 − 8-битни целобројни формат (**8**-bit **Int**eger)
LSTM − мрежа са дугом краткорочном меморијом (**L**ong **S**hort-**T**erm **M**emory)
MFCC − мел-фреквенцијски кепстрални коефицијенти (**M**el-**F**requency **C**epstral **C**oefficients)
ML − машинско учење (**M**achine **L**earning)
P95 − 95. перцентил (**95**th **P**ercentile)
RAM − радна меморија (**R**andom **A**ccess **M**emory)
RNN − рекурентна неуронска мрежа (**R**ecurrent **N**eural **N**etwork)
RSS − величина дела меморије процеса у физичкој меморији (**R**esident **S**et **S**ize)
RTF − фактор реалног времена (**R**eal-**T**ime **F**actor)
SD − стандардна девијација (**S**tandard **D**eviation)
SNR − однос сигнал-шум (**S**ignal-to-**N**oise **R**atio)
STFT − краткотрајна Фуријеова трансформација (**S**hort-**T**ime **F**ourier **T**ransform)
TTFR − време до добијања првог резултата (**T**ime **t**o **F**irst **R**esult)
TTS − синтеза говора из текста (**T**ext-**t**o-**S**peech)
VAD − детекција говорне активности (**V**oice **A**ctivity **D**etection)
WAV − формат аудио датотеке (Waveform Audio File Format)
WER − стопа грешке на нивоу речи (**W**ord **E**rror **R**ate)

ОЗНАКЕ

D − број изостављених речи (енгл. *Deletions*)
d_k − димензија вектора кључева у механизму пажње
I − број уметнутих речи (енгл. *Insertions*)
K − матрица вектора кључева (енгл. *Key*) у механизму пажње
N − укупан број речи у референтном тексту
pp – процентни поени (енгл. *percentage points*)
Q − матрица вектора упита (енгл. *Query*) у механизму пажње
S − број замена речи (енгл. *Substitutions*)
S_{uk} − укупан скор у поступку вишекритеријумске оптимизације
S_{chunk} − нормализовани скор величине сегмента
S_{lat} − нормализовани скор максималног кашњења реда чекања
Score(x) − нормализована вредност, односно скор посматране метрике x
S_{RAM} − нормализовани скор меморијске захтевности
S_{RTF} − нормализовани скор RTF метрике
S_{TTFR} − нормализовани скор времена до добијања првог резултата
S_{WER} − нормализовани скор WER метрике у вишекритеријумској оптимизацији
t_{audio} − трајање аудио записа
t_{obrada} − време потребно за обраду аудио записа
V − матрица вектора вредности (енгл. *Value*) у механизму пажње

САДРЖАЈ

1. УВОД 9
1.1. Предмет, мотивација и циљ рада 9
1.2. Истраживачка питања и доприноси рада 10
1.3. Организација рада 12
2. АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА 14
2.1. Основни принципи и развој ASR система 14
2.2. Обрада и представљање говорног сигнала 15
2.3. Модели дубоког учења за препознавање говора 16
2.4. Метрике за евалуацију ASR система 18
Стопа грешке на нивоу речи (WER) 18
Стопа грешке на нивоу карактера (CER) 19
Време транскрипције 20
Фактор реалног времена (RTF) 20
Меморијска потрошња 20
Латенција 21
2.5. Преглед сродних истраживања 21
3. WHISPER АРХИТЕКТУРА 24
3.1. Трансформер архитектура са енкодер-декодер структуром 24
3.2. Архитектура и начин рада Whisper модела 25
3.3. Тренинг, вишејезичност и варијанте Whisper модела 26
4. FASTER-WHISPER И CTRANSLATE2 27
4.1. Faster-Whisper и CTranslate2 библиотека 27
4.2. Квантизација и оптимизација извршавања 28
4.3. Beam Search и детекција говорне активности (VAD) 29
4.4. Обрада говора у реалном времену 31
5. ЕКСПЕРИМЕНТАЛНА МЕТОДОЛОГИЈА 33
5.1. Хардверско и софтверско окружење 33
5.2. Формирање и структура аудио скупова података 34
Главни скуп читаног српског говора 34
Додатни скупови за појединачне експерименте 34
Скуп за доменску адаптацију 36
5.3. Припрема и претпроцесирање аудио записа 36

5.4. Методологија евалуације и мерења перформанси 38
6. ПОРЕЂЕЊЕ WHISPER И FASTER-WHISPER СИСТЕМА 41
6.1. Поставка експеримента 41
6.2. Анализа тачности и брзине транскрипције 42
6.3. Анализа потрошње меморије 43
6.4. Анализа резултата према трајању и говорницима 44
Анализа према трајању аудио записа 44
Анализа према говорницима 45
7. ЕКСПЕРИМЕНТАЛНА АНАЛИЗА И ОПТИМИЗАЦИЈА FASTER-WHISPER СИСТЕМА 47
7.1. Утицај величине модела на резултате 47
7.2. Утицај позадинског шума и SNR вредности 49
7.3. Поређење српског и енглеског говора на FLEURS скупу 52
7.4. Утицај параметра *beam size* 53
7.5. Утицај квантизације на перформансе 55
7.6. Утицај детекције говорне активности (VAD) 56
7.7. Транскрипција у реалном времену 58
8. ИЗБОР КОНФИГУРАЦИЈЕ ПРИМЕНОМ ВИШЕКРИТЕРИЈУМСКЕ ОПТИМИЗАЦИЈЕ 62
8.1. Вишекритеријумска оптимизација 62
8.2. Рангирање и Парето анализа конфигурација 63
8.3. Анализа осетљивости 65
8.4. Избор препоручене конфигурације 66
Faster-Whisper Small + INT8 66
8.5. Завршна валидација интегрисаног профила 68
9. ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА ЗА СРПСКИ ЈЕЗИК 70
9.1. Формирање пољопривредног говорног скупа 70
9.2. Припрема података и модела за додатно обучавање 70
9.3. Евалуација основног и адаптираног модела 72
9.4. Анализа доменске терминологије и генерализације 73
10. ДИСКУСИЈА И ОГРАНИЧЕЊА ИСТРАЖИВАЊА 75
10.1. Дискусија добијених резултата 75
10.2. Ограничења истраживања 76
11. ЗАКЉУЧАК И ПРАВЦИ БУДУЋЕГ РАДА 77
12. ЛИТЕРАТУРА 78

1. УВОД

1.1. Предмет, мотивација и циљ рада

Последњих година системи за аутоматско препознавање говора (ASR) имају све већу примену у различитим областима. Развој дубоког учења и доступност великих количина говорних података омогућили су развој модела који могу са великом тачношћу да претварају говор у текст. Овакви системи се данас користе за аутоматску транскрипцију, титловање аудио и видео садржаја, гласовне асистенте, контакт центре, образовне платформе и друге примене у којима је потребна аутоматска обрада говора.

Један од познатијих модела за аутоматско препознавање говора је Whisper, који је развила компанија OpenAI. Whisper је заснован на трансформер архитектури и обучен је на великој количини разноврсних аудио података. Подржава велики број језика, међу којима је и српски, и може да се користи за транскрипцију говора у различитим условима снимања. Иако Whisper постиже добре резултате, један од проблема приликом његове практичне примене представљају време потребно за обраду аудио записа и потрошња меморије. Ово је посебно важно када се модел покреће на рачунару без снажне графичке картице или када је потребно обрадити већу количину аудио материјала у кратком временском периоду. Као једно од решења за овај проблем развијен је Faster-Whisper, имплементација Whisper модела која користи CTranslate2 библиотеку за оптимизовано извршавање трансформер модела. Faster-Whisper не представља нову архитектуру модела за препознавање говора, већ оптимизовану имплементацију постојећих Whisper модела, засновану на библиотеци CTranslate2. Ова библиотека подржава различите оптимизације, међу којима су квантизација, ефикасније коришћење меморије и оптимизоване операције приликом инференције. На овај начин могуће је смањити време обраде и меморијске захтеве, што је посебно битно за извршавање модела на процесору [1], [2].

Перформансе система за аутоматско препознавање говора не зависе само од тога да ли се користи Whisper или Faster-Whisper. На резултате могу да утичу величина модела, начин квантизације, параметри декодирања, присуство позадинског шума, језик, карактеристике говорника, примена детекције говорне активности и начин на који се аудио сигнал дели на сегменте. Поред тачности транскрипције, у практичним системима важни су и време извршавања, латенција, фактор реалног времена и потрошња меморије. Посебан део овог рада односи се на примену Whisper модела на српски језик. Иако Whisper подржава српски језик, постоји простор за детаљније испитивање његовог понашања на српском говору.

Предмет овог рада је анализа, оптимизација и доменска адаптација Whisper модела за аутоматско препознавање говора на српском језику. За основну експерименталну анализу формиран је скуп од 40 аудио записа читаног говора на српском језику, различитог садржаја и трајања, које су снимила три говорника. Овај скуп се користи за систематско испитивање различитих конфигурација Whisper и Faster-Whisper система.

У оквиру експерименталног дела извршено је основно поређење Whisper и Faster-Whisper система, а затим је анализиран утицај величине модела, квантизације,

позадинског шума и различитих SNR вредности, језика, параметра *beam size* и примене детекције говорне активности (VAD) на посматране метрике. Посебан експеримент односи се на симулацију сегментне обраде говора у условима приближним реалном времену, при чему су испитани различити кораци пристизања аудио података, примена акустичког преклапања и пренос текстуалног контекста из претходних транскрипција. Резултати се посматрају кроз више метрика, као што су стопа грешке на нивоу речи (WER), време обраде, фактор реалног времена (RTF), латенција и меморијска захтевност. На основу резултата ових експеримената извршен је и избор конфигурације Faster-Whisper система. При избору се не посматра само једна метрика, већ се истовремено узимају у обзир тачност транскрипције, брзина рада и меморијски захтеви. На овај начин могуће је упоредити различите конфигурације и одредити ону која представља добар компромис за коришћено хардверско окружење и испитивани скуп података.

Други важан део рада представља доменска адаптација Whisper модела за српски језик у домену пољопривреде. За овај део рада формиран је посебан скуп од укупно 800 аудио записа на српском језику, чији садржај обухвата пољопривредне теме и терминологију. Скуп за обучавање садржи 675 аудио записа три различита говорника, док је за валидацију издвојено 75 аудио записа. За завршно тестирање формиран је посебан скуп од 50 аудио записа четвртог говорника, чији говор није присутан у скупу за обучавање. Оваква подела омогућава да се, поред прилагођавања пољопривредном домену, испита и способност модела да препознаје доменски специфичан говор новог говорника, чији снимци нису коришћени током обучавања. На формираном пољопривредном говорном скупу извршена је доменска адаптација, односно додатно обучавање (енгл. *fine-tuning*) Whisper модела. Основни и адаптирани модел евалуирају се под истим условима како би њихови резултати могли директно да се упореде. Поред укупне тачности транскрипције, посматра се и препознавање речи и израза карактеристичних за пољопривредни домен. Општи скуп српског говора користи се и за проверу понашања адаптираног модела ван домена на коме је додатно обучаван.

Основни циљ рада је да се кроз више контролисаних експеримената испита како различити фактори утичу на тачност, брзину и захтеве за рачунарским ресурсима Whisper и Faster-Whisper система, као и да се одреди конфигурација која даје добар однос између ових карактеристика приликом препознавања српског говора. Такође, циљ је да се испита доменска адаптација Whisper модела на сопственом скупу српског говора из области пољопривреде и да се упореде основни и доменски прилагођени модел.

1.2. Истраживачка питања и доприноси рада

На основу предмета и циљева рада дефинисана су истраживачка питања која се односе на тачност, брзину и практичну примену Whisper и Faster-Whisper система за препознавање говора на српском језику. Посебна пажња посвећена је факторима који могу да утичу на квалитет транскрипције и ефикасност извршавања, као и могућности прилагођавања модела специфичном домену.

Основно истраживачко питање рада је:

У којој мери је могуће оптимизовати Whisper систем за аутоматско препознавање говора на српском језику са становишта тачности, брзине и потрошње рачунарских ресурса и какав ефекат има доменска адаптација модела на говор из области пољопривреде?

Из основног питања произилази неколико конкретнијих питања која су испитана у експерименталном делу рада:

- Какве разлике постоје између Whisper и Faster-Whisper система у погледу тачности транскрипције, времена извршавања, RTF вредности и потрошње RAM-а?
- Како величина Whisper модела утиче на однос између тачности транскрипције и брзине извршавања?
- У којој мери различити типови позадинског шума и SNR вредности утичу на тачност препознавања говора?
- Какве разлике у резултатима постоје приликом препознавања српског и енглеског говора у контролисаним условима?
- Како вредност параметра *beam size* утиче на WER и време потребно за транскрипцију?
- У којој мери INT8 квантизација може да смањи време извршавања и захтеве за ресурсима у односу на FP32 формат?
- Какав утицај примена VAD-а има на брзину и тачност транскрипције?
- Како корак обраде аудио сигнала, акустичко преклапање и пренос текстуалног контекста утичу на тачност транскрипције, RTF, време до првог резултата и нагомилавање обраде приликом симулације рада у реалном времену?
- Да ли је могуће на основу више различитих метрика изабрати конфигурацију која представља добар компромис између тачности, брзине и потрошње ресурса?
- Какав утицај доменска адаптација има на препознавање српског говора из области пољопривреде и колико се адаптирани модел успешно примењује на говорника који није био присутан у скупу за обучавање?

Први допринос представља формирање и коришћење скупа од 40 аудио записа читаног говора на српском језику са три говорника, различитог садржаја и трајања. На истом скупу могуће је контролисано поређење више конфигурација и анализа резултата не само у целини, већ и према говорницима и трајању аудио записа.

Други допринос представља проширену анализу фактора који утичу на рад Faster-Whisper система. Поред величине модела и позадинског шума, анализирани су квантизација, параметар *beam size*, примена VAD-а и сегментација аудио сигнала. Систем није посматран само кроз тачност транскрипције, већ истовремено кроз WER, време извршавања, RTF, латенцију и потрошњу меморије.

Посебан допринос представља анализа симулиране транскрипције у реалном времену, у којој је испитан утицај три корака обраде аудио сигнала и четири режима коришћења акустичког преклапања и текстуалног контекста. Поред тачности транскрипције, анализирани су фактор реалног времена, процењено време до првог резултата и кашњење реда чекања. Оваква поставка омогућила је да се, поред избора корака обраде, испита и да ли додатни акустички и текстуални контекст побољшавају препознавање говора.

Следећи допринос је развој поступка за избор конфигурације Faster-Whisper система. Резултати више експеримената обједињени су тако да се конфигурације могу поредити на основу више критеријума. Поред основног рангирања, коришћене су Парето анализа и анализа осетљивости на различите тежине критеријума, чиме је омогућено да се избор конфигурације не заснива само на једној метрици.

Значајан део рада представља и доменска адаптација Whisper модела за српски говор из области пољопривреде. Посебно је значајно што тест скуп садржи говор четвртог говорника који није учествовао у обучавању модела. Према томе, евалуација није ограничена само на препознавање говора говорника чији су снимци коришћени током обучавања, већ обухвата и проверу генерализације адаптираног модела на новог говорника.

Сви наведени доприноси заједно омогућавају да се Whisper систем анализира од основног препознавања српског говора, преко оптимизације инференције и рада у условима ограничених ресурса, до прилагођавања модела конкретном домену.

1.3. Организација рада

Рад је организован у дванаест поглавља која постепено обухватају теоријске основе, експерименталну методологију, резултате спроведених експеримената и доменску адаптацију модела.

Након уводног поглавља, у другом поглављу приказане су основне карактеристике система за аутоматско препознавање говора. Представљен је развој ASR система, основни поступци обраде говорног сигнала, модели дубоког учења који се користе за препознавање говора и метрике за њихову евалуацију. На крају поглавља дат је преглед сродних истраживања, са посебним освртом на препознавање говора на српском језику, оптимизацију инференције, обраду у реалном времену и доменску адаптацију.

У трећем поглављу описан је Whisper модел. Представљена је трансформер архитектура са енкодер-декодер структуром, начин обраде аудио сигнала, основне карактеристике обучавања и вишејезичности модела, као и различите величине Whisper модела.

Четврто поглавље посвећено је Faster-Whisper имплементацији и CTranslate2 библиотеци. Описане су технике које омогућавају ефикаснију инференцију, укључујући

квантизацију и оптимизацију меморије, као и поступци декодирања и обраде говора, попут Beam Search-а и VAD-а, који су значајни за обраду говора у реалном времену.

У петом поглављу представљена је експериментална методологија. Описани су хардверско и софтверско окружење, главни скуп читаног српског говора, додатни скупови коришћени у појединачним експериментима, начин припреме аудио записа и поступак мерења тачности и перформанси система.

Шесто поглавље садржи основно поређење Whisper и Faster-Whisper система. Поређење је извршено са становишта тачности транскрипције, времена извршавања, вредности RTF-а и потрошње меморије, уз додатну анализу резултата према говорницима и трајању аудио записа.

У седмом поглављу приказана је главна експериментална анализа и оптимизација Faster-Whisper система. Испитан је утицај величине модела, позадинског шума и SNR вредности, језика, параметра *beam size*, квантизације и примене VAD-а. У оквиру истог поглавља анализирана је и симулирана сегментна транскрипција у реалном времену, са различитим корацима обраде и режимима акустичког преклапања и преноса текстуалног контекста.

Осмо поглавље обједињује резултате претходних експеримената кроз поступак вишекритеријумског избора конфигурације. Поред рангирања, Парето анализе и анализе осетљивости, приказан је избор интегрисаног профила који обухвата модел, квантизацију и параметре транскрипције. На крају поглавља представљена је завршна евалуација профила на два говорна скупа, уз поређење сегментне обраде и транскрипције целих снимака.

У деветом поглављу описана је доменска адаптација Whisper модела за српски језик у области пољопривреде. Приказани су формирање и подела доменског говорног скупа, поступак додатног обучавања модела и методологија поређења основног и адаптираног модела, са посебним освртом на препознавање пољопривредне терминологије и генерализацију на новог говорника.

У десетом поглављу дата је заједничка дискусија добијених резултата и наведена су главна ограничења спроведеног истраживања.

У једанаестом поглављу изведени су закључци рада и наведени могући правци даљег развоја и истраживања.

На крају рада, у дванаестом поглављу, наведена је литература коришћена приликом израде теоријског и експерименталног дела рада.

2. АУТОМАТСКО ПРЕПОЗНАВАЊЕ ГОВОРА

2.1. Основни принципи и развој ASR система

Аутоматско препознавање говора (ASR) представља област вештачке интелигенције чији је основни задатак претварање говорног сигнала у текстуални облик. Улаз у ASR систем представља аудио сигнал који садржи говор, док је излаз текстуална секвенца која одговара изговореном садржају. Иако је овај поступак једноставан са становишта корисника, препознавање говора представља сложен проблем јер се говор разликује у зависности од говорника, брзине изговора, акцента, језика, квалитета снимка и присуства позадинског шума. Развој система за аутоматско препознавање говора траје више деценија. Први системи појавили су се средином двадесетог века и могли су да препознају само ограничен број речи или цифара. Њихове могућности биле су знатно мање од могућности савремених система, а препознавање је углавном било ограничено на унапред дефинисан речник и контролисане услове снимања.

Значајан напредак остварен је применом статистичких метода. Током осамдесетих и деведесетих година широко су коришћени скривени Марковљеви модели (HMM) у комбинацији са Гаусовим моделима мешавина (GMM). HMM модели коришћени су за описивање временске структуре говорног сигнала, док су GMM модели служили за статистичко представљање акустичких карактеристика. Овакав приступ дуго је представљао стандард у области аутоматског препознавања говора, али је захтевао више одвојених компоненти и пажљиву припрему карактеристика сигнала. Појава дубоког учења довела је до значајне промене у развоју ASR система. Дубоке неуронске мреже омогућиле су моделима да сложене карактеристике говора уче директно из података, чиме је постепено смањена потреба за ручним пројектовањем појединих делова система. Посебно значајну улогу имале су рекурентне неуронске мреже (RNN) и њихова варијанта Long Short-Term Memory (LSTM), које су погодне за обраду секвенцијалних података и омогућавају коришћење информација из претходних делова говорног сигнала [3].

Следећи значајан корак представља развој трансформер архитектуре. За разлику од класичних рекурентних мрежа, трансформер се заснива на механизму пажње (енгл. *attention*), који омогућава моделу да одреди који су делови улазне секвенце значајни приликом обраде одређеног елемента. Овај приступ омогућава ефикаснију обраду дугих секвенци и боље моделовање зависности између различитих делова сигнала. Трансформер архитектура представља основу Whisper модела који се користи у овом раду [4].

Без обзира на разлике између појединих архитектура, основни поступак аутоматског препознавања говора може се представити кроз неколико корака. Најпре се говор снима микрофоном и претвара у дигитални аудио сигнал. Након тога се врши припрема сигнала и формирање репрезентације погодне за обраду моделом. Модел анализира добијене карактеристике, а у последњој фази декодер генерише највероватнију текстуалну секвенцу.

Поједностављено, поступак се може представити на следећи начин:

говор → аудио сигнал → претпроцесирање → представљање аудио сигнала → ASR модел → декодирање → текст

Код традиционалних система ови кораци су често били реализовани као више одвојених компоненти. Савремени *end-to-end* системи обједињују велики део поступка у оквиру једног модела који учи везу између аудио сигнала и одговарајуће текстуалне секвенце. Whisper припада управо овој групи система [5]. На рад ASR система утиче велики број фактора. Иста реченица може звучати различито када је изговарају различите особе, а додатне разлике настају услед брзине говора, пауза, нагласка и начина изговора. Поред карактеристика говорника, значајан утицај имају микрофон, просторија у којој је снимак направљен и присуство различитих врста позадинског шума. Због тога се квалитет ASR система не може поуздано проценити на основу само једног говорника или малог броја идеалних аудио записа. За практичну примену важна је и брзина рада система. Висока тачност није довољна уколико је за транскрипцију потребно знатно више времена од трајања самог аудио записа. Ово је посебно важно код система који треба да обрађују говор у реалном времену. Због тога се савремени ASR системи анализирају и са становишта односа између тачности, времена обраде и потребних рачунарских ресурса. Управо овај однос представља један од главних предмета експерименталне анализе у овом раду.

2.2. Обрада и представљање говорног сигнала

Пре него што аудио сигнал може да се користи као улаз у модел за аутоматско препознавање говора, потребно га је представити у облику погодном за рачунарску обраду. Људски говор у физичком облику представља континуиран звучни талас, док рачунар ради са дискретним дигиталним вредностима. Због тога је први корак снимање и дигитализација говорног сигнала. Приликом дигитализације аналогни сигнал се узоркује у одређеним временским интервалима. Број узорака који се узимају у једној секунди представља фреквенцију узорковања (енгл. *sampling rate*) и изражава се у херцима. На пример, фреквенција узорковања од 16 kHz значи да се у једној секунди формира 16.000 узорака аудио сигнала. Тако се континуирани говор претвара у низ нумеричких вредности које рачунар може да обрађује. Добијени аудио сигнал може да садржи делове тишине, разлике у јачини звука и различите врсте шума. Због тога се пре даље обраде, у зависности од система, могу применити поступци као што су нормализација сигнала, уклањање или смањивање шума, промена фреквенције узорковања и сегментација аудио записа. Сам временски облик аудио сигнала није увек најпогоднији за анализу особина говора. Важне информације налазе се и у његовом фреквенцијском садржају, односно у томе које су фреквенције присутне у одређеном тренутку. Због тога се у обради говора често користи краткотрајна Фуријеова трансформација (STFT).

Основна идеја STFT поступка је да се аудио сигнал подели на кратке временске оквире и да се за сваки од њих анализира фреквенцијски садржај. Тако се добија информација о томе како се фреквенцијске компоненте сигнала мењају током времена. Ово је важно код говора јер се његове карактеристике непрестано мењају током

изговарања различитих гласова и речи. Резултат овакве анализе може се представити помоћу спектрограма. Спектрограм представља временско-фреквенцијску репрезентацију аудио сигнала: једна оса представља време, друга фреквенцију, док вредности унутар спектрограма описују интензитет појединих фреквенцијских компоненти. На овај начин модел добија много погоднији приказ структуре говорног сигнала него када би се посматрао само оригинални таласни облик. У системима за препознавање говора често се користи и Mel скала, која је формирана тако да боље одговара начину на који човек доживљава разлике у фреквенцији. На спектар сигнала примењује се скуп Mel филтера, чиме се добија Mel спектрограм. Уместо равномерног представљања целог фреквенцијског опсега, већи значај се даје расподели која је ближа перцепцији људског слуха. Следећи корак може бити логаритамска трансформација вредности Mel спектрограма, чиме се добија лог-Mel спектрограм. Оваква репрезентација је погодна за примену дубоких неуронских мрежа и користи се као улаз у Whisper модел [5].

Поред спектрограма, у традиционалним системима за препознавање говора често су коришћени мел-фреквенцијски кепстрални коефицијенти (MFCC). Они представљају компактнији опис спектралних карактеристика говорног сигнала и дуго су били један од стандардних начина представљања говора у ASR системима. Развој дубоког учења омогућио је моделима да све већи део потребних карактеристика науче директно из спектралних репрезентација, због чега модели као што је Whisper користе лог-Mel спектрограм као улаз.

За Whisper систем поступак се зато поједностављено може представити као:

аудио сигнал → узорковање и припрема → STFT → Mel филтерска банка → лог-Mel спектрограм → Whisper енкодер → декодер → транскрипција [5], [6]

Начин припреме аудио сигнала има директан утицај на касније препознавање говора. Позадински шум мења спектралне карактеристике сигнала, дуги периоди тишине повећавају количину аудио материјала који се обрађује, док неправилна сегментација може довести до губитка контекста или дела изговорене речи. Због тога су у експерименталном делу овог рада посебно анализирани позадински шум, детекција говорне активности и сегментација аудио сигнала. Тако се испитује не само сам модел, већ и утицај начина на који се говорни сигнал припрема и прослеђује систему за транскрипцију.

2.3. Модели дубоког учења за препознавање говора

Примена дубоког учења значајно је променила начин на који се развијају системи за аутоматско препознавање говора. За разлику од традиционалних приступа, код којих је систем био подељен на више засебних компоненти, савремени модели могу да науче сложену везу између аудио сигнала и одговарајућег текста на основу великог броја примера. Један од првих значајнијих приступа заснованих на дубоком учењу биле су дубоке неуронске мреже (DNN). Оне су коришћене за акустичко моделирање и постепено су замениле GMM моделе у многим ASR системима. Њихова предност била је могућност учења сложенијих зависности у говорном сигналу, али саме по себи нису биле довољно

погодне за моделовање дужих временских зависности које су карактеристичне за говор. За обраду секвенцијалних података значајну примену добиле су рекурентне неуронске мреже (RNN). Код њих се информација из претходних корака преноси на наредне кораке, што омогућава да се приликом анализе тренутног дела сигнала узме у обзир и претходни контекст. Ова особина је важна код препознавања говора, јер значење и препознавање одређеног гласа или речи често зависе од онога што је претходно изговорено. Класичне RNN мреже имају потешкоће при учењу зависности које обухватају већи број временских корака. Као једно од решења развијене су LSTM мреже. LSTM користи посебне механизме којима контролише које информације треба задржати, а које одбацити. На тај начин може успешније да обрађује дуже секвенце и због тога је дуго представљао важан приступ у системима за препознавање говора [3].

Даљи развој довео је до све веће примене *end-to-end* модела. Основна идеја овог приступа је да се што већи део процеса препознавања обједини у један модел. Уместо засебног пројектовања великог броја компоненти, модел се обучава на паровима аудио записа и одговарајућих транскрипата и учи како да из улазног говора генерише текст. У оквиру *end-to-end* приступа користе се различити начини повезивања аудио сигнала и текста. Један од њих је Connectionist Temporal Classification (CTC), који омогућава обучавање модела без потребе да се унапред зна тачно временско поравнање сваког дела аудио сигнала са одговарајућим карактером или речју. Ово је значајно јер аудио запис и текст имају различите дужине и не постоји једноставна веза између сваког аудио оквира и једног текстуалног симбола [7].

Други приступ заснива се на енкодер-декодер архитектури. Енкодер обрађује улазни сигнал и формира његову унутрашњу репрезентацију, док декодер на основу те репрезентације генерише излазну текстуалну секвенцу. У комбинацији са механизмом пажње, декодер може приликом генерисања текста да користи различите делове информација добијених из улазног сигнала. За разлику од RNN и LSTM архитектура, трансформер се не ослања на класичну рекурентну обраду секвенце, већ користи механизам пажње. То омогућава ефикасније моделовање зависности између различитих делова улазних података и представља основу великог броја савремених модела за обраду језика и говора [4].

Поред директне примене трансформер архитектуре, значајан правац развоја вишејезичких ASR система представља учење заједничких говорних репрезентација на великој количини неозначених података из различитих језика. Такви приступи омогућавају пренос научених репрезентација и на језике са мањом количином означених говорних података, што је посебно значајно за језике са ограниченим ресурсима [8].

Још једна значајна архитектура развијена за препознавање говора је *Conformer*, која комбинује трансформер механизам пажње са конволуционим слојевима како би истовремено моделовала глобалне и локалне зависности у говорном сигналу [9].

Whisper, који представља основу експерименталног дела овог рада, користи управо енкодер-декодер трансформер архитектуру. Улазни аудио сигнал се претвара у лог-Mel спектрограм и прослеђује енкодеру, док декодер генерише одговарајућу текстуалну

секвенцу. Исти модел подржава више задатака, укључујући препознавање језика, транскрипцију и превођење говора на енглески језик. Једна од важних карактеристика Whisper приступа је начин обучавања. Модел је обучен на приближно 680.000 сати вишејезичних и вишенаменских аудио података, што му омогућава примену на различитим језицима и типовима аудио садржаја без обавезног додатног обучавања за сваки појединачни скуп података [5].

Whisper је доступан у више величина, од мањих модела који захтевају мање ресурса до већих модела који имају знатно већи број параметара. На пример, оригинална породица обухвата Tiny, Base, Small, Medium и Large моделе. Разлике у величини директно утичу на рачунарске захтеве, али и на могућности модела. Управо због тога је у експерименталном делу овог рада посебно испитан однос између величине Whisper модела, тачности препознавања и времена извршавања.

Поред коришћења већ обученог модела, могуће је и његово додатно обучавање на специфичном скупу података. Овај поступак омогућава да се знање претходно обученог модела прилагоди одређеном језику, говорном стилу или домену. У овом раду такав приступ је примењен за доменску адаптацију Whisper модела на српски говор из области пољопривреде. Детаљан поступак припреме података, обучавања и евалуације адаптираног модела приказан је у деветом поглављу.

2.4. Метрике за евалуацију ASR система

За поређење система за аутоматско препознавање говора није довољно посматрати само добијени текст. Потребне су метрике којима се резултати различитих модела и конфигурација могу изразити бројчано и упоредити под истим условима. У овом раду посматрају се две основне групе метрика: метрике тачности транскрипције и метрике перформанси система.

Стопа грешке на нивоу речи (WER)

Основна метрика за процену тачности у овом раду је стопа грешке на нивоу речи (WER). Она показује колико се речи у добијеној транскрипцији разликује од референтног текста. WER је уједно једна од стандардних метрика за поређење код ASR система.

Израчунава се на основу три врсте грешака:

- S - број замењених речи,
- D - број изостављених речи,
- I - број додатих речи.

Ако је са N означен укупан број речи у референтном тексту, WER се израчунава као:

$$\mathrm{WER} = \frac{S+D+I}{N} \tag{2.1}$$

Добијена вредност се најчешће изражава процентуално. Мања вредност означава бољу транскрипцију, док WER од 0% значи да се транскрипција у потпуности поклапа са референтним текстом. На пример, ако референтни текст садржи 100 речи, а систем направи 5 замена, 3 изостављања и 2 додавања, добија се:

$$\text{WER} = \frac{5+3+2}{100} = 0{,}10 = 10\%$$

Важно је напоменути да WER може бити и већи од 100%. То се дешава када модел генерише велики број речи које не постоје у референтном тексту, односно када број замена, изостављања и нарочито уметања постане већи од броја референтних речи. Ова особина WER метрике је значајна приликом анализе веома деградираних аудио сигнала. Пре израчунавања вредности WER-а потребно је водити рачуна и о нормализацији текста. Разлике у интерпункцији, великим и малим словима или начину записивања одређених речи могу повећати WER иако суштинска разлика у препознатом говору није велика. И сам Whisper рад указује на овај проблем и примењује стандардизацију текста пре израчунавања WER метрике [5].

У експерименталном делу овог рада пре израчунавања вредности WER-а референтни и генерисани транскрипти нормализовани су превођењем текста у мала слова, уклањањем интерпункције и свођењем вишеструких размака на један. Додатно је проверено писмо генерисаних транскрипата у коришћеним експерименталним скуповима. У анализираним излазима није уочено мешање ћирилице и латинице, већ су транскрипти генерисани латиничним писмом, због чега додатна транслитерација није била неопходна. Бројеви нису посебно претварани из цифарског у текстуални облик, већ су задржавани у облику у ком се појављују у референтном и генерисаном транскрипту. Екавски и ијекавски облици нису изједначавани, јер би таква нормализација могла да прикрије стварне разлике у излазу ASR система.

Стопа грешке на нивоу карактера (CER)

Поред грешака на нивоу речи, тачност транскрипције може се анализирати и на нивоу појединачних карактера помоћу стопе грешке на нивоу карактера (CER).

Принцип израчунавања је исти као код WER метрике:

$$\text{CER} = \frac{S_c+D_c+I_c}{N_c} \tag{2.2}$$

где S_c , D_c и I_c представљају број замена, изостављања и додавања карактера, док N_c представља број карактера у референтном тексту. CER омогућава детаљнији увид у грешке код речи које су делимично исправно препознате. На пример, једна погрешно препозната реч може представљати целу грешку приликом израчунавања WER метрике,

иако се разликује од исправне речи само у једном или два слова. Иако CER представља корисну допунску метрику, у главном експерименталном делу овог рада WER је изабран као примарна метрика тачности како би се резултати различитих конфигурација поредили на јединствен начин.

Време транскрипције

Поред тачности, у овом раду значајно је време потребно за транскрипцију аудио записа. Оно представља време од покретања обраде до добијања резултата транскрипције и изражава се у секундама. Ова вредност омогућава директно поређење различитих имплементација, величина модела и начина квантизације. Ипак, само време транскрипције није увек довољно за поређење, јер аудио записи могу имати различито трајање. Због тога се користи и RTF метрика.

Фактор реалног времена (RTF)

Фактор реалног времена (RTF) представља однос времена потребног за обраду и трајања аудио записа:

$$\mathrm{RTF} = \frac{t_{\mathrm{obrada}}}{t_{\mathrm{audio}}} \tag{2.3}$$

где t_{obrada} представља време потребно за транскрипцију, а t_{audio} трајање аудио записа.

Ако аудио запис траје 60 секунди, а систем га обради за 15 секунди, добија се:

$$\mathrm{RTF} = \frac{15}{60} = 0{,}25$$

Вредност RTF < 1 значи да систем обрађује аудио брже од његовог реалног трајања. RTF = 1 означава обраду брзином реалног времена, док RTF > 1 значи да је за обраду потребно више времена од трајања аудио сигнала. RTF је посебно користан у овом раду јер омогућава поређење брзине обраде аудио записа различитих дужина.

Меморијска потрошња

Приликом локалног покретања ASR модела важну метрику представља и меморијска захтевност. Већи модели и начини извршавања са већом нумеричком прецизношћу могу захтевати значајно више меморије, што ограничава њихову примену на слабијем хардверу.

У овом раду меморијска потрошња посматра се пре свега приликом поређења Whisper и Faster-Whisper система, као и различитих величина модела и начина квантизације. При тумачењу ових резултата потребно је узети у обзир да се мери меморија процеса у коме се модел извршава, па добијене вредности представљају практично мерење у коришћеном окружењу, а не апсолутну величину самог модела.

Латенција

Код обраде говора у реалном времену поред укупног времена транскрипције важна је и латенција. Она описује кашњење између пријема дела аудио сигнала и добијања одговарајућег резултата. Ова метрика постаје посебно важна када се аудио не обрађује као један комплетан запис, већ се дели на мање сегменте. Мањи сегменти могу омогућити раније добијање првих резултата, али истовремено могу смањити количину контекста доступног моделу и тиме погоршати тачност. Због тога се код обраде у реалном времену латенција посматра заједно са вредностима WER-а и RTF-а.

Ниједна од наведених метрика сама по себи није довољна за потпуну оцену ASR система. Конфигурација са најмањим WER-ом може истовремено бити сувише спора или захтевати превише меморије, док најбржи модел може имати неприхватљив број грешака. Због тога се у експерименталном делу рада резултати анализирају кроз више метрика, а њихово заједничко посматрање касније представља основу за избор одговарајуће конфигурације система.

2.5. Преглед сродних истраживања

Развој система за аутоматско препознавање говора за српски језик има вишегодишњу истраживачку традицију, али је доступност великих означених говорних скупова знатно мања у поређењу са језицима са већом количином доступних ресурса. Сечујски и сарадници приказују развој технологија за синтезу и препознавање говора за српски и друге јужнословенске језике, као и прелазак од традиционалних статистичких приступа ка савременим системима заснованим на дубоком учењу. Ограничена количина говорних и језичких ресурса представља један од значајних изазова при развоју система за ове језике, због чега су од посебног значаја приступи који омогућавају коришћење претходно обучених вишејезичких модела и њихово накнадно прилагођавање конкретном језику или области примене [10].

Значајан ресурс за истраживање аутоматског препознавања српског говора представља и ParlaSpeech колекција, формирана на основу парламентарних заседања и аутоматског повезивања говорних и текстуалних података. У оквиру ове колекције доступан је и ParlaSpeech-RS, говорни корпус за српски језик, који представља један од новијих јавно доступних ресурса за развој и евалуацију система за препознавање српског говора [11], [12].

Поред ресурса специфичних за српски језик, за евалуацију вишејезичких ASR система значајни су и велики вишејезички скупови као што су FLEURS и Mozilla Common Voice. FLEURS је развијен као вишејезички референтни скуп (енгл. *benchmark*) за евалуацију говорних репрезентација, док Common Voice представља велики јавно доступан вишејезички говорни корпус формиран доприносима говорника различитих језика. Овакви скупови имају значајну улогу у развоју и упоредној евалуацији вишејезичких система за препознавање говора [13], [14].

Посебно релевантно за примену Whisper модела на српски језик је истраживање тима из Новог Сада, у коме је испитана могућност побољшања система заснованог на моделу Whisper за аутоматско препознавање српског говора коришћењем синтетички генерисаних говорних података. За генерисање додатног скупа коришћен је текст из српског веб корпуса SrWAC, уз припрему података и нормализацију текста засновану на великим језичким моделима. Применом система за синтезу говора (TTS) са девет различитих гласова генерисано је укупно око 1500 сати синтетичког говора. Експерименти су спроведени над Whisper Medium моделом, при чему је полазни модел претходно додатно обучен на око 1300 сати транскрибованог говора. Током додатног обучавања синтетичким подацима енкодер део модела био је замрзнут. Евалуација на Common Voice скупу и снимцима из реалних услова показала је побољшања у погледу WER и CER метрика, чиме је показано да синтетички говор може бити користан за додатно прилагођавање Whisper модела српском језику [15].

Наведени приступ је непосредно повезан са једним од праваца истраживања у овом раду, али се циљ и начин адаптације разликују. Док је у наведеном истраживању нагласак на побољшању препознавања српског говора коришћењем додатних синтетичких података, у овом раду адаптација је усмерена на специфичан домен пољопривреде. За ту намену формиран је посебан скуп од 800 аудио записа са доменски специфичним садржајем, а евалуација је организована тако да тест скуп садржи говорника који није учествовао у обучавању. На тај начин се, поред прилагођавања специфичној терминологији, испитује и генерализација адаптираног модела на новог говорника.

Значај прилагођавања система за препознавање говора специфичном домену показан је и у ранијим истраживањима за српски језик. Пакоци и сарадници разматрали су проблем аутоматске транскрипције диктираних медицинских налаза, код којих специфична терминологија и ограничена количина расположивих података представљају значајан изазов. У њиховом истраживању проблем оскудности података разматран је применом доменски прилагођених језичких модела и поступака за побољшање избора хипотеза. Овакви резултати указују на значај прилагођавања система карактеристикама конкретне области примене. У овом раду сличан проблем доменске специфичности разматра се у контексту савременог Whisper модела и терминологије из области пољопривреде [16].

Могућност доменског прилагођавања самог Whisper модела разматрана је и у новијим истраживањима усмереним на специфичне индустријске случајеве примене. Резултати таквих истраживања указују на потенцијал додатног обучавања Whisper модела када се систем примењује на говор и терминологију специфичне области [17].

Поред тачности препознавања, значајан аспект практичне примене савремених ASR система представља ефикасност инференције. Whisper модел развијен је као вишејезички модел за препознавање говора, обучен на великој количини разноврсних говорних података, чиме је омогућена његова примена на различите језике и услове снимања. Међутим, практична примена модела, посебно на уређајима који се ослањају на CPU, захтева разматрање не само тачности већ и времена извршавања и потребних рачунарских ресурса [5].

Faster-Whisper представља имплементацију Whisper модела засновану на библиотеци CTranslate2. Она омогућава примену различитих оптимизација инференције и типова квантизације, због чега је погодна за анализу односа између тачности, брзине и потрошње ресурса. CTranslate2 подржава различите типове нумеричке репрезентације и оптимизовано извршавање на CPU и GPU уређајима. Због тога се у овом раду, поред WER метрике, систематски анализирају време транскрипције, RTF и меморијска захтевност различитих Whisper и Faster-Whisper конфигурација [1], [2].

Други практично значајан аспект представља обрада говора у реалном времену. Код система заснованих на Whisper моделу аудио сигнал се приликом овакве примене може обрађивати у мањим сегментима, при чему избор величине сегмента утиче на количину контекста доступног моделу и на време потребно за добијање резултата. Краћи сегменти омогућавају раније добијање транскрипције, док већи сегменти обезбеђују моделу више говорног контекста. Због тога је у овом раду обрада у реалном времену испитана кроз контролисану сегментацију дужих аудио записа и истовремену анализу тачности транскрипције, латенције и вредности RTF-а.

На основу прегледаних истраживања може се уочити да су претходни радови обухватили развој технологија за препознавање говора на српском језику, примену Whisper модела и његово побољшање додатним синтетичким говорним подацима, као и прилагођавање ASR система специфичним доменима. Поред тога, развој оптимизованих имплементација као што је Faster-Whisper омогућава да се савремени модели посматрају не само са становишта тачности, већ и са становишта брзине и рачунарских захтева [1], [2], [10], [15], [16].

У односу на наведена истраживања, овај рад је усмерен на обједињену експерименталну анализу више аспеката практичне примене Whisper система за српски језик. Поред тачности препознавања, анализирају се брзина извршавања, RTF, меморијски захтеви, величина модела, квантизација, параметар *beam size*, примена VAD-а, отпорност на различите нивое позадинског шума и сегментација при симулираној обради у реалном времену. Резултати појединачних експеримената затим се обједињују у поступку избора конфигурације на основу више критеријума. Додатно, спроводи се доменска адаптација Whisper модела на српски говор из области пољопривреде и провера генерализације адаптираног модела на говорника који није био присутан током обучавања.

3. WHISPER АРХИТЕКТУРА

3.1. Трансформер архитектура са енкодер-декодер структуром

Whisper је заснован на трансформер архитектури, која је постала једна од основних архитектура за обраду секвенцијалних података. За разлику од RNN и LSTM мрежа, трансформер не захтева класичну рекурентну обраду елемената секвенце један по један. Његов кључни део представља механизам пажње, који омогућава моделу да приликом обраде једног дела секвенце узме у обзир и друге њене делове.

Основу механизма пажње чине три матрице: матрица упита (Q), матрица кључева (K) и матрица вредности (V). На основу њих модел одређује колики значај треба доделити различитим деловима улазне секвенце. Механизам пажње може се представити изразом:

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \tag{3.1}$$

Матрице упита (Q) и кључева (K) користе се за одређивање повезаности између елемената секвенце, док матрица вредности (V) садржи информације које се даље користе на основу израчунатих тежина. Дељење са $\sqrt{d_k}$ спречава да вредности скаларних производа постану превелике са повећањем димензионалности вектора. У пракси трансформер користи механизам вишеструке пажње (енгл. *multi-head attention*), односно више механизама пажње који раде паралелно. На овај начин различите пројекције могу да науче различите односе између делова секвенце. Поред механизма пажње, трансформер блокови садрже потпуно повезане слојеве, резидуалне везе и нормализацију, који заједно омогућавају стабилно обучавање дубљих мрежа [4].

Whisper користи енкодер-декодер трансформер архитектуру. Ова организација подразумева да модел има два главна дела са различитим улогама. Енкодер је задужен за обраду улазног аудио сигнала, док декодер на основу информација добијених од енкодера генерише текстуалну секвенцу. Енкодер добија репрезентацију говорног сигнала и претвара је у низ унутрашњих репрезентација које описују важне особине аудио садржаја. Механизам самопажње омогућава му да повеже информације из различитих делова улазног сигнала. На тај начин информације из једног дела изговорене реченице могу бити значајне за правилно тумачење других делова секвенце. Декодер има другачији задатак. Он постепено формира транскрипцију, при чему се текст не генерише као целина, већ токен по токен. Приликом избора следећег токена декодер користи претходно генерисане токене и информације које је добио од енкодера. Тако се акустичка информација из аудио сигнала повезује са текстуалним контекстом. Оваква архитектура је погодна за препознавање говора јер улазна и излазна секвенца не морају имати исту дужину. Неколико секунди аудио сигнала може да садржи различит број речи и токена, па модел сам учи везу између говорног и текстуалног садржаја [5].

3.2. Архитектура и начин рада Whisper модела

Whisper представља *end-to-end* систем за препознавање говора заснован на описаној енкодер-декодер трансформер архитектури. Основни поступак рада може се представити као:

аудио сигнал → лог-Mel спектрограм → енкодер → декодер → текстуална транскрипција

Први корак представља припрема аудио сигнала. Whisper стандардно ради са аудио сигналом фреквенције узорковања од 16 kHz. Аудио сигнал се затим претвара у лог-Mel спектрограм, који представља улаз у неуронску мрежу. Начин формирања овакве репрезентације описан је у претходном поглављу, па се овде пажња усмерава на њену даљу обраду унутар Whisper модела [5], [6].

Пре уласка у трансформер блокове, спектрограм пролази кроз почетне конволуционе слојеве. Њихов задатак је да обраде локалне карактеристике спектрограма и припреме одговарајућу репрезентацију за енкодер. Пошто трансформер сам по себи нема информацију о редоследу елемената, репрезентацији се додају и позиционе информације. Добијена секвенца затим пролази кроз више трансформер блокова енкодера. У сваком блоку механизам пажње анализира односе између различитих делова аудио сигнала. На излазу енкодера добија се репрезентација која више није само спектрални приказ аудио сигнала, већ садржи информације које модел користи за препознавање његовог говорног садржаја. Декодер на основу ове репрезентације генерише транскрипцију. Процес почиње посебним токенима који моделу задају контекст задатка, на пример језик и врсту операције која треба да се изврши. Након тога се текст генерише токен по токен све док модел не дође до ознаке завршетка секвенце. Токени не морају да одговарају целим речима. Једна реч може бити представљена једним или већим бројем токена, у зависности од начина на који је присутна у речнику модела. Овакав приступ омогућава коришћење истог система токенизације над великим бројем различитих речи и језика [5].

Приликом генерисања транскрипције модел за сваки следећи токен формира расподелу вероватноћа могућих кандидата. Начин избора између њих зависи и од поступка декодирања. Једноставнији приступ бира највероватнији наредни токен, док Beam Search истовремено задржава више могућих секвенци и током декодирања тражи повољнију целокупну секвенцу. Утицај параметра *beam size* на тачност и време транскрипције посебно је испитан у експерименталном делу рада.

Важно је поновити да Faster-Whisper не мења основну архитектуру и обучене параметре Whisper модела. Главна разлика налази се у начину извршавања, јер Faster-Whisper користи CTranslate2 библиотеку. Због тога се архитектура Whisper модела разматра одвојено од оптимизација инференције, које су предмет наредног поглавља [1], [2].

3.3. Тренинг, вишејезичност и варијанте Whisper модела

Једна од главних карактеристика Whisper модела је начин на који је обучаван. Уместо обучавања искључиво на мањим, пажљиво припремљеним скуповима говорних података, за Whisper је коришћена велика количина аудио података прикупљених са интернета и одговарајућих транскрипата. Whisper модели обучени су на приближно 680.000 сати аудио података. Скуп садржи енглески и вишејезички говор, као и примере који се користе за задатак превођења говора на енглески језик. Велика количина и разноврсност података један су од разлога због којих модел може да ради са различитим говорницима, језицима и условима снимања [5].

Whisper је обучаван као модел са више задатака. Различити задаци представљени су у заједничком формату помоћу посебних токена. На овај начин исти модел учи да идентификује језик, транскрибује говор, преводи говор на енглески језик и генерише временске ознаке. Ово је практично јер није потребно користити потпуно одвојен модел за сваки од ових задатака. За овај рад посебно је значајна вишејезичност Whisper модела. Српски језик је подржан у вишејезичким варијантама модела, па је могуће користити већ обучени Whisper без претходног обучавања сопственог модела од почетка [5]. Ипак, количина и структура тренинг података нису исте за сваки језик, због чега се квалитет препознавања може разликовати између језика. Управо је то један од разлога зашто се у овом раду српски говор посебно анализира. Whisper је доступан у више величина. У експерименталном делу овог рада коришћене су четири основне варијанте: Tiny, Base, Small и Medium. Оне се разликују по броју параметара, броју трансформер слојева и потребним рачунарским ресурсима. Поред њих, постоје и веће варијанте из породице Large. Подела на више величина омогућава избор модела у зависности од конкретне примене и расположивог хардвера [6].

Мањи модели имају мањи број параметара и захтевају мање ресурса, због чега су погодни за бржу инференцију. Са повећањем величине модела расту меморијски и рачунарски захтеви, али већи капацитет модела може да омогући прецизније препознавање сложенијег говора. Из тог разлога се избор модела не своди једноставно на коришћење највеће доступне варијанте, већ зависи од односа између захтеване тачности и расположивих ресурса. Тај однос се у овом раду не претпоставља унапред, већ се испитује експериментално. Поред директног коришћења већ обучених модела, Whisper се може додатно прилагодити одређеном скупу података применом поступка додатног обучавања. При томе се полази од већ научених параметара модела, а обучавање се наставља на новом скупу аудио записа и одговарајућих транскрипата. Према томе, није потребно обучавати ASR модел од почетка, што би захтевало далеко већу количину података и рачунарских ресурса. У овом раду ова могућност је искоришћена за доменску адаптацију на српски говор из области пољопривреде. Полази се од већ обученог Whisper модела, а додатним обучавањем модел се излаже већем броју примера који садрже пољопривредне појмове и начин њихове употребе у српском језику. Циљ таквог поступка није формирање новог ASR модела од почетка, већ прилагођавање постојећег модела конкретном домену. Сам поступак додатног обучавања, структура формираног скупа и начин евалуације основног и адаптираног модела детаљније су приказани у поглављу посвећеном доменској адаптацији.

4. FASTER-WHISPER И CTRANSLATE2

4.1. Faster-Whisper и CTranslate2 библиотека

Иако Whisper модели могу да постигну добру тачност транскрипције, њихово извршавање може бити захтевно, посебно када се користе већи модели или када се инференција обавља на CPU-у. Основна имплементација заснована на PyTorch-у није првенствено развијена са циљем минималног времена извршавања и потрошње меморије. Због тога су развијене алтернативне имплементације које користе исте обучене Whisper моделе, али оптимизују начин њиховог извршавања. Faster-Whisper представља имплементацију Whisper модела која за инференцију користи библиотеку CTranslate2. Основна идеја није промена начина на који Whisper препознаје говор нити обучавање новог модела, већ ефикасније извршавање постојећег модела. Ово је важно за практичну примену, јер омогућава ефикасније извршавање Whisper модела и потенцијално смањење времена обраде и захтева за рачунарским ресурсима. CTranslate2 је библиотека намењена ефикасној инференцији трансформер модела. За разлику од општих оквира за дубоко учење, који морају да подрже и обучавање и велики број различитих архитектура, CTranslate2 библиотека је усмерена на извршавање већ обучених модела. То омогућава примену оптимизација које су посебно прилагођене инференцији [1], [2].

Да би Whisper модел могао да се користи у Faster-Whisper имплементацији, његови параметри се конвертују у формат који подржава CTranslate2 библиотеку. При томе се не мења основна трансформер енкодер-декодер архитектура описана у претходном поглављу. Конвертовани модел и даље садржи научене параметре Whisper модела, али се они чувају и извршавају у облику који је прилагођен CTranslate2 библиотеци [1], [2].

Поступак се поједностављено може представити на следећи начин:

Whisper модел → конверзија у CTranslate2 формат → Faster-Whisper → оптимизована инференција → транскрипција

Приликом транскрипције Faster-Whisper најпре припрема аудио сигнал у облику који Whisper модел очекује, након чега CTranslate2 библиотека извршава енкодер и декодер део мреже. На излазу се добијају токени који се затим претварају у текстуалну транскрипцију. Са становишта корисника добија се исти тип излаза као код основног Whisper система, док се главне разлике налазе у начину на који се операције модела извршавају. Једна од важних предности CTranslate2 библиотеке је могућност ефикаснијег извршавања на различитим типовима хардвера. Библиотека садржи оптимизације за CPU и GPU, а начин извршавања може се прилагодити доступном уређају [2]. Ово је значајно у случају овог рада, јер је главни део анализе усмерен на CPU извршавање, односно на могућност практичног коришћења ASR система без ослањања на снажну графичку картицу.

Faster-Whisper подржава и различите начине рачунске прецизности, као што су FP32 и INT8. Тиме се омогућава да се иста основна архитектура извршава са различитим односом између прецизности израчунавања, брзине и потребних ресурса. Ова особина је

посебно важна за експерименте у овом раду, јер омогућава да се у контролисаним условима испита утицај квантизације [1], [2].

Поред самог извршавања модела, Faster-Whisper омогућава подешавање параметара који утичу на процес транскрипције, као што су језик, параметар *beam size* и примена VAD-а. Због тога он представља погодну основу за испитивање не само брзине извршавања, већ и начина на који различита подешавања утичу на укупан рад система [1].

Евентуалне разлике у брзини између различитих имплементација не представљају последицу потпуно другачије неуронске архитектуре, већ су последица специфичности саме имплементације и оптимизације инференције. Са друге стране, мање разлике у добијеним транскрипцијама могу настати због различитих имплементационих детаља и подешавања декодирања, због чега се у експериментима пореде и тачност и перформансе система [1], [2].

4.2. Квантизација и оптимизација извршавања

Једна од најзначајнијих могућности које CTranslate2 библиотека пружа јесте квантизација модела. Квантизација представља поступак коришћења нумеричких формата ниже прецизности за чување параметара и извршавање одређених операција модела. Циљ је смањење количине података који се обрађују и ефикасније коришћење расположивог хардвера [18].

Параметри неуронских мрежа се уобичајено могу представљати бројевима са покретним зарезом, на пример у FP32 формату. У том случају за представљање једне вредности користе се 32 бита. Код квантизације се параметри могу представити са мањим бројем битова. За овај рад посебно је значајан INT8 формат, у коме се користе осмобитне целобројне вредности.

Основна идеја може се приказати поређењем:

FP32 → 32 бита по вредности

INT8 → 8 бита по вредности

То не значи да ће цео модел у реалном систему користити тачно четири пута мање RAM-а. Поред самих тежина модела, током извршавања постоје и активације, привремени подаци, библиотеке и други делови процеса који заузимају меморију. Ипак, мања нумеричка репрезентација омогућава смањење меморијског оптерећења параметара и може да убрза операције на хардверу који има ефикасну подршку за INT8 израчунавања. Приликом квантизације потребно је вредности из оригиналног опсега пресликати у мањи број могућих вредности. Због тога квантизована репрезентација није потпуно идентична оригиналној. Теоријски, губитак прецизности може да утиче и на излаз модела, па је приликом практичне примене потребно проверити да ли добијено убрзање оправдава евентуалну промену тачности транскрипције. Управо због тога се у овом раду INT8 не посматра само као начин за постизање веће брзине. Квантизација се анализира

истовремено са становишта времена извршавања, вредности RTF-а, потрошње меморије и WER-а. На тај начин може да се утврди да ли смањење нумеричке прецизности доноси практичну корист без израженог нарушавања квалитета препознавања.

Поред квантизације, CTranslate2 библиотека примењује и друге оптимизације извршавања. Оне се односе на ефикаснију реализацију операција које се велики број пута понављају у трансформер моделу, боље коришћење процесорских ресурса и смањење броја непотребних операција приликом инференције. Важан део оптимизације представља и управљање меморијом. Код великих неуронских мрежа није важно само колико меморије заузимају параметри модела, већ и колико се привремених података ствара током извршавања. Ефикасније коришћење и поновна употреба меморијских области могу да смање додатне трошкове који настају током инференције [2].

На CPU-у је значајно и ефикасно коришћење доступних процесорских инструкција и паралелног извршавања. Операције над матрицама представљају велики део израчунавања у трансформер моделима, па њихова оптимизована имплементација може значајно да утиче на укупно време транскрипције. Ефекат ових оптимизација зависи и од конкретног процесора, величине модела и изабраног начина израчунавања. Из тог разлога није исправно очекивати да INT8 увек донесе исто убрзање или исто смањење меморијске потрошње. Практични ефекат зависи од модела, дужине аудио записа, хардвера и осталих подешавања система. Због тога се стварна корист квантизације у овом раду утврђује мерењем, а не само на основу теоријских карактеристика нумеричких формата.

Посебно је важно разликовати оптимизацију модела за инференцију од његовог додатног обучавања. CTranslate2 и INT8 квантизација не мењају знање модела на начин на који то чини додатно обучавање. Њихов циљ је да већ обучени модел буде ефикасније извршен. Доменска адаптација из области пољопривреде, са друге стране, мења параметре модела кроз додатно обучавање на новом скупу података. На тај начин су у овом раду раздвојена два различита приступа побољшању ASR система: оптимизација начина извршавања и прилагођавање самог модела специфичном домену [2].

4.3. Beam Search и детекција говорне активности (VAD)

Поред избора модела и начина квантизације, на рад Faster-Whisper система утичу и параметри који одређују начин декодирања и припреме аудио сигнала. У овом раду посебно су разматрани Beam Search и детекција говорне активности (VAD), јер оба механизма могу да утичу на однос између тачности транскрипције и времена потребног за обраду. Приликом генерисања транскрипције Whisper декодер за сваки корак одређује вероватноће могућих наредних токена. Најједноставнији приступ је да се у сваком кораку изабере само токен са највећом вероватноћом. Овакав поступак је брз, али локално највероватнији избор не мора увек да доведе до најбоље целокупне текстуалне секвенце.

Beam Search представља поступак декодирања код кога се истовремено задржава више могућих кандидата за транскрипцију. Параметар *beam size* одређује број кандидата који остају у разматрању током генерисања текста. Након сваког корака кандидати се

проширују новим токенима, оцењују се добијене секвенце, а задржава се ограничен број најбоље оцењених [1].

На пример, код вредности *beam_size = 1* практично се прати само један кандидат. Код вредности *beam_size = 5* током декодирања задржава се више могућих секвенци, чиме се смањује вероватноћа да локално најбољи избор доведе до неповољније целокупне транскрипције. Повећање вредности овог параметра, међутим, повећава и број операција које декодер мора да изврши. Због тога већи *beam_size* може да побољша резултат декодирања, али истовремено повећава време транскрипције. Такође, повећавање броја кандидата не значи да ће се тачност стално побољшавати. После одређене вредности добитак може постати веома мали или потпуно изостати, док време извршавања наставља да расте. Из тог разлога је у овом раду утицај различитих вредности *beam size* испитан експериментално, а не претпостављен унапред.

Други механизам значајан за практичну обраду говора јесте детекција говорне активности (VAD). Његов задатак је да у аудио сигналу одреди делове у којима је присутан говор и да их разликује од периода без говорне активности. Аудио запис у реалним условима често не садржи непрекидан говор. Између реченица и речи могу да постоје паузе, а дужи снимци могу да садрже и значајне периоде тишине. Уколико се цео такав запис директно проследи ASR моделу, систем обрађује и делове у којима нема корисног говорног садржаја.

Применом VAD-а најпре се проналазе сегменти са говорном активношћу, након чега се они прослеђују систему за транскрипцију [19]. Поједностављено, поступак се може представити као:

аудио сигнал → VAD → издвајање говорних сегмената → Whisper → транскрипција

На овај начин могуће је смањити количину аудио материјала коју модел стварно обрађује. Ефекат VAD-а зато највише зависи од структуре снимка. Код аудио записа који садрже дуге периоде тишине корист може бити већа, док код готово непрекидног говора нема много материјала који се може изоставити. Примена VAD-а ипак мора да буде довољно пажљива. Ако алгоритам погрешно процени почетак или крај говорног сегмента, може да одсече део изговорене речи или кратак део говора. То може да утиче на каснију транскрипцију. Због тога није довољно посматрати само да ли VAD смањује време обраде, већ је потребно проверити и да ли при томе долази до промене вредности WER-а. У овом раду *beam size* и VAD имају различите улоге у оптимизацији система. *Beam size* утиче на начин претраживања могућих текстуалних секвенци током декодирања, док VAD утиче на количину и делове аудио сигнала који се прослеђују моделу. Њихов стварни утицај на тачност и брзину анализиран је у засебним експериментима [19].

4.4. Обрада говора у реалном времену

Код класичне транскрипције комплетан аудио запис је доступан пре почетка обраде. Такав приступ је погодан за транскрипцију већ снимљених аудио и видео материјала, али није довољан за примене у којима резултат треба приказивати док особа још увек говори. У таквим случајевима потребна је обрада говора у реалном или приближно реалном времену. Под транскрипцијом у реалном времену подразумева се обрада аудио сигнала који пристиже постепено, уместо чекања да се заврши цео снимак. Аудио се најчешће дели на мање сегменте (енгл. *chunks*), који се редом прослеђују ASR систему.

Могућност прилагођавања Whisper модела транскрипцији у реалном времену разматрана је и у претходним истраживањима, у којима се континуирани аудио ток обрађује кроз краће сегменте и постепено ажурирање транскрипције [20].

Основни поступак може се приказати као:

аудио ток → сегмент → транскрипција → следећи сегмент → транскрипција → ...

Један од главних проблема оваквог приступа представља избор трајања сегмента. Ако су сегменти веома кратки, систем може раније да започне обраду и корисник потенцијално брже добија први резултат. Међутим, модел тада има мање контекста на располагању. Реч или реченица може бити пресечена на граници два сегмента, а независна транскрипција кратких делова може да доведе до већег броја грешака. Са друге стране, дужи сегменти обезбеђују више говорног контекста и по структури су ближи класичној транскрипцији целог аудио записа. Недостатак је што систем мора дуже да чека да се сегмент прикупи пре него што може да започне његову обраду. Због тога постоји компромис између латенције и тачности транскрипције [20].

За процену могућности рада у реалном времену значајан је RTF. Ако је за обраду једног сегмента потребно мање времена него што траје сам сегмент, систем у принципу може да прати долазни аудио без сталног нагомилавања необрађених података. Међутим, RTF сам по себи не описује целокупно понашање система за обраду у реалном времену. Важна је и латенција обраде, односно време потребно да систем обради појединачни сегмент. Поред просечне вредности може се посматрати и високи перцентил, на пример P95 латенција, која показује испод које вредности се налази 95% измерених времена обраде. Тако се поред типичног понашања система могу уочити и повремена већа кашњења.

За кориснички доживљај значајно је и време до првог резултата (TTFR). Оно показује колико времена протекне од почетка аудио тока до тренутка када је доступан први резултат транскрипције. Ова вредност зависи и од трајања изабраног сегмента, јер систем најпре мора да прикупи довољну количину аудио сигнала за његову обраду. Уколико обрада сегмента траје дуже него што нови аудио подаци пристижу, може доћи до стварања реда чекања, односно нагомилавања необрађених сегмената. У том случају кашњење се временом повећава и систем више не може стабилно да прати говор у реалном времену. Због тога се приликом анализе система за обраду у реалном времену,

поред WER-а и RTF-а, могу посматрати и величина реда чекања и кашњење добијених резултата.

Whisper по својој основној архитектури није класичан ASR модел за обраду у реалном времену који интерно обрађује непрекидан аудио ток без сегментације. Практичан приступ је зато да се долазни аудио дели на сегменте и да се сваки од њих обрађује Whisper или Faster-Whisper моделом. Квалитет таквог решења у великој мери зависи од начина сегментације и количине контекста доступне моделу. У овом раду обрада у реалном времену је испитана кроз симулацију над унапред снимљеним аудио записима, а не директним снимањем са микрофона. Према томе, могуће је контролисано поредити различите величине сегмената под истим условима. Аудио записи се обрађују сегментно, редоследом којим би делови сигнала пристизали у реалном систему, при чему се, у зависности од примењеног режима, може користити и акустички или текстуални контекст из претходних сегмената.

Један од начина ублажавања проблема на границама сегмената јесте акустичко преклапање, при коме се приликом обраде новог дела сигнала поново укључује и кратак део претходног аудио материјала. На тај начин модел добија додатни акустички контекст за препознавање речи које се налазе у близини границе. Други приступ је пренос текстуалног контекста, при коме се део претходно прихваћене транскрипције користи као почетни текстуални подстицај приликом декодирања наредног сегмента. Ови поступци могу побољшати континуитет препознавања, али могу довести и до понављања речи, преноса претходних грешака или повећања рачунарског оптерећења. Због тога је потребно посебно испитати њихов утицај на тачност и перформансе система.

Овакав приступ не представља потпуну имплементацију продукционог система за обраду у реалном времену, али омогућава контролисану анализу утицаја корака обраде, акустичког преклапања и текстуалног контекста на тачност транскрипције и временске карактеристике система. Конкретна методологија симулације и добијени резултати приказани су у поглављима 5.3 и 7.7.

5. ЕКСПЕРИМЕНТАЛНА МЕТОДОЛОГИЈА

5.1. Хардверско и софтверско окружење

Сви главни експерименти у овом раду изведени су у локалном рачунарском окружењу са оперативним системом Windows, при чему је за извршавање Whisper и Faster-Whisper модела коришћен CPU. Овакав избор окружења омогућава анализу применљивости система на рачунару без ослањања на снажну графичку картицу, што је посебно важно приликом испитивања оптимизација које нуди Faster-Whisper [1], [6].

Основно Python окружење организовано је помоћу Anaconda платформе, при чему је за потребе експеримената коришћено засебно виртуелно окружење. Експерименти су развијани и извршавани кроз Jupyter Notebook, што је омогућило да се код за припрему података, покретање модела, мерење перформанси и анализу резултата организује у одвојене експерименталне целине. За рад са основним Whisper моделом коришћена је библиотека OpenAI Whisper, која модел извршава помоћу PyTorch оквира. Пошто је инференција вршена на CPU-у, основни Whisper је коришћен у FP32 формату. За оптимизовану имплементацију коришћена је библиотека Faster-Whisper, која се ослања на CTranslate2 библиотеку. У зависности од експеримента, Faster-Whisper модели покретани су са INT8 или FP32 начином израчунавања.

У експериментима су коришћене различите величине Whisper модела: Tiny, Base, Small и Medium. У основном поређењу Whisper и Faster-Whisper система коришћен је Base модел, док је у експериментима посвећеним величини модела и квантизацији анализирано више варијанти. Поред основних библиотека за покретање модела, коришћени су NumPy и Pandas за обраду и организацију резултата, Matplotlib за графички приказ, JiWER за израчунавање WER метрике и psutil за праћење потрошње меморије процеса.

Резултати експеримената чувани су у CSV датотекама и посебним директоријумима за резултате, што је омогућило да се касније користе за заједничку анализу без поновног покретања свих модела. Ово је посебно коришћено у експерименту избора конфигурације, где су резултати претходних експеримената обједињени и анализирани кроз више критеријума.

Главни експерименти извршени су на рачунару следеће конфигурације:

Процесор: AMD Ryzen 5 5600H (3,30 GHz)
RAM: 8 GB (7,34 GB доступно)
Оперативни систем: 64-битни Windows
Начин извршавања: CPU

Навођење хардверске конфигурације важно је јер измерено време транскрипције и потрошња меморије зависе од рачунара на коме се експеримент извршава. Због тога резултати брзине у овом раду представљају мерења у конкретном експерименталном окружењу, док су поређења различитих конфигурација извршена под истим условима.

5.2. Формирање и структура аудио скупова података

За потребе експерименталног дела рада коришћено је више аудио скупова, при чему је сваки формиран у складу са циљем одређеног експеримента. Главни скуп намењен анализи Whisper и Faster-Whisper система садржи читани говор на српском језику, док су за испитивање шума, језика, примене VAD-а и доменске адаптације коришћени додатни скупови.

Главни скуп читаног српског говора

Основни референтни скуп садржи 40 WAV аудио записа на српском језику. Снимке су направила три различита говорника, а садржај је намерно одабран тако да обухвати различите реченице и теме. Према томе, скуп није ограничен на једну област, већ представља општи скуп српског говора намењен поређењу различитих конфигурација система. Аудио записи су организовани у четири групе према приближном трајању. Снимци од 1 до 10 представљају кратке записе трајања приближно 5-10 секунди, снимци 11-25 средње записе од приближно 15-30 секунди, снимци 26-35 дуже записе од приближно 30-60 секунди, док снимци 36-40 представљају веома дуге записе од приближно 62-82 секунде. Три говорника нису заступљена потпуно једнаким бројем снимака. Први говорник снимио је 13, други 13, а трећи 14 аудио записа. Оваква структура омогућава да се, поред укупних резултата, анализирају и разлике према говорнику и трајању аудио материјала. За сваки снимак постоји познат референтни текст, односно тачан текст који је говорник читао. Референтни транскрипти користе се за поређење са текстом који генерише ASR модел и израчунавање вредности WER-а.

Овај скуп није дељен на подскупове за обучавање, валидацију и тестирање, јер се у основном делу рада не користи за обучавање модела. Његова улога је да представља заједнички референтни скуп на коме се под контролисаним условима могу поредити различити модели и конфигурације.

Додатни скупови за појединачне експерименте

Нису сви експерименти захтевали обраду свих 40 снимака. За експерименте који подразумевају већи број поновљених транскрипција формирани су подскупови главног референтног скупа.

За анализу утицаја величине модела изабрано је 20 снимака који обухватају различита трајања и говорнике. Над њима су испитани Tiny, Base, Small и Medium модели.

За испитивање утицаја позадинског шума коришћен је подскуп од 10 снимака читаног српског говора, који обухвата три говорника. На основу ових снимака формиране су варијанте са три врсте шума: белим шумом, розе шумом и снимљеним шумом пољопривредне механизације, односно трактора. За сваки тип шума коришћено је седам SNR вредности: 20, 10, 5, 0, −5, −10 и −15 dB. Тако је за сваки оригинални снимак формирана 21 верзија са шумом. Укупно је генерисано 210 деградираних аудио записа, који су, заједно са 10 оригиналних снимака без додатог шума, чинили 220 тестних

случајева. Оваква поставка омогућила је поређење тачности транскрипције истог говорног садржаја при различитим типовима и интензитетима шума.

За упоредно испитивање препознавања српског и енглеског говора коришћен је вишејезички говорни скуп FLEURS. Из тестног дела скупа издвојено је по 30 аудио записа за српски и енглески језик, односно укупно 60 снимака природног говора. Избор је извршен програмски, уз фиксно почетно стање генератора случајних бројева, како би се омогућила поновљивост експеримента. За оба језика коришћени су исти модел, тип квантизације и параметри декодирања, уз експлицитно задавање одговарајућег језика транскрипције. Оваква поставка омогућава упоредну анализу перформанси на два језичка узорка, али не изолује у потпуности утицај језика од разлика у говорницима, акцентима и акустичким карактеристикама снимака.

У експерименту са параметром *beam size* коришћен је подскуп од 15 српских аудио записа читаног говора. Исти снимци транскрибовани су са различитим вредностима параметра *beam size*, чиме је обезбеђено да се утицај декодирања испитује над непромењеним улазним материјалом.

За анализу квантизације коришћен је цео скуп од 40 српских снимака читаног говора. Комбиновањем четири величине модела и два начина израчунавања, INT8 и FP32, добијено је осам конфигурација. Свака конфигурација тестирана је над истих 40 снимака, што је укупно дало 320 измерених транскрипција.

За анализу утицаја VAD-а коришћене су две групе аудио записа. Једну групу чинили су синтетички енглески записи, док је друга формирана од српских снимака читаног говора којима су контролисано додате паузе. На тај начин је било могуће поредити исте записе са укљученим и искљученим VAD механизмом.

За експеримент симулиране сегментне транскрипције у реалном времену коришћено је пет најдужих српских снимака читаног говора из главног скупа, односно записи 36-40. На сваком снимку испитана су три корака обраде од 2, 5 и 10 секунди, у комбинацији са четири режима: без преклапања и текстуалног контекста, само са акустичким преклапањем, само са текстуалним контекстом и са оба механизма. Исти снимци транскрибовани су и као целина ради формирања контролних резултата. Оваква поставка омогућила је поређење укупно 12 конфигурација сегментне обраде над истим говорним материјалом.

За завршну проверу интегрисаног профила коришћена су два скупа података. Први је обухватао 30 српских аудио записа из тестног дела скупа FLEURS, претходно издвојених за експеримент поређења српског и енглеског говора. Други је представљао главни скуп од 40 снимака читаног српског говора, који је коришћен и у претходним експериментима оптимизације. На оба скупа примењени су исти параметри интегрисаног профила, уз засебно поређење сегментне транскрипције и обраде целих снимака. Резултати су анализирани одвојено за сваки скуп, како би се избегло мешање различитих говорних материјала и њихових референтних транскрипата.

Скуп за доменску адаптацију

Поред референтних скупова, формиран је засебан говорни скуп за доменску адаптацију Whisper модела на српски језик у области пољопривреде. За разлику од претходних скупова, овај скуп се користи за додатно обучавање модела. Доменски скуп садржи укупно 800 аудио записа са одговарајућим референтним транскриптима. Садржај снимака усмерен је на пољопривреду и обухвата речи, изразе и реченице карактеристичне за овај домен. Од укупног броја, 675 аудио записа припада скупу за обучавање и обухвата говор три различита говорника. За валидацију је издвојено 75 аудио записа, док завршни тест скуп садржи 50 аудио записа посебног четвртог говорника. Увођење четвртог говорника само у тест скуп има важну улогу у евалуацији. Модел током поступка додатног обучавања није изложен гласу тог говорника, па се завршно тестирање не врши само над новим реченицама, већ и над особом чији говор није био присутан у скупу за обучавање. На овај начин смањује се могућност да побољшање на тест скупу буде последица искључиво прилагођавања гласовима говорника који су учествовали у обучавању, а истовремено се испитује способност модела да доменско знање примени на говор новог говорника.

Главни скуп од 40 снимака читаног говора и пољопривредни скуп од 800 снимака зато имају различите улоге. Први служи као општи српски референтни скуп за анализу и оптимизацију, док други служи за обучавање, валидацију и тестирање доменски адаптираног модела. Ова два скупа се не мешају приликом обучавања, што омогућава да се касније провери и понашање адаптираног модела на општем српском говору.

5.3. Припрема и претпроцесирање аудио записа

Пре покретања експеримената било је потребно припремити аудио записе и одговарајуће референтне транскрипте тако да се исти подаци могу користити за поређење различитих модела и конфигурација. Припрема је зависила од конкретног експеримента, али је основни принцип био да се приликом поређења мења само параметар који се испитује, док остали услови остају што је могуће више непромењени. Главни скуп од 40 аудио записа читаног говора на српском језику чуван је у WAV формату. За сваки аудио запис постоји одговарајући референтни текст који садржи оно што је говорник изговорио. Називи датотека организовани су тако да садрже редни број снимка и ознаку говорника, на пример 1govornik1.wav. Овакав начин именовања олакшава обраду већег броја датотека и каснију анализу резултата према говорницима. За сваки снимак програмски је одређено његово трајање. Ова информација се користи за израчунавање RTF метрике и за поделу снимака у групе према трајању.

Посебна припрема била је потребна у експерименту са позадинским шумом. Полазни снимци без додатог шума задржани су као референтна варијанта, док су за испитивање деградације генерисане верзије са белим, розе и шумом пољопривредне механизације. Снимак механизације претворен је у моно сигнал, прилагођен фреквенцији узорковања говорног записа и временски усклађен са његовим трајањем. За сваки говорни запис одабран је репродуктиван сегмент шума механизације, који је затим коришћен на свим SNR нивоима тог записа. Интензитет додатог шума подешаван је на основу снаге

говорног и шумног сигнала, како би се постигао задати однос сигнал-шум (SNR). Коришћене су вредности 20, 10, 5, 0, −5, −10 и −15 dB. У случајевима прекорачења дозвољене амплитуде, целокупна мешавина је заједнички скалирана ради спречавања одсецања сигнала, чиме је очуван однос сигнал-шум. На тај начин исти говорни садржај испитиван је при различитим нивоима акустичке деградације.

Припрема је била другачија и у експерименту са применом VAD-а. За српски део читаног говора овог експеримента изабрано је пет снимака из главног скупа, а у њих су контролисано додате паузе. У сваком снимку додате су четири паузе случајног трајања између приближно 1,2 и 2,5 секунди. За генерисање је коришћено фиксно почетно стање генератора случајних бројева, чиме је обезбеђена поновљивост поступка. Тако припремљени снимци омогућавају да се VAD испита у условима у којима аудио садржи јасно присутне периоде без говора. Поред српских снимака читаног говора, у истом експерименту коришћена је и група од пет синтетичких енглеских снимака са контролисано уметнутним паузама.

Код експеримента са симулираном транскрипцијом у реалном времену коришћено је пет најдужих снимака из главног скупа, односно записи 36–40. Пре сегментације аудио сигнали су доведени на фреквенцију узорковања од 16 kHz. Сваки снимак најпре је транскрибован као целина ради формирања контролне вредности, након чега је испитана сегментна обрада са корацима од 2, 5 и 10 секунди. За сваки корак испитана су четири режима: независна обрада без преклапања и контекста, обрада са акустичким преклапањем, обрада са преносом текстуалног контекста и комбинована примена оба механизма. Код режима са преклапањем новом сегменту додаван је до један секунд претходног аудио сигнала, тако да је трајање улаза у модел могло бити веће од корака пристизања нових података. Код режима са текстуалним контекстом коришћено је највише осам последњих прихваћених речи из претходне транскрипције, под условом да је претходни сегмент задовољавао дефинисану проверу поузданости контекста. При спајању резултата примењена су правила за издвајање новог временског дела и уклањање поновљених речи на границама сегмената. За речи које прелазе границу преклапања коришћен је унапред дефинисан праг од 40% процењеног трајања речи у новом делу сигнала. Додатно је примењена провера броја препознатих речи по секунди. Уколико је број препознатих речи по секунди прелазио задати праг од четири, транскрипција тог сегмента није коришћена за формирање текстуалног контекста наредног сегмента, али је задржана у коначном транскрипту за израчунавање WER-а. Коначна транскрипција сваког снимка формирана је спајањем прихваћених делова, након чега је упоређена са референтним текстом. Експеримент је реализован над унапред снимљеним сигналима, уз симулацију времена пристизања сегмената и реда чекања, па добијене латенције представљају процене, а не мерења продукционог система са микрофонским улазом.

За поређење српског и енглеског језика коришћени су аудио записи из тестног дела скупа FLEURS. Метаподаци су преузети из одговарајућих датотека, док су из званичних аудио архива издвојени изабрани WAV снимци. За сваки снимак коришћен је припадајући референтни транскрипт. Пре израчунавања вредности метрика примењена је нормализација текста, која обухвата уједначавање великих и малих слова, интерпункције и размака. Бројеви нису претварани у речи, нити су дијалекатске и друге језичке варијанте

аутоматски изједначаване. На тај начин обезбеђен је доследан поступак евалуације оба језичка узорка.

Пре израчунавања WER-а, референтни и генерисани текстови нормализовани су превођењем слова у мала слова, уклањањем интерпункцијских знакова и нормализацијом размака. Исти поступак примењен је на референтни текст и излаз модела. Посебан поступак припреме примењен је на пољопривредни скуп за доменску адаптацију. Сваки аудио запис повезан је са тачним текстом који му одговара, јер додатно обучавање захтева парове аудио записа и транскрипата. Подаци су затим организовани у одвојене скупове за обучавање, валидацију и тестирање. Тест скуп је током обучавања остао потпуно издвојен, а додатну разлику представља то што га је снимио четврти говорник чији снимци нису присутни у скупу за обучавање.

На овај начин припрема података није била потпуно иста за све експерименте, већ је прилагођена ономе што се у конкретном експерименту испитује. Ипак, код свих поређења задржан је исти основни принцип: конфигурације које се међусобно пореде добијају исти улазни аудио и исти референтни текст.

5.4. Методологија евалуације и мерења перформанси

Евалуација Whisper и Faster-Whisper система извршена је кроз више метрика које описују различите аспекте њиховог рада. Главна метрика тачности је стопа грешке на нивоу речи (WER), док су за анализу перформанси коришћени време транскрипције, фактор реалног времена (RTF), меморијска захтевност и, код експеримента за обраду у реалном времену, метрика латенције. WER је израчунаван поређењем референтног текста са транскрипцијом коју је генерисао модел. Као што је описано у поглављу 2.4, метрика узима у обзир замене, изостављања и додавања речи. Пошто су поједини експерименти обухватали већи број аудио записа, резултати нису анализирани само појединачно, већ су коришћене и збирне вредности.

Као основна збирна мера коришћена је просечна вредност WER-а по аудио записима, односно макро просек. Поред ње, у појединим експериментима израчунавана је и медијана, која је мање осетљива на појединачне снимке са веома великим бројем грешака. Коришћен је и WER на нивоу корпуса (енгл. *corpus* WER), код кога се грешке и број референтних речи сабирају на нивоу целог скупа пре израчунавања коначне вредности. На тај начин дужи снимци и реченице са већим бројем речи имају пропорционално већи утицај него код обичног просека вредности WER-а. За мерење брзине бележено је време транскрипције сваког аудио записа. Мерење обухвата инференцију над датим снимком, док се учитавање модела не посматра као део времена транскрипције. Ово је важно јер би у супротном резултат кратких снимака био у великој мери одређен временом иницијалног учитавања модела, а не стварном брзином обраде говора. Поред апсолутног времена израчунаван је RTF, као однос времена обраде и трајања аудио записа. Ова метрика омогућава поређење снимака различитих дужина. За сваки модел или конфигурацију израчунаване су просечне вредности времена и RTF-а, а код појединих експеримената анализирана је и максимална вредност RTF-а и проценат снимака који су обрађени са RTF < 1.

Када су две имплементације или конфигурације директно поређене, израчунавано је и убрзање (енгл. *speedup*). Убрзање је израчунавано као однос времена извршавања референтне конфигурације и времена конфигурације са којом се она пореди. Вредност већа од 1 означава да је посматрана конфигурација бржа од референтне. При поређењу Whisper и Faster-Whisper система, Whisper је коришћен као референтна конфигурација.

За процену меморијских захтева коришћена је библиотека psutil, којом је праћена RSS меморија Python процеса. Меморијска мерења спроведена су независно од главних Jupyter петљи за мерење времена извршавања и RTF-а. Свака испитивана конфигурација покретана је у засебном Python процесу, чиме је избегнут утицај претходно учитаних модела, кешираних података и заосталих меморијских алокација на наредно мерење. За сваку конфигурацију извршена су три независна понављања. Вредност RSS-а је праћена од почетка процеса, током учитавања модела и током контролисане транскрипције, а као главна меморијска метрика коришћена је максимална вредност RSS-а (енгл. *peak* RSS) , односно највећа забележена количина физичке меморије коју је процес заузимао током мерења. За сваку конфигурацију приказане су просечна максимална вредност RSS-а и стандардна девијација три независна мерења. Овај поступак примењен је у два одвојена експеримента. У директном поређењу основног Whisper и Faster-Whisper система анализиране су Whisper Base FP32, Faster-Whisper Base FP32 и Faster-Whisper Base INT8 конфигурације. У експерименту утицаја квантизације меморијска захтевност је засебно измерена за осам Faster-Whisper конфигурација насталих комбинацијом Tiny, Base, Small и Medium модела са INT8 и FP32 начином извршавања. Измерена максимална вредност RSS-а представља укупну вредност RSS-а засебног Python процеса током учитавања модела и контролисане инференције, а не искључиво величину тежина модела у меморији. Због тога се резултати тумаче као практична мера максималне меморијске захтевности конфигурације у коришћеном експерименталном окружењу.

Код експеримената са више конфигурација водило се рачуна да основни параметри транскрипције остану непромењени када нису предмет испитивања. На пример, у анализи величине модела мењана је величина модела, док је у анализи параметра *beam size* мењана искључиво његова вредност. На тај начин се смањује број додатних фактора који би могли да утичу на резултат. Посебна методологија коришћена је код експеримента за обраду у реалном времену. Поред WER и RTF метрика, мерено је време обраде сваког сегмента, просечна и P95 латенција, време до првог резултата (TTFR), као и појава реда чекања када обрада сегмента не може да прати брзину пристизања аудио података. За сваку величину сегмента резултати су упоређени и са транскрипцијом целог аудио записа. У експерименту избора конфигурације резултати претходних мерења обједињени су кроз вишекритеријумску анализу. За главно поређење конфигурација коришћени су WER, RTF и просечна максимална вредност RSS-а. Пошто ове метрике имају различите јединице и опсеге вредности, пре њиховог комбиновања извршена је нормализација. Затим су метрикама додељене тежине у складу са значајем тачности, брзине и ресурсне захтевности.

Поред основног рангирања коришћена је Парето анализа, којом се издвајају конфигурације код којих побољшање једне карактеристике захтева погоршање најмање једне друге. Спроведена је и анализа осетљивости са различитим расподелама тежина,

како би се проверило у којој мери избор конфигурације зависи од почетно постављених приоритета.

Евалуација доменски адаптираног модела заснована је на директном поређењу основног Whisper модела и модела након додатног обучавања. Оба модела тестирају се над истим издвојеним пољопривредним тест скупом, који није коришћен током обучавања. Пошто тест скуп садржи четвртог говорника, овакав поступак омогућава проверу препознавања доменског садржаја и понашања модела на новом говорнику који није био заступљен током обучавања. Поред тога, општи српски референтни скуп омогућава проверу да ли се након доменске адаптације мења понашање модела на говору који није везан за пољопривреду.

У завршној валидацији интегрисаног профила додатно су поређена два начина транскрипције: сегментна обрада са акустичким преклапањем и текстуалним контекстом и контролна обрада целог аудио записа. За оба начина коришћени су исти модел, квантизација, параметар *beam size* и VAD подешавање. Време учитавања модела и припрема аудио сигнала нису укључени у време инференције. Код сегментне обраде процењено је време до првог делимичног резултата, док је код обраде целог снимка процењено време до добијања комплетне транскрипције.

Овако постављена методологија омогућава да се различити аспекти система не процењују на основу једне вредности. Тачност, брзина, меморијски захтеви и понашање у условима приближним реалном времену посматрају се одвојено, а затим се њихови резултати повезују приликом коначног избора конфигурације.

6. ПОРЕЂЕЊЕ WHISPER И FASTER-WHISPER СИСТЕМА

6.1. Поставка експеримента

Први експериментални део рада има за циљ директно поређење основне Whisper имплементације и Faster-Whisper имплементације у контролисаним условима. Намера је да се испита утицај различите имплементације и нумеричке прецизности на тачност и брзину транскрипције, при чему се параметри декодирања одржавају једнаким. За експеримент је коришћен главни референтни скуп од 40 аудио записа читаног говора на српском језику, које су снимила три различита говорника. Као што је описано у поглављу 5, скуп садржи кратке, средње, дуге и веома дуге записе.

У основном поређењу коришћен је Whisper Base модел у три конфигурације:

1. Основни Whisper Base са FP32 начином израчунавања,
2. Faster-Whisper Base са FP32 начином израчунавања,
3. Faster-Whisper Base са INT8 начином израчунавања.

Све конфигурације извршаване су у истом CPU окружењу и над истих 40 аудио записа. Пошто различите имплементације могу имати различите подразумеване вредности параметара декодирања, параметри су експлицитно усклађени како би се обезбедили што упоредивији услови. Коришћена подешавања приказана су у Табели 6.1.

Табела 6.1. Параметри коришћени у контролисаном поређењу

Параметар	**Whisper**	**Faster-Whisper FP32**	**Faster-Whisper INT8**
Модел	Base	Base	Base
Уређај	CPU	CPU	CPU
Нумеричка прецизност	FP32	FP32	INT8
Језик	sr	sr	sr
Задатак	transcribe	transcribe	transcribe
beam_size	5	5	5
temperature	0.0	0.0	0.0
condition_on_previous_text	True	True	True
without_timestamps	False	False	False
initial_prompt	None	None	None
VAD	-	False	False

Код основног Whisper модела FP32 извршавање обезбеђено је постављањем параметра *fp16 = False*, док је код Faster-Whisper конфигурација VAD био искључен. За сваки аудио запис мерени су WER, време транскрипције и RTF. Поред резултата за појединачне снимке, израчунате су просечне и медијалне вредности за цео скуп. Меморијска захтевност посматрана је одвојено и анализирана је у поглављу 6.3, док су резултати додатно груписани према трајању аудио записа и говорнику у поглављу 6.4.

Циљ овог експеримента није да се покаже да је једна имплементација универзално боља од друге, већ да се у контролисаним условима испитају разлике између основне PyTorch имплементације и CTranslate2 имплементације, као и утицај INT8 начина извршавања. Закључци се зато односе на коришћени референтни скуп, хардверско окружење и наведене параметре декодирања.

6.2. Анализа тачности и брзине транскрипције

Након усклађивања параметара декодирања, експеримент је поновљен над свих 40 аудио записа. Збирни резултати тачности и времена транскрипције приказани су у Табели 6.2.

Табела 6.2. Поређење Whisper Base и Faster-Whisper Base конфигурација

Конфигурација	Просечан WER [%]	Просечно време [s]
Whisper Base FP32	42,95	21,72
Faster-Whisper Base FP32	42,95	6,85
Faster-Whisper Base INT8	43,08	4,59

Са становишта тачности, Whisper Base FP32 и Faster-Whisper Base FP32 остварили су идентичан просечан WER од 42,95%. Faster-Whisper Base INT8 остварио је WER од 43,08%, што представља разлику од свега 0,13 процентних поена у односу на FP32 конфигурације. На посматраном скупу ова разлика је веома мала, што указује да INT8 формат није довео до већег погоршања просечне тачности транскрипције.

Овај резултат је посебно значајан за методолошко тумачење поређења. При коришћењу различитих подразумеваних параметара декодирања основни Whisper и Faster-Whisper могу дати различите WER вредности иако користе исту породицу модела. Након експлицитног усклађивања параметара, Whisper Base FP32 и Faster-Whisper Base FP32 остварили су идентичан просечан WER. Према томе, разлика која је могла бити уочена при поређењу подразумеваних конфигурација не може се приписати само CTranslate2 имплементацији, већ је неопходно контролисати и стратегију декодирања.

Знатно већа разлика уочена је у времену извршавања. Whisper Base FP32 имао је просечно време транскрипције од 21,72 s, док је Faster-Whisper Base FP32 исти скуп обрађивао за просечно 6,85 s. Faster-Whisper Base INT8 био је најбржи, са просечним временом од 4,59 s. На основу ових вредности, Faster-Whisper FP32 је у просеку био приближно 3,17 пута бржи од основног Whisper-а, док је Faster-Whisper INT8 био

приближно 4,73 пута бржи. Поређење две Faster-Whisper конфигурације показује да INT8 додатно смањује време извршавања у односу на FP32, уз веома малу промену просечног WER-а.

Добијени резултати омогућавају одвојено посматрање два ефекта. Поређење Whisper FP32 и Faster-Whisper FP32 показује ефекат различите имплементације при истој величини модела и истој нумеричкој прецизности, док поређење Faster-Whisper FP32 и Faster-Whisper INT8 омогућава посматрање додатног ефекта INT8 начина извршавања. У контролисаним условима CTranslate2 имплементација доноси изражено смањење времена обраде без промене просечног WER-а у FP32 поређењу, док INT8 доноси додатно убрзање уз разлику од 0,13 процентних поена у просечном WER-у.

6.3. Анализа потрошње меморије

Меморијска захтевност измерена је поступком описаним у поглављу 5.4, при чему је свака конфигурација покретана у засебном Python процесу и мерена у три независна понављања. За контролни аудио запис коришћен је 37govornik2.wav, а параметри декодирања били су усклађени са поставком из поглавља 6.1. Као главна метрика коришћена је просечна максимална вредност RSS-а.

Табела 6.3. Просечна максимална вредност RSS-а у директном поређењу Whisper и Faster-Whisper система

Конфигурација	Број понављања	Просечна максимална вредност RSS-а [MB]	SD [MB]
Whisper Base FP32	3	1050,92	73,28
Faster-Whisper Base FP32	3	693,22	0,97
Faster-Whisper Base INT8	3	494,15	0,33

Резултати показују јасну разлику у меморијској захтевности три анализиране конфигурације. Whisper Base FP32 остварио је просечну максималну вредност RSS-а од 1050,92 ± 73,28 MB. Faster-Whisper Base FP32 остварио је 693,22 ± 0,97 MB, док је најнижа вредност измерена код Faster-Whisper Base INT8 конфигурације и износила је 494,15 ± 0,33 MB. У односу на Whisper Base FP32, Faster-Whisper Base FP32 имао је приближно 34,04% мању просечну максималну вредност RSS-а, иако обе конфигурације користе Base модел и 32-битни начин израчунавања. Овај резултат указује на мању меморијску захтевност CTranslate2 имплементације у условима коришћеним у овом експерименту. Прелазак на Faster-Whisper Base INT8 додатно је смањио меморијску захтевност. У односу на Whisper Base FP32, просечна максимална вредност RSS-а била је мања за приближно 52,98%. Поређењем две Faster-Whisper конфигурације види се и додатни ефекат INT8 начина извршавања: максимална вредност RSS-а је смањена са 693,22 MB код FP32 на 494,15 MB код INT8 конфигурације.

Код Whisper конфигурације забележена је већа варијабилност између три понављања, са стандардном девијацијом од 73,28 MB, док су код Faster-Whisper FP32 и

INT8 конфигурација стандардне девијације износиле 0,97 MB и 0,33 MB. Због тога се резултати приказују као средња вредност и стандардна девијација, а не као појединачно меморијско мерење. Важно је поновити да RSS представља меморијску заузетост целог процеса током мерења, а не само величину тежина модела, као што је детаљније описано у поглављу 5.4.

6.4. Анализа резултата према трајању и говорницима

Просечне вредности приказане у поглављу 6.2 дају општу слику перформанси система, али не показују да ли се конфигурације једнако понашају за различита трајања аудио записа и различите говорнике. Због тога су резултати контролисаног експеримента додатно груписани према ове две карактеристике.

Анализа према трајању аудио записа

Главни скуп од 40 аудио записа читаног говора подељен је на четири групе према трајању: 10 кратких, 15 средњих, 10 дугих и 5 веома дугих снимака. Просечно трајање ових група износило је 6,96 s, 15,35 s, 31,83 s и 71,66 s, редом. Резултати WER-а и времена извршавања по групама приказани су у Табели 6.4.

Табела 6.4. Резултати према трајању аудио записа

Група	Број	Просечно трајање [s]	WER Whisper [%]	WER FW INT8 [%]	WER FW FP32 [%]	Време Whisper [s]	Време INT8 [s]	Време FP32 [s]
Кратки	10	6,96	43,18	45,99	43,18	6,820	1,630	2,388
Средњи	15	15,35	38,35	36,03	38,35	12,634	2,335	3,737
Дуги	10	31,83	51,82	53,01	51,82	29,771	5,873	9,098
Веома дуги	5	71,66	38,52	38,52	38,52	62,652	14,726	20,648

Резултати показују да Whisper и Faster-Whisper FP32 остварују идентичне просечне WER вредности у свакој од четири групе трајања. Овај резултат је у складу са укупним поређењем из поглавља 6.2 и додатно потврђује да, након усклађивања параметара декодирања, промена имплементације са основног Whisper-а на Faster-Whisper FP32 није довела до промене квалитета транскрипције на коришћеном скупу. Код INT8 конфигурације уочене су мале разлике које зависе од групе. За кратке снимке WER износи 45,99%, у односу на 43,18% код две FP32 конфигурације. Код средњих снимака INT8 остварује нижи WER од 36,03%, у поређењу са 38,35% код Whisper и Faster-Whisper FP32 конфигурације. Код дугих снимака INT8 има WER од 53,01%, док друге две конфигурације остварују 51,82%. За веома дуге снимке све три конфигурације остварују идентичан просечан WER од 38,52%. Ови резултати не показују систематско побољшање или погоршање тачности услед INT8 начина извршавања. У зависности од конкретне групе снимака, INT8 може остварити нешто нижи или нешто виши WER, док је на нивоу целог скупа разлика у односу на FP32 конфигурације свега 0,13 процентних поена.

Знатно израженије разлике постоје у времену извршавања. Faster-Whisper INT8 има најкраће просечно време у све четири групе. Код кратких снимака просечно време смањено је са 6,820 s код Whisper-а на 1,630 s код INT8 конфигурације. Код средњих снимака одговарајуће вредности износе 12,634 s и 2,335 s, док су код дугих снимака 29,771 s и 5,873 s. Код веома дугих снимака Whisper просечно захтева 62,652 s, Faster-Whisper FP32 20,648 s, а Faster-Whisper INT8 14,726 s. Пошто апсолутно време извршавања природно расте са трајањем аудио записа, за поређење ефикасности различитих група додатно је анализиран RTF. Резултати су приказани у Табели 6.5.

Табела 6.5. Просечан RTF према трајању аудио записа

Група	Whisper	Faster-Whisper INT8	Faster-Whisper FP32
Кратки	1,003	0,240	0,353
Средњи	0,832	0,154	0,246
Дуги	0,942	0,187	0,287
Веома дуги	0,879	0,206	0,289

Faster-Whisper INT8 остварује најнижи просечан RTF у све четири групе трајања. Faster-Whisper FP32 такође има знатно нижи RTF од Whisper-а у свакој групи. Ово показује да предност Faster-Whisper имплементације у брзини није ограничена само на одређену дужину аудио записа, већ је присутна код кратких, средњих, дугих и веома дугих снимака у коришћеном тест скупу. Посебно је значајно да је код кратких снимака просечан RTF Whisper-а приближно 1,003, док Faster-Whisper INT8 остварује 0,240. Са повећањем трајања снимака Whisper остварује RTF мањи од 1, али Faster-Whisper конфигурације задржавају знатно ниже вредности. Све Faster-Whisper групне вредности налазе се испод 1, што показује да је обрада у просеку бржа од реалног трајања аудио материјала.

Анализа према говорницима

Други део анализе односи се на разлике између три говорника. Први и други говорник заступљени су са по 13 снимака, док трећи говорник има 14 снимака. Резултати су приказани у Табели 6.6.

Табела 6.6. Просечан WER према говорнику

Говорник	Број снимака	Whisper [%]	Faster-Whisper INT8 [%]	Faster-Whisper FP32 [%]
Говорник 1	13	46,15	45,39	46,15
Говорник 2	13	25,50	25,68	25,50
Говорник 3	14	56,17	57,09	56,17

Резултати показују изражене разлике у WER вредностима између говорника. Најнижи просечан WER остварен је код другог говорника, где Whisper и Faster-Whisper FP32 имају WER од 25,50%, а Faster-Whisper INT8 25,68%. Код првог говорника WER износи 46,15% за Whisper и Faster-Whisper FP32, односно 45,39% за INT8 конфигурацију. Највеће вредности добијене су код трећег говорника: 56,17% за две FP32 конфигурације и 57,09% за INT8. Разлике између говорника знатно су веће од разлика између три конфигурације за истог говорника. На пример, код Whisper-а разлика између другог и трећег говорника износи више од 30 процентних поена, док су разлике између FP32 и INT8 конфигурације унутар појединачног говорника мање од једног процентног поена. То показује да су разлике у WER-у између група снимака различитих говорника у овом експерименталном скупу знатно веће од разлика између FP32 и INT8 конфигурације унутар истих група. Међутим, пошто говорници нису изговарали идентичан скуп реченица, ове разлике се не могу приписати искључиво карактеристикама самих говорника. Када су параметри декодирања усклађени, промена имплементације није довела до промене просечне тачности ни на нивоу целог скупа, ни приликом груписања резултата према говорнику. Укупно посматрано, анализа према трајању и говорницима не мења закључке основног поређења. Разлике између FP32 и INT8 конфигурација у тачности остају мале и нису једносмерне у свим подгрупама, док Faster-Whisper конфигурације остварују краће време обраде у свим анализираним групама трајања.

7. ЕКСПЕРИМЕНТАЛНА АНАЛИЗА И ОПТИМИЗАЦИЈА FASTER-WHISPER СИСТЕМА

Након основног поређења Whisper и Faster-Whisper система, у овом поглављу анализирају се фактори који могу да утичу на рад Faster-Whisper модела. Овде се испитује како избор величине модела, услови улазног аудио сигнала и различита подешавања система утичу на тачност и брзину транскрипције.

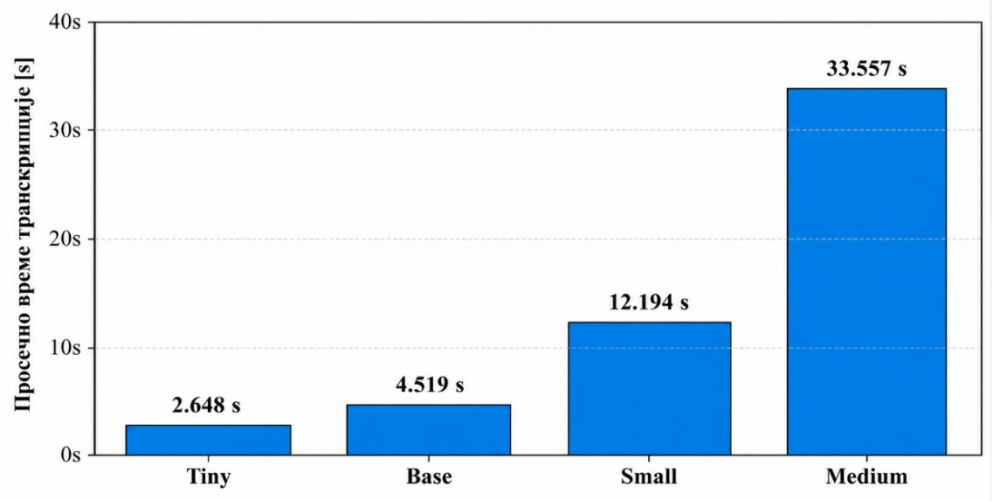
7.1. Утицај величине модела на резултате

Whisper је доступан у више величина које се разликују по броју параметара и рачунарским захтевима. Због тога је један од првих корака оптимизације био да се утврди колико повећање величине модела стварно доприноси тачности препознавања српског говора и колико се тиме повећава време обраде. У овом експерименту анализиране су четири Faster-Whisper варијанте: Tiny, Base, Small и Medium. За тестирање је изабрано 20 снимака читаног говора на српском језику из главног скупа. Подскуп је формиран тако да садржи по пет кратких, средњих, дугих и веома дугих снимака. Сви модели тестирани су над истим аудио записима и под истим условима декодирања, чиме је омогућено контролисано поређење перформанси различитих величина модела [6]. За све четири величине модела коришћен је INT8 тип израчунавања на CPU-у, са подразумеваном вредношћу параметра *beam_size = 5* и искљученом детекцијом говорне активности.

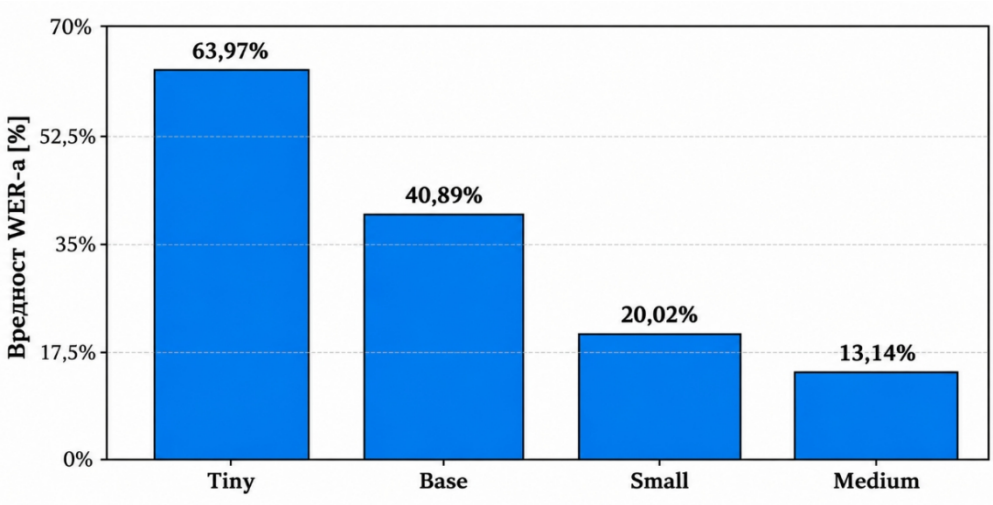
За сваку конфигурацију мерени су просечан WER, медијана WER-а, просечно и укупно време транскрипције и просечан RTF. Добијени резултати приказани су у Табели 7.1 и на сликама 7.1 и 7.2.

Табела 7.1. Утицај величине Faster-Whisper модела

Модел	Број снимака	Просечан WER [%]	Медијана WER [%]	Просечно време [s]	Укупно време [s]	Просечан RTF
Tiny	20	63,97	66,54	2,648	52,963	0,0871
Base	20	40,89	40,36	4,519	90,377	0,1405
Small	20	20,02	19,68	12,194	243,875	0,3907
Medium	20	13,14	8,17	33,557	671,142	1,0452



Слика 7.1. Утицај величине модела на време транскрипције



Слика 7.2. Утицај величине модела на тачност транскрипције

Резултати показују веома јасну везу између величине модела и тачности транскрипције. Tiny модел има највећи просечан WER од 63,97%, док Base смањује ову вредност на 40,89%. Још већа промена добијена је код Small модела, са просечним WER-ом од 20,02%, док је Medium остварио најнижу вредност од 13,14%. Прелазак са Tiny на Base тако смањује просечан WER за 23,08 процентних поена, са Base на Small за додатних 20,87 процентних поена, а са Small на Medium за још 6,88 процентних поена. На посматраном подскупу повећање величине модела доследно је доводило до ниже вредности WER-а, при чему се додатни добитак у тачности постепено смањивао.

Са друге стране, повећање величине модела знатно повећава време обраде. Tiny моделу је у просеку било потребно само 2,648 s, Base моделу 4,519 s, Small моделу 12,194 s, а Medium моделу чак 33,557 s по снимку. Medium је тако у просеку био око 12,7 пута спорији од Tiny и око 2,75 пута спорији од Small модела. Исти однос видљив је код RTF

метрике. Tiny има просечан RTF од само 0,0871, Base 0,1405, а Small 0,3907. Све три вредности су знатно испод 1, што показује да су ови модели у просеку обрађивали аудио брже од његовог реалног трајања. Medium модел има просечан RTF од 1,0452, што значи да му је на посматраном скупу у просеку било потребно приближно онолико времена колико траје сам аудио, односно нешто више. Са становишта CPU примене у реалном времену, ова разлика је практично важна.

Резултати према групама трајања додатно потврђују да Small модел даје добар однос између тачности и времена. Његов просечан WER износи 15,46% за кратке, 27,21% за средње, 17,61% за дуге и 19,79% за веома дуге снимке, док се просечан RTF креће од 0,339 до 0,472. Medium је у већини група тачнији, али је његов RTF знатно већи и код више група се приближава или прелази вредност 1. Код Medium модела уочен је и један изражен појединачни резултат на снимку 36govornik1.wav. За овај снимак измерено је време од 102,45 s, RTF од 1,4845 и WER од 100%. Остали веома дуги снимци код истог модела имају знатно нижи WER, па се овај резултат издваја у односу на остале снимке. Пошто је укључен у израчунате просеке, није накнадно уклањан из анализе. Истовремено, показује зашто је поред просечног WER-а корисно посматрати и медијану, која код Medium модела износи само 8,17%.

Резултати показују да повећање величине модела доноси јасно побољшање тачности, али уз раст времена обраде и RTF-а. Medium пружа најбољу тачност, али уз знатно веће време обраде, док је Tiny веома брз, али са високим WER-ом. У овом експерименту Small представља повољан компромис за CPU извршавање, јер смањује просечан WER на око 20%, док просечан RTF остаје испод 0,4. Овај закључак се у овом тренутку односи само на однос величине модела и перформанси. Коначни избор конфигурације не доноси се на основу једног експеримента, већ се касније повезује са резултатима квантизације, меморијске потрошње и осталих параметара.

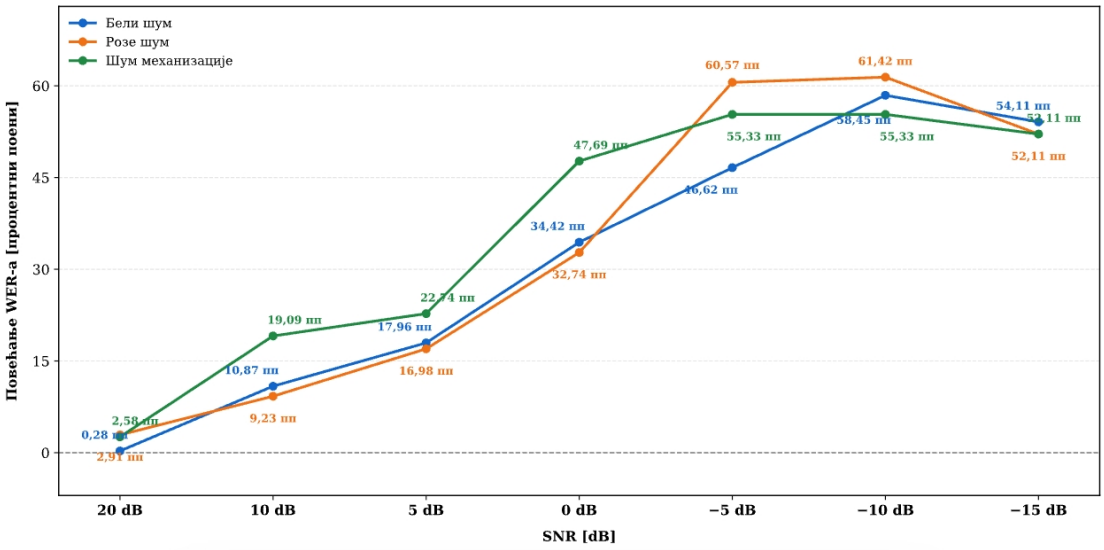
7.2. Утицај позадинског шума и SNR вредности

Препознавање говора у реалним условима често се не врши над аудио сигналом без шума. Разговор може бити снимљен у присуству саобраћаја, рада различитих уређаја, амбијенталног шума или других извора звука. Због тога је у другом експерименту испитана отпорност Faster-Whisper система на контролисано додавање позадинског шума.

За овај експеримент изабрано је 10 аудио записа читаног говора са три говорника. На сваки оригинални снимак додаване су три врсте шума: бели, розе и снимљени шум пољопривредне механизације. За све три врсте коришћено је седам SNR нивоа: 20, 10, 5, 0, −5, −10 и −15 dB. SNR описује однос снаге корисног говорног сигнала и шума, при чему више вредности означавају повољније услове за препознавање говора. Оригинални снимци без додатог шума коришћени су као основа за поређење. Од 10 оригиналних снимака формирано је 210 варијанти са шумом, што са оригиналним снимцима даје укупно 220 транскрипција. За транскрипцију је коришћен Faster-Whisper Base модел са INT8 типом израчунавања на CPU-у, са подразумеваном вредношћу параметра *beam_size = 5* и искљученом детекцијом говорне активности (VAD). Просечан WER оригиналних снимака износио је 47,89%. Резултати су приказани у Табели 7.2 и на Слици 7.3.

Табела 7.2. Просечан WER и његово повећање у односу на снимке без шума при различитим SNR вредностима

SNR [dB]	Бели WER	Розе WER	Механ. WER	Δ бели	Δ розе	Δ механ.
Без шума	47,89	47,89	47,89	—	—	—
20	48,16	50,80	50,47	+0,28	+2,91	+2,58
10	58,75	57,12	66,98	+10,87	+9,23	+19,09
5	65,84	64,86	70,63	+17,96	+16,98	+22,74
0	82,31	80,62	95,58	+34,42	+32,74	+47,69
−5	94,51	108,46	107,70	+46,62	+60,57	+59,82
−10	106,33	109,30	103,21	+58,45	+61,42	+55,33
−15	102,00	100,00	100,00	+54,11	+52,11	+52,11



Слика 7.3. Деградација тачности у односу на сигнал без шума

При SNR вредности од 20 dB утицај додатог шума на тачност транскрипције релативно је мали. Просечан WER оригиналних снимака износи 47,89%, док су након додавања белог, розе и шума пољопривредне механизације добијене вредности од 48,16%, 50,80% и 50,47%. У односу на сигнал без додатог шума, повећање WER-а износи 0,28, 2,91 и 2,58 процентних поена. Ови резултати показују да модел при повољном односу сигнал-шум задржава приближно исти ниво тачности, независно од испитиване врсте шума.

Смањивањем SNR вредности на 10 dB разлике постају израженије. Просечан WER износи 58,75% код белог, 57,12% код розе и 66,98% код шума механизације. При 5 dB вредности достижу 65,84%, 64,86% и 70,63%. У оба случаја највећа стопа грешке забележена је код шума механизације, што указује да је испитивани снимак рада трактора

имао израженији негативан утицај на препознавање говора него генерисани бели и розе шум при наведеним SNR вредностима.

При SNR вредности од 0 dB, када су снаге говорног сигнала и додатог шума приближно једнаке, деградација постаје веома изражена. Просечан WER износи 82,31% за бели, 80,62% за розе и 95,58% за шум механизације. У односу на оригиналне снимке, повећање износи 34,42, 32,74 и 47,69 процентних поена. На овом нивоу шум механизације остварио је највећи негативан утицај на тачност транскрипције, са WER-ом већим за 13,27 процентних поена у односу на бели и 14,96 процентних поена у односу на розе шум.

На негативним SNR вредностима долази до веома великог погоршања тачности код све три врсте шума. При −5 dB просечан WER износи 94,51% за бели, 108,46% за розе и 107,70% за шум механизације. При −10 dB добијене су вредности од 106,33%, 109,30% и 103,21%, док на −15 dB WER износи 102,00%, 100,00% и 100,00%. Резултати показују да при веома неповољним односима сигнал-шум модел губи способност поузданог препознавања изговореног садржаја, без обзира на испитивану врсту шума.

Вредности WER-а веће од 100% могуће су када укупан број замена, изостављања и уметања речи премаши број речи у референтном транскрипту. При веома јаком шуму модел може генерисати погрешан текст који није подржан говорним садржајем, али и веома кратке или празне транскрипције. Због тога смањење WER-а са 109,30% на −10 dB на 100,00% при −15 dB код розе шума не треба тумачити као стварно побољшање препознавања. За поуздано утврђивање узрока оваквог понашања потребно је анализирати појединачне транскрипте и структуру грешака. Могућност појаве халуцинација код Whisper модела разматрана је и у претходним истраживањима [21], [22].

Поред тачности, уочене су и разлике у времену транскрипције. При 20 dB просечно време обраде износи 5,371 s за бели, 5,472 s за розе и 5,419 s за шум механизације. При −10 dB ове вредности расту на 30,452 s, 32,971 s и 22,452 s. Повећање времена обраде при јаком шуму указује на то да деградација улазног сигнала у појединим случајевима може да утиче и на трајање процеса декодирања. Међутим, зависност није монотона, па је потребно узети у обзир разлике у генерисаним транскриптима и појединачним снимцима.

Поређење три врсте шума показује да ниједна није доследно најнеповољнија на свим SNR нивоима. Шум механизације доводи до највећег WER-а при 10, 5 и 0 dB, док на −5 и −10 dB розе шум има нешто веће вредности. Ово указује да, поред односа сигнал-шум, спектралне и временске карактеристике додатог шума могу утицати на понашање ASR модела. Ипак, пошто је за механизацију коришћен један конкретан снимак рада трактора, добијени резултати не могу се уопштити на све типове пољопривредних машина.

Резултати по говорницима такође показују разлике, али број снимака по говорнику није једнак: четири припадају првом, два другом и четири трећем говорнику. Због ограниченог броја снимака није оправдано изводити опште закључке о отпорности говора појединачних говорника на шум. У целини, експеримент показује да је однос сигнал-шум један од најважнијих фактора за тачност препознавања, док тип шума може додатно утицати на степен деградације. Увођењем снимљеног шума пољопривредне механизације

анализа је проширена са генерисаних шумова на један пример стварног акустичког окружења релевантног за пољопривредни домен.

7.3. Поређење српског и енглеског говора на FLEURS скупу

Whisper је вишејезички модел, али количина и структура података на којима је обучаван нису једнаке за све језике. Због тога је у овом експерименту испитано како се иста Faster-Whisper конфигурација понаша приликом транскрипције српског и енглеског говора [5].

За потребе експеримента коришћен је вишејезички говорни скуп FLEURS [13]. Из његовог тестног дела издвојено је 30 снимака српског (sr_rs) и 30 снимака енглеског (en_us) језика. Избор снимака извршен је програмски, уз фиксно почетно стање генератора случајних бројева. За оба језика примењен је Faster-Whisper Base INT8 модел на CPU-у, са истим параметрима декодирања: *beam_size = 5*, *temperature = 0,0* и искљученом VAD обрадом. Језик транскрипције задаван је експлицитно за сваки узорак. За процену тачности коришћени су просечан WER, медијана WER-а, WER на нивоу корпуса и CER, док су перформансе извршавања анализиране на основу времена транскрипције и RTF вредности. Пре израчунавања метрика примењена је нормализација референтних и добијених транскрипата, укључујући пресловљавање српске ћирилице у латиницу.

Табела 7.3. Поређење резултата Faster-Whisper Base INT8 модела на српском и енглеском говору

Метрика	Енглески	Српски
Број снимака	30	30
Просечан WER [%]	9,97	57,46
Медијана WER [%]	7,14	59,00
WER на нивоу корпуса [%]	9,85	55,99
Просечан CER [%]	3,63	15,86
Просечно трајање снимка [s]	9,674	11,672
Просечно време транскрипције [s]	1,388	1,582
Просечан RTF	0,151	0,142

Добијени резултати показују изражену разлику у тачности транскрипције између два испитивана језичка узорка. Просечан WER за енглески језик износи 9,97%, док је за српски забележено 57,46%, што представља разлику од 47,49 процентних поена. Сличан однос добијен је и на нивоу корпуса, где WER износи 9,85% за енглески и 55,99% за српски језик. Медијана WER-а износи 7,14% за енглески и 59,00% за српски, што потврђује да уочена разлика није последица искључиво малог броја снимака са изразито високим грешкама. Додатно, просечан CER износи 3,63% за енглески и 15,86% за српски језик, што показује да се разлика у тачности јавља и на нивоу карактера.

У погледу брзине извршавања, просечно време транскрипције енглеских снимака износи 1,388 s, а српских 1,582 s. Међутим, просечно трајање српских снимака је веће, па је за ту групу добијен нешто нижи просечан RTF од 0,142, у односу на 0,151 за енглески језик. Ови резултати указују да је модел у обе групе обрађивао снимке брже од њиховог стварног трајања, при чему разлике у времену извршавања треба посматрати заједно са разликама у дужини аудио записа.

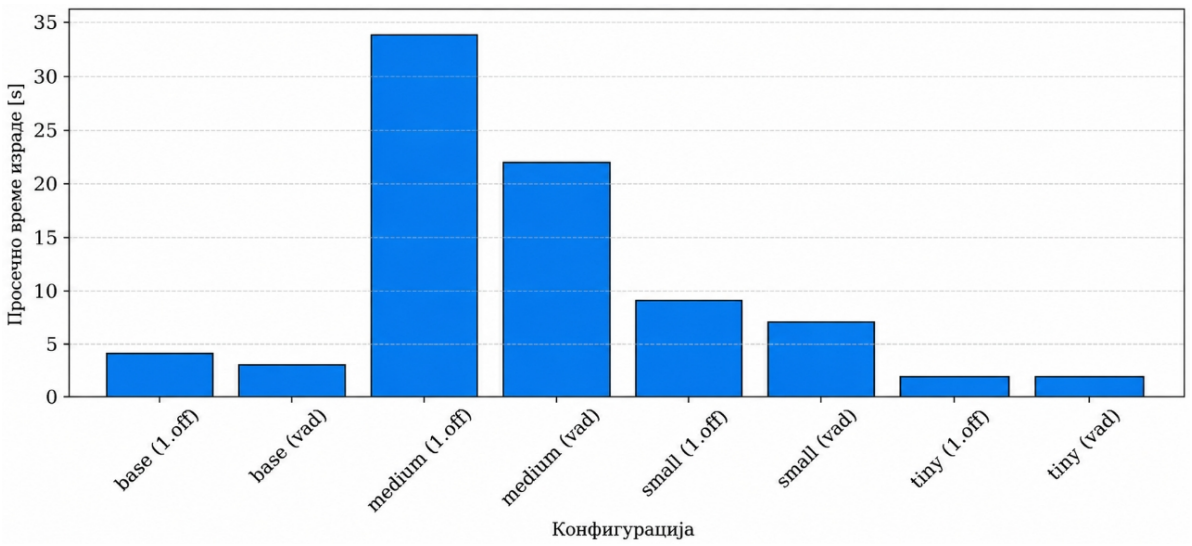
Иако су за оба језика коришћени исти модел и параметри транскрипције, резултате не треба тумачити као потпуно изолован ефекат језика. Узорак обухвата по 30 снимака из скупа FLEURS, а разлике у говорницима, акцентима, акустичким карактеристикама и садржају снимака могу утицати на добијене вредности. Избор записа на основу заједничких нумеричких идентификатора не представља сам по себи потврду да су одговарајући српски и енглески снимци преводно еквивалентни. Зато резултати представљају поређење перформанси на два изабрана језичка узорка, а не општу процену разлике у квалитету препознавања енглеског и српског говора. У оквиру испитаних услова Faster-Whisper Base INT8 остварио је знатно нижу стопу грешке на енглеском узорку, што додатно указује на значај истраживања препознавања српског говора.

7.4. Утицај параметра *beam size*

Следећи експеримент испитује утицај параметра *beam size* на тачност и брзину транскрипције. За разлику од претходног експеримента, овде је коришћен читани говор на српском језику [1]. Из главног скупа изабрано је 15 репрезентативних снимака различитих трајања и говорника. У свим тестовима коришћен је Faster-Whisper Base INT8 модел, док је мењана само вредност параметра *beam size*. Испитане су вредности 1, 3, 5 и 10. Оваква поставка омогућава директнију анализу утицаја параметра *beam size*, јер су модел, аудио записи, језик и остали основни услови остали исти. Резултати су приказани у Табели 7.4 и на слици 7.4.

Табела 7.4. Утицај параметра *beam size*

Beam size	**Просечан WER [%]**	**Медијана WER [%]**	**WER на нивоу корпуса [%]**	**Просечно време [s]**	**Просечан RTF**
1	49,09	51,85	49,03	2,499	0,1076
3	44,48	48,15	43,48	3,276	0,1218
5	43,17	48,15	43,00	4,045	0,1425
10	43,76	48,15	42,39	6,439	0,1988



Слика 7.4. Просечно време транскрипције по конфигурацији

Најједноставнија конфигурација, *beam_size = 1*, била је најбржа, са просечним временом транскрипције од 2,499 s и RTF вредношћу од 0,1076. Међутим, истовремено је имала и највећи просечан WER од 49,09%. Повећањем вредности на 3 просечан WER се смањује на 44,48%, односно за 4,61 процентни поен у односу на *beam_size = 1*. Просечно време расте на 3,276 s, што представља приближно 1,31 пута дуже извршавање. Најнижи просечан WER добијен је за *beam_size = 5* и износи 43,17%. То представља побољшање од 5,92 процентна поена у односу на вредност 1. Просечно време транскрипције износи 4,045 s, односно извршавање је око 1,62 пута спорије него код *beam_size = 1*. Повећање на *beam_size = 10* није наставило побољшање просечног WER-а. Он износи 43,76%, што је нешто лошије од 43,17% добијених код вредности 5. Истовремено, просечно време расте на 6,439 s, што је приближно 2,58 пута дуже него код вредности 1. WER на нивоу корпуса показује нешто другачију слику. Његова најнижа вредност од 42,39% добијена је код *beam_size = 10*, у односу на 43,00% код вредности 5. Разлика износи само 0,61 процентни поен, док је време обраде код *beam_size = 10* око 59% веће него код вредности 5. Због тога резултати показују да повећање параметра *beam_size* до одређене мере доноси изражено побољшање просечног WER-а, али да даље повећање има све мањи ефекат. На овом тест скупу *beam_size = 5* даје најнижи просечан WER и повољнији однос тачности и брзине, док *beam_size = 10* остварује најнижи WER на нивоу корпуса уз знатно већи временски трошак.

Важно је и да су све четири конфигурације имале просечан RTF знатно испод 1. Повећање параметра *beam size*, дакле, није онемогућило обраду бржу од реалног времена на овом скупу, али је постепено повећавало рачунарски трошак. Ови резултати ће касније бити употребљени приликом избора конфигурације. При томе се не посматра само конфигурација са најнижом грешком, већ однос између побољшања WER-а и додатног времена потребног за декодирање.

7.5. Утицај квантизације на перформансе

Након анализе величине модела и параметра *beam size*, испитан је утицај INT8 квантизације на перформансе Faster-Whisper система. Циљ овог експеримента био је да се утврди колико INT8 начин израчунавања може да смањи време обраде и RTF у односу на FP32 и да ли ефекат зависи од величине модела [2]. За експеримент је коришћено свих 40 српских аудио записа читаног говора. Испитана су четири модела (Tiny, Base, Small и Medium) у две варијанте, INT8 и FP32. На тај начин добијено је осам конфигурација, а свака је тестирана на истих 40 снимака. Укупно је извршено 320 транскрипција.

Основни параметри декодирања били су исти за све конфигурације: CPU извршавање, српски језик, *beam_size = 1*, температура 0 и искључен VAD. Пре мерења вршено је иницијално загревање модела (енгл. *warm-up*) како би се умањио утицај иницијалног покретања на резултате. У овом експерименту задржана је вредност *beam_size = 1*, јер је циљ био изоловано поређење временских и меморијских захтева INT8 и FP32 начина извршавања при истој минималној сложености декодирања; избор параметра *beam size* разматран је засебно у поглављу 7.4.

Табела 7.5. Поређење INT8 и FP32 начина израчунавања

Модел	INT8 време [s]	FP32 време [s]	Убрзање INT8	INT8 RTF	FP32 RTF	Смањење времена [%]
Tiny	1,453	1,945	1,34×	0,073	0,095	25,30
Base	2,590	3,581	1,38×	0,127	0,178	27,67
Small	7,321	10,876	1,49×	0,351	0,514	32,69
Medium	22,271	33,955	1,52×	1,061	1,659	34,41

Резултати показују да је INT8 формат био бржи од FP32 код све четири испитане величине модела. Степен убрзања није био исти за све моделе, али је код сваке анализиране величине забележено смањење просечног времена транскрипције. Код Tiny модела просечно време транскрипције смањено је са 1,945 s на 1,453 s, што представља смањење од 25,30% и убрзање од приближно 1,34 пута. Код Base модела време је смањено са 3,581 s на 2,590 s, односно за 27,67%, уз убрзање од приближно 1,38 пута. Код Small модела просечно време транскрипције смањено је са 10,876 s на 7,321 s, што представља смањење од 32,69% и убрзање од приближно 1,49 пута. Највеће релативно смањење времена у овом експерименту добијено је код Medium модела. Просечно време смањено је са 33,955 s на 22,271 s, односно за 34,41%, при чему је INT8 варијанта била приближно 1,52 пута бржа од FP32 варијанте.

Вредности RTF-а показују исти тренд. Код Tiny модела просечан RTF смањен је са 0,095 на 0,073, код Base модела са 0,178 на 0,127, а код Small модела са 0,514 на 0,351. Код Medium модела RTF је смањен са 1,659 на 1,061. Иако INT8 знатно смањује време извршавања Medium модела, његов просечан RTF и даље остаје нешто изнад 1, што значи да ова конфигурација на коришћеном CPU окружењу у просеку није постигла обраду бржу од реалног трајања аудио сигнала.

Поред времена извршавања и RTF-а, меморијска захтевност конфигурација испитана је независним мерењем максималне вредности RSS-а. За разлику од мерења у главној Jupyter петљи, свака комбинација величине модела и типа квантизације покренута је у засебном Python процесу, чиме је избегнут утицај претходно учитаних модела, кеша и заосталих меморијских алокација. За сваку од осам конфигурација извршена су три независна понављања над истим контролним аудио записом, а као главна меморијска метрика коришћена је просечна максимална вредност RSS-а, уз приказ стандардне девијације.

Добијени резултати показују систематски мању меморијску потрошњу INT8 конфигурација. За Tiny модел просечна максимална вредност RSS-а смањена је са 519,52 ± 0,82 MB на 416,30 ± 0,71 MB, за Base са 693,01 ± 0,47 MB на 493,11 ± 0,63 MB, за Small са 1424,32 ± 2,17 MB на 853,59 ± 6,87 MB, а за Medium са 3334,86 ± 57,82 MB на 1917,02 ± 4,82 MB. Посматрано релативно, INT8 је смањио максималну вредност RSS-а приближно за 19,9% код Tiny, 28,8% код Base, 40,1% код Small и 42,5% код Medium модела. Резултати показују да је меморијска корист INT8 квантизације била израженија код већих модела.

Ово мерење представља засебан експеримент у односу на директно поређење из поглавља 6, па се добијене вредности не очекују као нумерички идентичне, иако су по реду величине веома блиске.

У овој фази анализе примарни фокус био је на времену извршавања, RTF-у и меморијској захтевности. WER је накнадно израчунат за свих 320 сачуваних транскрипција и укључен у интеграциону вишекритеријумску анализу у поглављу 8. На тај начин су у завршној вишекритеријумској анализи за сваку конфигурацију заједно посматрани WER, RTF и поузданије измерена максимална вредност RSS-а.

У комбинацији са резултатима анализе величине модела, Small INT8 се издваја као један од кандидата за даљу вишекритеријумску анализу, јер Small модел остварује знатно нижи WER од Base и Tiny варијанти, док INT8 смањује време извршавања и меморијску захтевност у односу на FP32 варијанту исте величине.

7.6. Утицај детекције говорне активности (VAD)

У практичним аудио записима говор није увек непрекидан, већ се између речи и реченица јављају паузе различитог трајања. Обрада таквих делова не доноси корисне информације за транскрипцију, па је у овом експерименту испитано да ли употреба Voice Activity Detection (VAD) алгоритма може да смањи време обраде без погоршања тачности препознавања [19]. Експеримент је изведен коришћењем Faster-Whisper Base INT8 модела на CPU-у. Формиране су две групе са по пет аудио записа. Прву групу чинило је пет синтетичких енглеских снимака генерисаних помоћу библиотеке gTTS, док је друга садржала пет српских снимака читаног говора из главног скупа којима су контролисано додате паузе како би се обезбедило присуство делова без говорне активности.

Сваки аудио запис транскрибован је у два режима: са искљученим VAD-ом (VAD OFF) и са укљученим VAD-ом (VAD ON). Време извршавања мерено је три пута по режиму како би се смањио утицај случајних варијација у времену обраде. Поред времена транскрипције посматрани су RTF и WER. Резултати су приказани у Табели 7.6.

Табела 7.6. Утицај примене VAD-а на две групе аудио записа

Скуп	VAD OFF време [s]	VAD ON време [s]	Убрзање	Смањење времена [%]	RTF OFF	RTF ON	WER OFF [%]	WER ON [%]	ΔWER [pp]
Синтетички EN	1,968	1,557	1,263×	20,85	0,061	0,048	7,58	6,37	−1,21
Читани SR	4,302	4,175	1,031×	2,96	0,080	0,078	66,28	65,80	−0,48

Код синтетичких енглеских снимака укључивање VAD-а смањило је просечно време обраде са 1,968 на 1,557 s, што представља смањење од 20,85%, односно убрзање од приближно 1,26 пута. Истовремено је просечан RTF смањен са 0,061 на 0,048. Код српских снимака читаног говора ефекат на брзину био је знатно мањи. Просечно време смањено је са 4,302 на 4,175 s, односно за 2,96%, док је RTF промењен са 0,080 на 0,078. VAD је, дакле, и у овој групи смањио време обраде, али је добитак био релативно мали. Посебно је важно проверити да ли је уклањање делова без говора довело до погоршања транскрипције. У овом експерименту то није био случај. Код синтетичког енглеског скупа просечан WER се променио са 7,58% на 6,37%, док је код српског скупа читаног говора промењен са 66,28% на 65,80%. Мала смањења WER-а од 1,21 и 0,48 процентних поена не треба тумачити као доказ да VAD сам по себи повећава способност Whisper модела да препозна говор. Вероватније је да уклањање одређених периода без говора у конкретним снимцима може да утиче на сегментацију и процес декодирања. За овај рад је важније да укључивање VAD-а није довело до приметног погоршања WER-а, док је истовремено смањено време обраде. Разлика између две групе такође показује да корист од VAD-а зависи од структуре аудио материјала. Уколико снимак садржи већи број или дуже периоде без говора, постоји више материјала који се може изоставити из обраде. Код готово непрекидног говора очекивани добитак је мањи.

Због тога се на основу овог експеримента не може тврдити да ће VAD увек донети убрзање од око 20%. Та вредност добијена је само за конкретан синтетички енглески скуп. Код српских снимака читаног говора добитак је био око 3%, што показује да ефекат зависи од карактеристика самог снимка. У оквиру испитаних услова VAD ON се показује као оправдан кандидат за укључивање у препоручену конфигурацију, јер је код обе групе забележено смањење времена без погоршања просечног WER-а.

7.7. Транскрипција у реалном времену

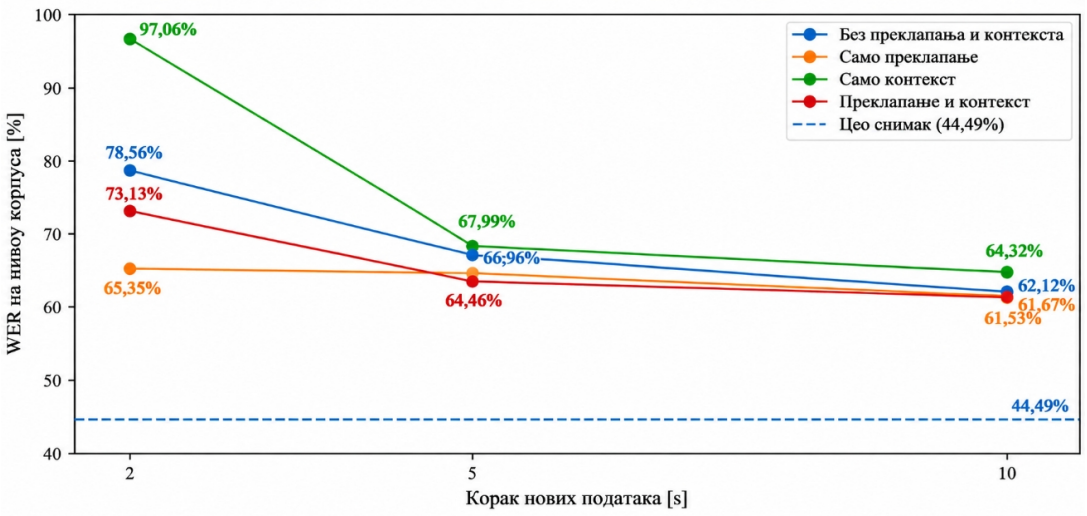
Последњи експеримент у овом поглављу односи се на анализу Faster-Whisper система у условима симулиране сегментне транскрипције у реалном времену. Уместо анализе целокупног записа одједном, у овом приступу сигнал се обрађује у деловима. Симулацијом пристизања нових сегмената на унапред снимљеним аудио записима праћени су време и карактеристике обраде.

Коришћено је пет најдужих српских снимака читаног говора из главног скупа, односно записи 36-40. За транскрипцију је коришћен Faster-Whisper Base INT8 модел на CPU-у, са параметром *beam_size = 1* и искљученом VAD обрадом. Испитани су кораци пристизања нових података од 2, 5 и 10 секунди, при чему су за сваки корак примењена четири режима: А - без преклапања и контекста, Б - само акустичко преклапање, В - само текстуални контекст и Г - комбинација преклапања и контекста. Акустичко преклапање износило је највише једну секунду, док је текстуални контекст обухватао највише осам последњих прихваћених речи. Код режима са преклапањем корак пристизања нових података остајао је 2, 5 или 10 секунди, али је улазни аудио сегмент могао трајати до 3, 6 или 11 секунди. При спајању транскрипата примењена су правила за спречавање понављања речи и издвајање текста који припада новом делу сигнала.

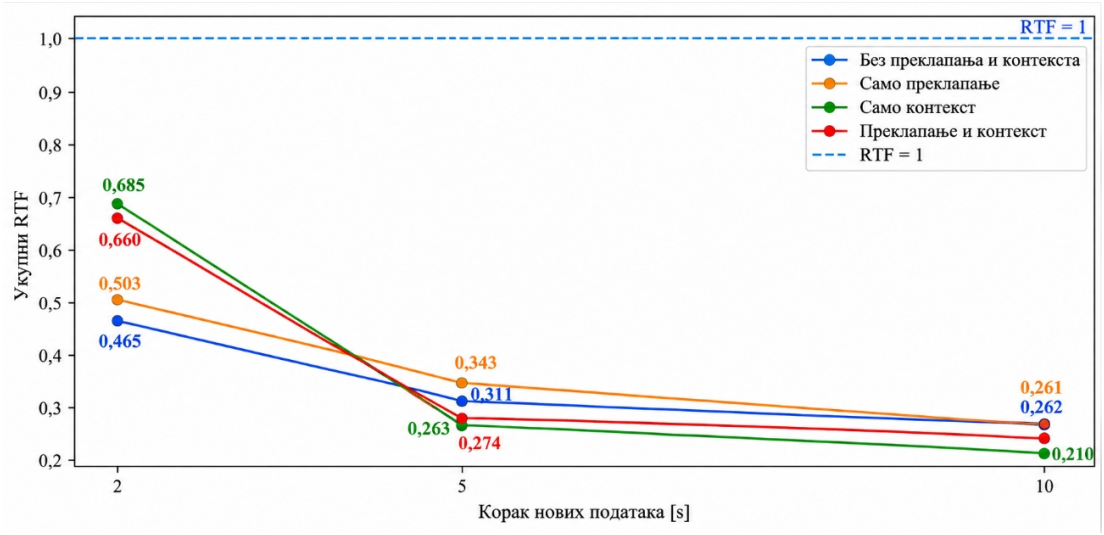
Главна метрика тачности сегментне обраде био је WER на нивоу корпуса, уз додатно праћење просечног WER-а, фактора реалног времена (RTF), процењеног времена до првог резултата (TTFR) и максималног кашњења реда чекања. Резултати су приказани у Табели 7.7.

Табела 7.7. Резултати симулације обраде у реалном времену

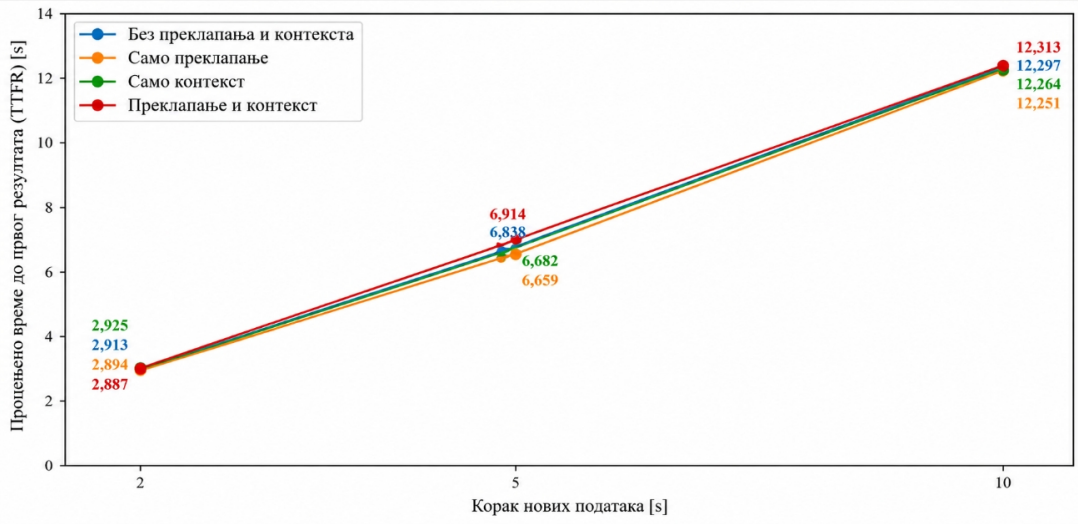
Корак [s]	Режим	WER корпуса [%]	RTF	TTFR [s]
2	А - без оба механизма	78,56	0,465	2,913
2	Б - преклапање	65,35	0,503	2,894
2	В - контекст	97,06	0,685	2,925
2	Г - оба механизма	73,13	0,660	2,887
5	А - без оба механизма	66,96	0,311	6,838
5	Б - преклапање	64,46	0,343	6,659
5	В - контекст	67,99	0,263	6,682
5	Г - оба механизма	63,58	0,274	6,914
10	А - без оба механизма	62,12	0,262	12,297
10	Б - преклапање	61,53	0,261	12,251
10	В - контекст	64,32	0,210	12,264
10	Г - оба механизма	61,67	0,241	12,313



Слика 7.5. Утицај корака обраде и режима коришћења контекста на WER на нивоу корпуса



Слика 7.6. Утицај корака обраде и режима коришћења контекста на RTF



Слика 7.7. Процењено време до првог резултата за различите кораке обраде и режиме

Резултати показују да на тачност сегментне транскрипције утичу и корак обраде и начин коришћења претходног акустичког и текстуалног контекста. Контролна транскрипција комплетних снимака остварила је WER на нивоу корпуса од 44,49%, док су све испитане конфигурације сегментне обраде имале већу стопу грешке.

При кораку од 2 секунде најнижи WER на нивоу корпуса остварен је применом само акустичког преклапања и износио је 65,35%. Без преклапања и текстуалног контекста WER је износио 78,56%, док је при примени само текстуалног контекста порастао на 97,06%. Комбинована примена оба механизма дала је WER од 73,13%. Ови резултати показују да акустичко преклапање може значајно да ублажи грешке на границама кратких сегмената, док пренос текстуалног контекста сам по себи није обезбедио побољшање тачности. При кораку од 5 секунди разлике између режима биле су мање. WER без оба механизма износио је 66,96%, применом само преклапања 64,46%, а само текстуалног контекста 67,99%. Најнижи WER од 63,58% остварен је комбинованом применом акустичког преклапања и текстуалног контекста. То указује да се при средњој дужини корака може остварити ограничена корист од истовремене примене оба механизма. При кораку од 10 секунди добијене су најниже вредности WER-а у целом експерименту. Без додатних механизама WER је износио 62,12%, са акустичким преклапањем 61,53%, са текстуалним контекстом 64,32%, а комбинованом применом 61,67%. Најбољи резултат остварен је режимом са акустичким преклапањем, али је разлика у односу на комбиновани режим износила свега око 0,14 процентних поена. У односу на контролни WER од 44,49%, најбоља сегментна конфигурација имала је повећање грешке од приближно 17,04 процентна поена.

Са становишта брзине, све испитане конфигурације остариле су укупан RTF мањи од један, што указује да је просечно време инференције било краће од трајања обрађеног аудио материјала. Најнижи RTF од 0,210 забележен је при кораку од 10 секунди и примени само текстуалног контекста, али ова конфигурација није имала најнижи WER.

Најтачнија конфигурација, са кораком од 10 секунди и акустичким преклапањем, остварила је RTF од 0,261.

Процењено време до првог резултата било је најкраће код корака од 2 секунде и кретало се приближно од 2,89 до 2,93 секунде, у зависности од режима. Код корака од 5 секунди вредности су биле приближно од 6,66 до 6,91 секунде, док су код корака од 10 секунди износиле од 12,25 до 12,31 секунде. Према томе, краћи кораци омогућавају ранији први резултат, али у испитаним условима доводе до веће стопе грешке.

Поређење режима показује да примена акустичког преклапања није увек доводила до истог степена побољшања, док је утицај текстуалног контекста био још променљивији. Посебно неповољан резултат режима са само текстуалним контекстом при кораку од 2 секунде указује на могућност преношења претходно погрешно препознатих речи у наредне кораке декодирања.

Добијени резултати показују да повећање корака обраде у испитаном опсегу углавном побољшава тачност, али повећава време до првог резултата. Акустичко преклапање показало се корисним у појединим конфигурацијама, док текстуални контекст није обезбедио доследно побољшање. Најтачнија конфигурација није истовремено била и најповољнија према времену одзива, што потврђује постојање компромиса између тачности и латенције. Пошто је експеримент спроведен на пет снимака и уз симулирано пристизање аудио података, резултате треба тумачити као процену понашања конкретног алгоритма сегментне обраде, а не као доказ његове оптималности у свим условима примене.

8. ИЗБОР КОНФИГУРАЦИЈЕ ПРИМЕНОМ ВИШЕКРИТЕРИЈУМСКЕ ОПТИМИЗАЦИЈЕ

Претходни експерименти показали су да на рад Whisper система истовремено утиче више параметара. Већи модел може да смањи WER, али захтева више времена и меморијских ресурса, док мањи модел омогућава бржу обраду уз већи број грешака. Сличан компромис постоји и код квантизације, параметра *beam size*, VAD алгоритма и величине сегмента при обради говора у реалном времену.

Због тога избор конфигурације само на основу једне метрике не би дао потпуну слику. У овом поглављу резултати претходних експеримената обједињени су у поступак вишекритеријумског избора, чији је циљ да се пронађе конфигурација са повољним односом тачности, брзине и меморијске захтевности.

8.1. Вишекритеријумска оптимизација

Главни део избора заснован је на резултатима експеримента са величином модела и квантизацијом, јер је у њему свих 40 аудио записа читаног говора обрађено помоћу истих осам конфигурација. Комбинована су четири модела (Tiny, Base, Small и Medium) са INT8 и FP32 начином израчунавања. Обезбеђено је да се модел и квантизација пореде на истом тест скупу. Укупно је на располагању било 320 транскрипција, односно 40 снимака за сваку од осам конфигурација. Оваква организација експеримента омогућава директно поређење конфигурација под истим условима. У основном експерименту квантизације за сваку транскрипцију сачувани су добијени текст, време обраде и RTF. У интеграционој анализи модели нису поново покретани ради израчунавања ових метрика, већ је WER накнадно израчунат поређењем сваке сачуване транскрипције са одговарајућим референтним текстом. Све транскрипције коришћене у овој анализи потичу из експеримента квантизације из поглавља 7.5, спроведеног са *beam_size = 1* и искљученим VAD-ом. Због тога се вредности WER-а и RTF-а коришћене у вишекритеријумском избору модела и типа квантизације односе на наведена подешавања декодирања.

За меморијску захтевност коришћена су засебна мерења описана у претходном поглављу. Као меморијски критеријум коришћена је просечна максимална вредност RSS-а, док је стандардна девијација коришћена као метрика варијабилности мерења. На тај начин меморијски критеријум у избору није заснован на RSS разликама измереним у дуготрајном Jupyter процесу, већ на независним и поновљивим мерењима.

За главни избор коришћена су три критеријума:

- WER - представља тачност транскрипције,
- RTF - представља брзину обраде у односу на трајање аудио сигнала,
- Просечна максимална вредност RSS-а - представља меморијску захтевност конфигурације.

Код сва три критеријума мања вредност представља повољнији резултат. Пошто се WER изражава у процентима, RTF као однос времена, а просечна максимална вредност RSS-а у мегабајтима, њихове вредности није могуће директно сабирати. Због тога је примењена min-max нормализација, којом су вредности сваког критеријума пресликане на интервал од 0 до 1. Нормализација је извршена према следећој формули:

$$S_x = \frac{x_{\max} - x}{x_{\max} - x_{\min}} \tag{8.1}$$

где је x вредност посматраног критеријума, $x_{\min}$ његова најмања, а $x_{\max}$ највећа вредност међу разматраним конфигурацијама. Оваквом трансформацијом најповољнија вредност критеријума добија скор 1, а најнеповољнија скор 0. Након нормализације формиран је укупан пондерисани скор:

$$S_{\text{uk}} = 0{,}50S_{\text{WER}} + 0{,}30S_{\text{RTF}} + 0{,}20S_{\text{RAM}} \tag{8.2}$$

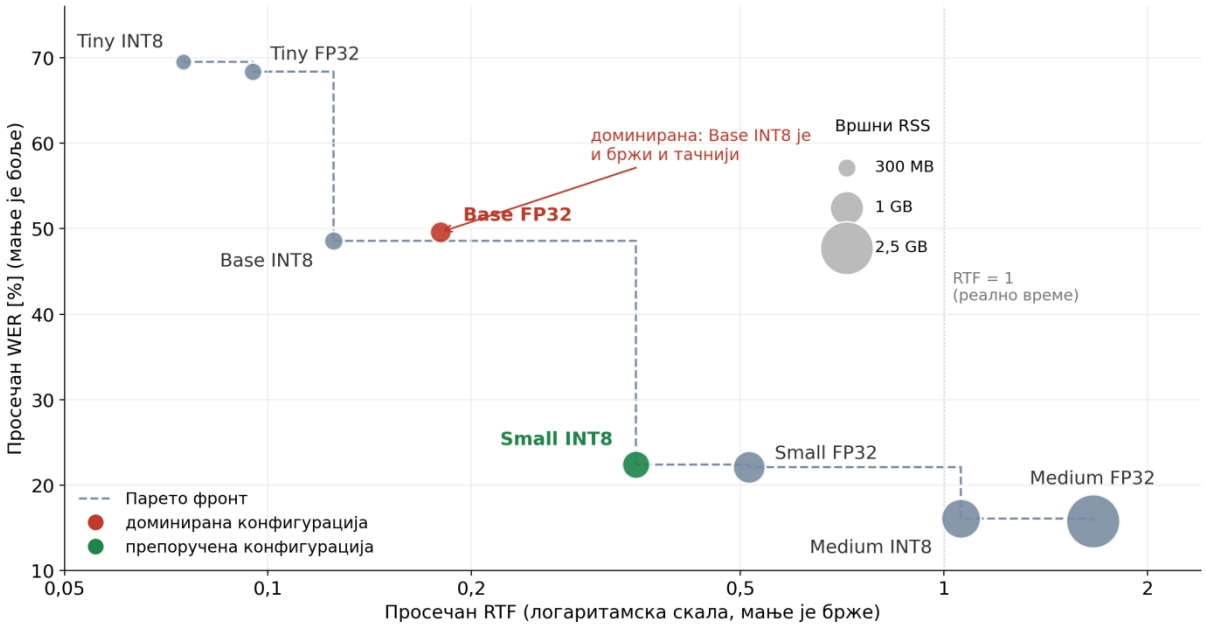
Највећа тежина од 50% додељена је WER-у, јер је основна функција ASR система што тачније препознавање говора. RTF учествује са 30%, док меморијска захтевност има тежину од 20%. На овај начин тачност има највећи значај, али се истовремено узимају у обзир брзина и меморијски захтеви система. Ове тежине не представљају универзалну дефиницију оптималности, због чега је додатно спроведена анализа осетљивости са другачијим расподелама тежина.

8.2. Рангирање и Парето анализа конфигурација

Након израчунавања WER-а, придруживања нових просечних максималних вредности RSS-а и нормализације критеријума, формирана је ранг-листа свих осам конфигурација. Резултати су приказани у Табели 8.1 и на Слици 8.1.

Табела 8.1. Рангирање Faster-Whisper конфигурација

Ранг	Конфигурација	Просечан WER [%]	WER на нивоу корпуса [%]	Просечан RTF	Просечна максимална вредност RSS-а [MB]	SD [MB]	Укупан скор
1	Small INT8	22,43	22,22	0,351	853,59	6,87	0,8554
2	Small FP32	22,06	21,90	0,514	1424,32	2,17	0,7887
3	Medium INT8	16,03	17,83	1,061	1917,02	4,82	0,7076
4	Base INT8	48,61	48,45	0,127	493,11	0,63	0,6788
5	Base FP32	49,47	48,93	0,178	693,01	0,47	0,6473
6	Medium FP32	15,75	17,40	1,659	3334,86	57,82	0,5000
7	Tiny INT8	69,49	68,84	0,073	416,30	0,71	0,5000
8	Tiny FP32	68,39	67,93	0,095	519,52	0,82	0,4990



Слика 8.1. Компромис између тачности и брзине; величина тачке представља просечну максималну вредност RSS-а

Највећи укупан скор од 0,8554 остварила је конфигурација Small INT8. Њен просечан WER износи 22,43%, WER на нивоу корпуса 22,22%, просечан RTF 0,351, док просечна максимална вредност RSS-а износи 853,59 MB, уз стандардну девијацију ± 6,87 MB. Small FP32 остварује нешто нижи просечан WER од 22,06%, али има већи просечан RTF од 0,514 и знатно већу меморијску захтевност од 1424,32 ± 2,17 MB. Због тога са укупним скором од 0,7887 заузима друго место. Medium модели остварују најбољу тачност. Medium FP32 има најнижи просечан WER од 15,75%, док Medium INT8 има 16,03%. Међутим, њихова већа тачност праћена је знатно већим временским и меморијским захтевима. Medium INT8 има просечан RTF од 1,061 и просечну максималну вредност RSS-а од 1917,02 ± 4,82 MB, док Medium FP32 има RTF од 1,659 и максималну вредност RSS-а од 3334,86 ± 57,82 MB. Супротан пример представља Tiny INT8. Ова конфигурација има најнижи просечан RTF од 0,073 и најнижу максималну вредност RSS-а од 416,30 ± 0,71 MB, али истовремено има највећи просечан WER од 69,49%. Због тога њене предности у брзини и меморијској ефикасности нису довољне да надокнаде знатно нижу тачност. Small INT8 налази се између ова два екстрема. Његова тачност је знатно боља од Base и Tiny модела, док је истовремено знатно бржи и меморијски мање захтеван од Medium варијанти. Управо због таквог односа резултата остварује највећи укупан скор.

Поред тежинског рангирања примењена је и Парето анализа. Конфигурација се сматра Парето оптималном ако не постоји друга конфигурација која је истовремено једнако добра или боља по сва три критеријума, а строго боља бар по једном од њих. Након примене нових максималних RSS вредности, Base FP32 је једина конфигурација која је Парето доминирана. Преосталих седам конфигурација припада Парето скупу. На пример, Medium FP32 има најнижи просечан WER, али највећи RTF и максималну вредност RSS-а, док Tiny INT8 има најмањи RTF и максималну вредност RSS-а, али

највећи WER. Small INT8 не остварује апсолутно најбољу вредност сваког појединачног критеријума, али представља повољан компромис између сва три критеријума.

Ова анализа показује да код оптимизације ASR система не постоји нужно једна конфигурација која је најбоља према свакој појединачној метрици. Избор зависи од захтева конкретне примене, односно од тога да ли је већи приоритет тачност, брзина или меморијска ефикасност.

8.3. Анализа осетљивости

Пошто резултат вишекритеријумске оптимизације зависи од изабраних тежина, додатно је проверено како се ранг конфигурација мења када се промене приоритети система. Формирана су три сценарија. Balanced представља основни сценарио са тежинама WER 50%, RTF 30% и просечне максималне вредности RSS-а 20%. Accuracy сценарио даје већи значај тачности, са тежинама 70%, 20% и 10%. Resource сценарио више вреднује брзину и меморијску ефикасност, са тежинама 35% за WER, 35% за RTF и 30% за максималну вредност RSS-а.

Табела 8.2. Анализа осетљивости на избор тежина

Конфигурација	Balanced ранг	Accuracy ранг	Resource ранг
Small INT8	1	1	1
Small FP32	2	2	3
Medium INT8	3	3	7
Base INT8	4	5	2
Base FP32	5	6	4
Medium FP32	6	4	8
Tiny INT8	7	8	5
Tiny FP32	8	7	6

Најважнији резултат анализе осетљивости је да Small INT8 остаје на првом месту у сва три сценарија. Његов скор износи 0,8554 у balanced, 0,8630 у accuracy и 0,8503 у resource сценарију. Овај резултат показује да избор Small INT8 конфигурације није последица само једне специфичне расподеле тежина. Чак и када се приоритет помери ка тачности или ка брзини и меморијској ефикасности, ова конфигурација задржава прво место међу испитаним варијантама. Small FP32 такође показује релативно стабилан положај. Заузима друго место у balanced и accuracy сценарију, а треће у resource сценарију. Његова главна слабост у односу на INT8 варијанту представљају већи RTF и већа меморијска захтевност. Medium INT8 је трећи у balanced и accuracy сценарију, али пада на седмо место у resource сценарију. Ова промена је последица његовог већег RTF-а и максималне вредности RSS-а, који постају значајнији када се ресурсним критеријумима доделе веће тежине. Base INT8 показује супротан тренд. У accuracy сценарију налази се на петом месту због већег WER-а, али се у resource сценарију пење на друго место

захваљујући ниском RTF-у од 0,127 и релативно малој максималној вредности RSS-а од 493,11 MB.

Анализа осетљивости зато не служи само за проверу стабилности првопласиране конфигурације, већ показује и како се избор мења у зависности од захтева примене. У системима у којима је тачност доминантан критеријум већи модели постају конкурентнији, док Base и Tiny варијанте добијају већи значај када су приоритет брзина и ограничени меморијски ресурси. У условима дефинисаним овим радом Small INT8 задржао је прво место у сва три испитана сценарија, што указује на стабилност његовог положаја у односу на примењене расподеле тежина.

8.4. Избор препоручене конфигурације

Главна вишекритеријумска анализа одређује комбинацију модела и квантизације која представља најповољнији компромис према критеријумима дефинисаним у овом раду. На основу 40 снимака читаног српског говора и критеријума WER, RTF и максималне вредности RSS-а, изабрана је конфигурација:

Faster-Whisper Small + INT8

У експерименту коришћеном за избор комбинације модела и квантизације, Small INT8 је остварио просечан WER од 22,43%, WER на нивоу корпуса од 22,22%, просечан RTF од 0,3506 и просечну максималну вредност RSS-а од 853,59 ± 6,87 MB. У основном balanced сценарију остварен је укупан скор од 0,8554. Конфигурација је истовремено Парето оптимална и задржава прво место у сва три сценарија анализе осетљивости. Међутим, модел и квантизација представљају само један део коначне конфигурације. Због тога су резултати засебних експеримената из поглавља 7 употребљени за избор параметра *beam size*, VAD подешавања и величине сегмента за обраду говора у реалном времену. За избор параметра *beam size* коришћени су резултати експеримента из поглавља 7.4. У интеграционој анализи формиран је посебан скор који даје 70% значаја WER-у и 30% RTF-у. Највећи скор од 0,8852 добијен је за *beam_size = 5*, испред вредности 3, 10 и 1. Због тога је вредност 5 изабрана као препоручено подешавање.

Важно ограничење је да је експеримент са различитим вредностима параметра *beam size* изведен над Base INT8 моделом, а не над Small INT8 моделом који је изабран у главној вишекритеријумској анализи. Због тога је вредност *beam_size = 5* првобитно пренета на Small INT8 на основу резултата засебног контролисаног експеримента. Тако формирана комбинација накнадно је укључена у завршну проверу целокупног препорученог профила, у којој су коришћени српски говорни снимци из скупа FLEURS и оригинални скуп од 40 снимака читаног српског говора. Испитане су и сегментна обрада у изабраном симулираном режиму обраде у реалном времену и контролна транскрипција целих снимака. Вредности WER-а од 22,43% и RTF-а од 0,351 потичу из експеримента квантизације из поглавља 7.5, спроведеног са *beam_size = 1* и искљученим VAD-ом. Оне представљају резултате конфигурације коришћене за вишекритеријумски избор модела, а не резултате коначног препорученог профила са *beam_size = 5* и укљученим VAD-ом. За VAD је коришћен резултат српског подскупа. Укључивање VAD-а дало је убрзање од

1,031×, односно смањење времена од 2,96%, без погоршања WER-а. Због тога је VAD ON укључен у препоручени профил.

За избор режима сегментне транскрипције у реалном времену коришћени су резултати експеримента из поглавља 7.7. Уместо избора заснованог искључиво на величини сегмента, примењено је вишекритеријумско рангирање свих 12 испитаних конфигурација, које обухватају три корака обраде и четири режима коришћења акустичког преклапања и текстуалног контекста. При рангирању су коришћени WER на нивоу корпуса са тежином од 50%, RTF са тежином од 20%, процењено време до првог резултата (TTFR) са тежином од 20% и просечно максимално кашњење реда чекања са тежином од 10%. Након нормализације критеријума, највећи укупан скор од 0,8589 остварила је конфигурација са кораком обраде од 5 секунди, акустичким преклапањем од једне секунде и преносом текстуалног контекста од највише осам претходно прихваћених речи.

Изабрана конфигурација у експерименту из поглавља 7.7 остварила је WER на нивоу корпуса од 63,58%, RTF од 0,274 и процењено време до првог резултата од 6,914 секунди. Иако је најнижи појединачни WER од 61,53% остварен при кораку од 10 секунди и примени само акустичког преклапања, комбиновани режим са кораком од 5 секунди остварио је најповољнији резултат према дефинисаном вишекритеријумском скору. Важно је нагласити да је овај избор заснован на резултатима Faster-Whisper Base INT8 модела са параметром *beam_size = 1* и искљученом VAD обрадом. Због тога пренос изабраног режима на интегрисани профил Small INT8 са параметром *beam_size = 5* и укљученим VAD-ом захтева засебну проверу.

Табела 8.3. Препоручена Faster-Whisper конфигурација

Параметар	**Препоручена вредност**
Модел	Small
Квантизација	INT8
Уређај	CPU
Језик	sr
Beam size	5
VAD	Укључен
Корак сегментације	5 s
Акустичко преклапање	1 s
Текстуални контекст	Највише 8 речи
Режим сегментне обраде	Комбиновано преклапање и контекст

Овако формиран профил не представља универзално најбољу Faster-Whisper конфигурацију. Он представља препоручену конфигурацију за услове испитане у овом раду: CPU извршавање, српски језик, формирани скуп читаног говора и дефинисане критеријуме тачности, брзине и меморијске захтевности. Приликом самог поступка избора

параметри коначног профила нису били истовремено испитани у једном заједничком експерименту. Small INT8 је изабран на основу свих 40 снимака читаног српског говора, док су параметар *beam size*, VAD и сегментација обраде у реалном времену испитивани у засебним контролисаним експериментима и на мањим подскуповима. Главна вредност овог поступка је у томе што избор није заснован само на најнижој WER вредности или најбржем моделу. Комбиновањем више критеријума, Парето анализе и анализе осетљивости добијен је систематичан и репродуктиван начин избора конфигурације који узима у обзир различите захтеве практичне примене.

8.5. Завршна валидација интегрисаног профила

Након избора модела, квантизације и параметара транскрипције спроведена је завршна провера интегрисаног Faster-Whisper профила. Циљ експеримента био је да се испита понашање изабране конфигурације на два говорна скупа, уз поређење сегментне транскрипције и обраде целих аудио записа.

Коришћен је Faster-Whisper Small INT8 модел са параметром *beam_size = 5* и укљученом детекцијом говорне активности (VAD). За сегментну транскрипцију примењен је корак од 5 секунди, акустичко преклапање од једне секунде и текстуални контекст од највише осам претходно прихваћених речи. Параметри су преузети из поступка избора описаног у претходном потпоглављу и нису накнадно прилагођавани на основу резултата завршне провере. Евалуација је спроведена на 30 српских аудио записа из скупа FLEURS и на 40 оригиналних снимака читаног говора на српском језику. За FLEURS су коришћени оригинални референтни транскрипти, док су за други скуп употребљене референце формиране у оквиру главног експеримента. За сваки снимак испитана су два начина обраде: сегментна транскрипција са изабраним механизмима преклапања и контекста и контролна транскрипција целог снимка без streaming сегментације.

За процену тачности коришћени су просечан WER по снимку и WER на нивоу корпуса, док су временске карактеристике анализиране помоћу RTF-а и процењеног времена до добијања резултата. Резултати за два говорна скупа израчунати су одвојено, без обједињавања њихових референтних текстова у заједнички корпус. На FLEURS скупу од 30 снимака сегментна транскрипција остварила је WER на нивоу корпуса од 49,211%, просечан WER од 49,532% и просечан RTF од 1,125. Контролна обрада целих снимака остварила је корпусни WER од 49,054%, просечан WER од 48,165% и просечан RTF од 0,886. Разлика у корпусном WER-у била је мала, али је сегментна обрада имала веће временске захтеве.

На главном скупу од 40 снимака сегментна транскрипција остварила је WER на нивоу корпуса од 34,368%, просечан WER од 35,004% и просечан RTF од 1,358. При транскрипцији целих снимака добијени су корпусни WER од 23,233%, просечан WER од 22,440% и просечан RTF од 0,434. Разлика у корпусном WER-у износила је 11,135 процентних поена у корист обраде целих снимака. Процењено време до првог резултата у streaming режиму износило је просечно 10,574 секунде на FLEURS скупу и 12,460 секунди на главном скупу. Код контролне обраде целих снимака процењено време до добијања комплетне транскрипције износило је 21,738, односно 33,905 секунди. Ове вредности

указују на могућност ранијег добијања делимичног резултата применом сегментне обраде, али не представљају директно упоредиве мере исте врсте излазног резултата.

Добијени резултати показују да интеграција појединачно изабраних параметара не гарантује најповољније перформансе њихове заједничке примене. Посебно је значајно што је просечни RTF сегментне обраде на оба скупа био већи од један, што указује на ограничења оваквог начина транскрипције у условима континуираног пристизања аудио сигнала. Пошто је главни скуп од 40 снимака већ коришћен приликом избора модела и квантизације, резултати на њему представљају додатну проверу интегрисаног профила, а не потпуно независну процену генерализације. FLEURS скуп обезбеђује додатну проверу на другачијем говорном материјалу.

Табела 8.4. Завршна провера интегрисаног профила на два говорна скупа

Скуп и начин обраде	**WER корпуса [%]**	**Просечан WER [%]**	**Просечан RTF**	**Процењено време до резултата [s]**
FLEURS 30 - streaming	49,211	49,532	1,125	10,574
FLEURS 30 - цео снимак	49,054	48,165	0,886	21,738
Природни 40 - streaming	34,368	35,004	1,358	12,460
Природни 40 - цео снимак	23,233	22,440	0,434	33,905

Завршна евалуација показује да се изабрани параметри могу објединити у функционалан систем за сегментну транскрипцију, али истовремено указује на одређена ограничења оваквог начина обраде. Резултати показују да утицај сегментације на тачност зависи од карактеристика говорног материјала, при чему је на главном скупу читаног српског говора забележено израженије погоршање тачности него на FLEURS скупу. Иако сегментна обрада омогућава раније добијање резултата транскрипције, она је на оба скупа довела до повећања фактора реалног времена у односу на обраду целог снимка. То указује на потребу за пажљивим усклађивањем тачности, брзине обраде и времена до добијања резултата. Због тога је за даље унапређење интегрисаног профила потребно испитати додатне комбинације величине модела, параметара декодирања, акустичког преклапања и начина преноса текстуалног контекста, како би се смањио негативан утицај сегментације и побољшала погодност система за примену у реалном времену.

9. ДОМЕНСКА АДАПТАЦИЈА WHISPER МОДЕЛА ЗА СРПСКИ ЈЕЗИК

Након анализе тачности, брзине и параметара извршавања Whisper система, у овом поглављу испитује се могућност побољшања препознавања српског говора применом доменске адаптације. За разлику од претходних експеримената, у којима су коришћени већ обучени модели, овде се модел Whisper Small додатно обучава на говорном скупу из области пољопривреде. Циљ је да се утврди у којој мери прилагођавање специфичној терминологији побољшава тачност транскрипције и како утиче на препознавање говора ван домена обучавања.

9.1. Формирање пољопривредног говорног скупа

За потребе доменске адаптације формиран је скуп од 800 аудио записа на српском језику, укупног трајања 111,55 минута. Садржај снимака обухвата терминологију из области пољопривреде, са посебним освртом на гајење украсних биљака, припрему земљишта, садњу, одржавање и избор биљака у различитим условима.

Скуп је подељен на три целине: 675 снимака за обучавање, 75 за валидацију и 50 за завршно тестирање. Тест скуп садржи снимке четвртог говорника, који није био заступљен у подацима за обучавање. Оваква подела омогућава да се резултати не процењују искључиво на основу препознавања већ познатих говорника, већ и на говору особе чији акустички обрасци нису коришћени приликом адаптације.

Табела 9.1. Структура пољопривредног говорног скупа

Подскуп	Број снимака	Трајање [min]	Просечно трајање [s]
Обучавање	675	93,07	8,27
Валидација	75	9,26	7,41
Тестирање	50	9,23	11,07
Укупно	800	111,55	8,37

Сви снимци су монофони и изворно узорковани фреквенцијом од 44,1 kHz. За сваки аудио запис обезбеђен је одговарајући референтни транскрипт, а приликом припреме скупа проверено је да свих 800 идентификатора постоји тачно једном. Тиме је обезбеђено једнозначно повезивање аудио записа и њиховог текстуалног садржаја.

9.2. Припрема података и модела за додатно обучавање

За доменску адаптацију коришћен је претходно обучени модел *openai/whisper-small*, имплементиран помоћу библиотеке Transformers [23]. Обучавање је спроведено у Kaggle окружењу, на графичком процесору NVIDIA Tesla T4. За разлику од CPU експеримената

из претходних поглавља, GPU је коришћен због већих рачунарских захтева поступка додатног обучавања.

Аудио записи су приликом учитавања претварани у моно сигнал фреквенције 16 kHz, а затим су помоћу Whisper процесора формиране улазне аудио карактеристике и токенизовани референтни транскрипти, у складу са уобичајеним поступком припреме података за додатно обучавање Whisper модела [23].

Обучавање је извршено над оригиналним текстовима, док је за евалуацију примењена нормализација референтних и генерисаних транскрипата. Модел је учитан са параметрима у FP32 формату, док је током обучавања коришћена мешовита прецизност FP16 ради смањења меморијских захтева. Примењено је акумулирање градијената, са ефективном величином серије од осам примера, као и *gradient checkpointing* ради ефикаснијег коришћења меморије.

Табела 9.2. Главни параметри додатног обучавања Whisper Small модела

Параметар	**Вредност**
Основни модел	Whisper Small
Окружење	Kaggle, NVIDIA Tesla T4
Број епоха	5
Стопа учења (енгл. *learning rate*)	0,00001
Величина серије по кораку	2
Акумулација градијената	4 корака
Ефективна величина серије	8
Прецизност обучавања	FP32 параметри, FP16 AMP
Распоред стопе учења	Линеарни
Период загревања (енгл. *warmup*)	10% корака
Критеријум избора модела	Најнижи валидациони WER
Декодирање при евалуацији	Greedy, beam_size = 1

Током обучавања модел је евалуиран након сваке епохе. За коначну проверу задржана је конфигурација са најнижом стопом грешке на валидационом скупу, у складу са приступом евалуацији и избору модела током додатног обучавања [24]. На тај начин избегнут је избор модела на основу резултата тестирања. Најнижи валидациони WER од 7,84% остварен је након треће епохе. У четвртој и петој епохи није дошло до даљег побољшања ове метрике, па је за завршну евалуацију коришћен сачувани модел из треће епохе.

9.3. Евалуација основног и адаптираног модела

Евалуација је спроведена на 50 издвојених пољопривредних снимака четвртог говорника. Поређени су оригинални Whisper Small и доменски адаптирани модел, оба у FP32 формату, са истим параметрима декодирања и поступком нормализације текста. Као основне метрике тачности коришћени су WER и CER на нивоу корпуса, док је брзина извршавања анализирана помоћу просечног RTF-а.

Табела 9.3. Резултати основног и доменски адаптираног модела на пољопривредном тест скупу

Метрика	Оригинални Small	Адаптирани Small
Просечна вредност WER-а [%]	31,30	17,35
Медијана WER-а [%]	30,08	16,67
WER на нивоу корпуса [%]	31,01	17,32
CER на нивоу корпуса [%]	5,91	3,23
Просечна вредност RTF-а	0,0741	0,1012

Доменска адаптација довела је до смањења корпусног WER-а са 31,01% на 17,32%, што представља апсолутно побољшање од 13,69 процентних поена, односно релативно смањење грешке од 44,15%. Истовремено, CER је смањен са 5,91% на 3,23%, што потврђује да је побољшање присутно и на нивоу појединачних карактера. Побољшање није ограничено на неколико издвојених снимака. Од укупно 50 тест примера, код 45 је забележено смањење WER-а, код три повећање, док су два остала непромењена. Поред квантитативних резултата, анализа појединачних транскрипата показује да је адаптирани модел у појединим случајевима успешније препознавао речи и њихове граматичке облике. На снимку 777 WER је смањен са 57,89% на 21,05%, док је на снимку 760 смањен са 36,36% на 9,09%. Примери карактеристичних исправки приказани су у Табели 9.4.

Табела 9.4. Примери побољшања транскрипције након доменске адаптације

Снимак	Оригинални модел	Адаптирани модел
777	„struktur u zemljišta“	„strukturu zemljišta“
777	„prestajua važan izbor“	„predstavlja važan izbor“
760	„transporto je posad“	„transportuje posadi“
760	„zalije u čvrsti“	„zalije učvrsti“

Приказани примери указују на смањење броја неправилно препознатих или раздвојених речи, посебно у деловима реченица који садрже пољопривредне изразе. Ипак, адаптирани модел није у потпуности отклонио грешке, што се може уочити и у приказаним транскриптима. Са становишта брзине, просечна вредност RTF-а повећана је са 0,0741 на 0,1012. Иако је адаптирани модел у овом мерењу био спорији, обе конфигурације остариле су RTF мањи од један. Добијени резултати показују да је

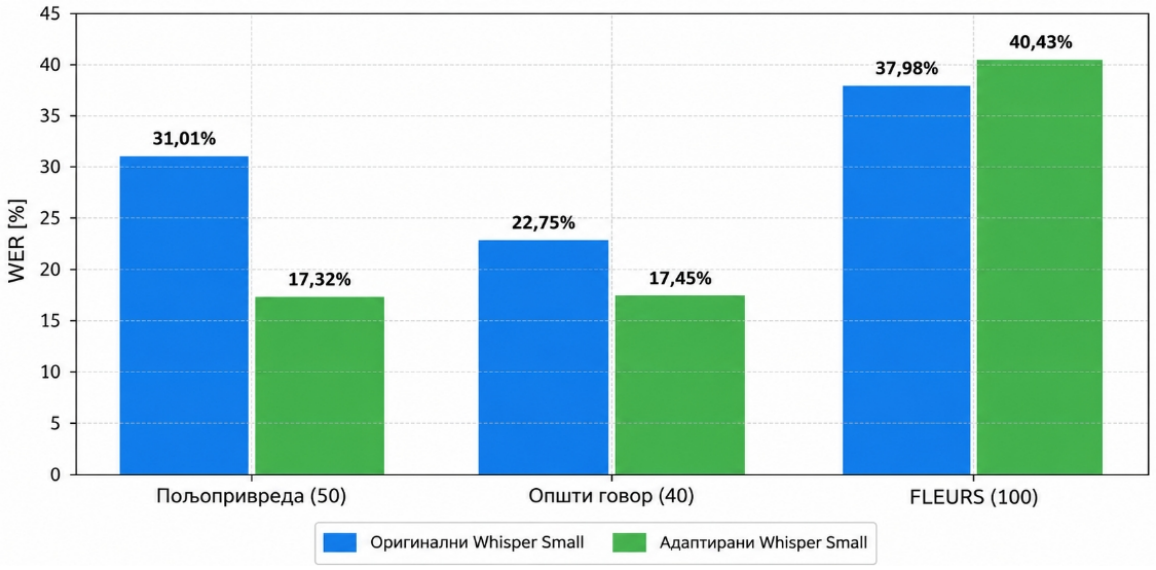
додатно обучавање значајно побољшало препознавање говора из циљног домена, уз умерено повећање измереног времена обраде.

9.4. Анализа доменске терминологије и генерализације

Поред укупног побољшања тачности, анализиран је утицај доменске адаптације на препознавање говора који није ограничен на пољопривредну терминологију. За ову проверу коришћена су два додатна скупа: 40 снимака општег српског говора из главног експерименталног скупа и 100 српских снимака из корпуса FLEURS. На оба скупа поређени су оригинални и адаптирани Whisper Small модели, уз исте параметре декодирања унутар сваког експеримента. Коришћено је FP32 извршавање и похлепо декодирање (енгл. *greedy search*), док су дужи снимци обрађивани применом изворног Whisper поступка за транскрипцију дужих аудио записа.

Табела 9.5. Провера генерализације након доменске адаптације

Тест скуп	Оригинални WER [%]	Адаптирани WER [%]	Промена [pp]
Пољопривреда - 50	31,01	17,32	−13,69
Општи српски говор - 40	22,75	17,45	−5,30
FLEURS српски - 100	37,98	40,43	+2,44



Слика 9.1. Поређење вредности WER-а оригиналног и доменски адаптираног Whisper Small модела на три тест скупа.

Негативна промена означава смањење WER-а, односно побољшање тачности. Вредности су заокружене; разлике су израчунате из прецизнијих резултата. На скупу од 40

снимака општег српског говора адаптирани модел остварио је корпусни WER од 17,45%, у поређењу са 22,75% код оригиналног модела. Побољшање је забележено код сва три говорника, што указује да адаптација није довела до општег губитка способности препознавања говора ван пољопривредног домена. Међутим, на скупу од 100 FLEURS снимака добијен је супротан резултат. Корпусни WER повећан је са 37,98% на 40,43%, а CER са 10,57% на 12,29%. То показује да ефекат адаптације зависи од карактеристика говорног скупа и да побољшање на једном скупу није довољно за закључак о универзално бољој тачности.

Анализа појединачних пољопривредних снимака показује да је највећи део тест примера имао користи од додатног обучавања. Ипак, на основу укупног WER-а није могуће прецизно утврдити колики део побољшања потиче искључиво од успешнијег препознавања пољопривредних термина, а колики од општег прилагођавања говору, изговору и структури реченица у коришћеном корпусу. За такву процену било би потребно засебно означавање доменских израза и анализа грешака на том подскупу речи.

Добијени резултати потврђују да је доменска адаптација Whisper Small модела била успешна на циљном пољопривредном скупу, уз побољшање и на једном скупу општег српског говора. Истовремено, умерено погоршање на FLEURS скупу указује на ограничену преносивост добијених побољшања и потребу да се адаптирани ASR модели проверавају на више независних говорних скупова пре практичне примене.

10. ДИСКУСИЈА И ОГРАНИЧЕЊА ИСТРАЖИВАЊА

10.1. Дискусија добијених резултата

Спроведено истраживање показало је да перформансе Whisper система за аутоматско препознавање српског говора зависе од међусобног утицаја величине модела, начина извршавања, параметара транскрипције и карактеристика улазног аудио сигнала. Добијени резултати указују да оптимизацију није оправдано заснивати искључиво на тачности или брзини, већ на њиховом односу и расположивим рачунарским ресурсима.

Поређење оригиналног Whisper и Faster-Whisper система показало је предности оптимизоване имплементације, посебно у погледу меморијске захтевности и ефикасности извршавања на CPU-у. Анализа различитих величина модела потврдила је очекивани компромис између тачности и брзине, док је INT8 квантизација омогућила смањење рачунарских захтева уз релативно мале разлике у тачности у односу на FP32 конфигурације. Истовремено, испитивање позадинског шума показало је значајно погоршање препознавања при нижим SNR вредностима, укључујући услове са шумом пољопривредне механизације.

Применом вишекритеријумске оптимизације, Парето анализе и анализе осетљивости издвојен је Faster-Whisper Small INT8 као најповољнији компромис у оквиру испитиваних конфигурација. Међутим, завршна провера интегрисаног профила показала је да појединачно повољна подешавања не гарантују једнако добре резултате када се примењују заједно. Сегментна транскрипција са акустичким преклапањем и преносом текстуалног контекста имала је већу стопу грешке од обраде целих снимака, док је просечни RTF већи од један указао на ограничења примене испитаног профила у континуираном раду у реалном времену. Овај резултат наглашава значај завршне провере целокупног система, а не само његових појединачних компоненти.

Посебно значајни резултати добијени су доменском адаптацијом Whisper Small модела. Додатно обучавање на пољопривредном говорном скупу довело је до релативног смањења корпусног WER-а од 44,15% на тест снимцима говорника који није учествовао у обучавању. Побољшање је забележено и на главном скупу општег српског говора, док је на независном FLEURS скупу дошло до умереног погоршања. Овакви резултати показују да доменска адаптација може значајно побољшати тачност препознавања говора из циљног домена, али да њен утицај на говор ван домена зависи од карактеристика конкретног скупа података.

У целини, резултати потврђују да избор конфигурације и доменска адаптација представљају два међусобно допуњујућа приступа унапређењу ASR система. Први је усмерен на ефикасније коришћење рачунарских ресурса, а други на побољшање тачности препознавања у специфичној области примене.

10.2. Ограничења истраживања

Главни експериментални скуп обухвата 40 снимака читаног говора три говорника, што ограничава репрезентативност резултата у односу на спонтани, разговорни говор, док су поједини експерименти спроведени на мањим подскуповима. Иако су додатно коришћени снимци из корпуса FLEURS, добијени резултати не могу се непосредно уопштити на све говорнике, дијалекте, стилове говора и услове снимања српског језика.

Сва мерења оптимизације извршена су у ограниченом CPU окружењу, па резултати брзине и меморијске потрошње зависе од коришћеног хардвера и софтверских библиотека. Поред тога, испитиване су одабране величине модела и конфигурације, а не целокупан простор могућих подешавања. Због тога препоручена конфигурација представља најповољнији избор у оквиру спроведених експеримената, а не универзално оптимално решење.

Испитивање отпорности на шум засновано је на контролисаном додавању белог, розе и шума пољопривредне механизације. Оваква поставка омогућава упоредиву анализу различитих SNR нивоа, али не обухвата сву сложеност стварних акустичких услова. Такође, сегментна транскрипција испитивана је симулацијом пристизања аудио података, а не у потпуно имплементираном систему са непрекидним микрофонским улазом. Због тога добијене вредности латенције и RTF-а не представљају потпуну процену понашања система у продукционом окружењу.

Код доменске адаптације ограничење представља релативно мали говорни скуп, формиран од ограниченог броја говорника и у контролисаним условима снимања. Иако је тестирање на издвојеном говорнику омогућило проверу генерализације, за поузданију процену практичне применљивости потребно је испитивање на већем броју независних говорника и разноврснијим аудио записима. Уочено погоршање на FLEURS скупу додатно указује на потребу за пажљивом провером способности адаптираног модела да препознаје говор ван циљног домена.

11. ЗАКЉУЧАК И ПРАВЦИ БУДУЋЕГ РАДА

У овом раду спроведена је анализа, оптимизација и доменска адаптација Whisper модела за аутоматско препознавање говора на српском језику. Истраживање је обухватило поређење оригиналне Whisper и Faster-Whisper имплементације, испитивање фактора који утичу на тачност и ефикасност транскрипције, избор погодне конфигурације и додатно обучавање модела за препознавање говора из области пољопривреде.

Експериментални резултати показали су да Faster-Whisper, уз одговарајућу величину модела и квантизацију, омогућава ефикасније извршавање на CPU-у уз очување упоредиве тачности транскрипције. Применом вишекритеријумске оптимизације и Парето анализе издвојена је конфигурација Faster-Whisper Small INT8 као повољан компромис између тачности, брзине и меморијске захтевности. Истовремено, завршна валидација показала је да интегрисани профил сегментне транскрипције захтева даљу оптимизацију како би се смањила стопа грешке и обезбедила ефикасна обрада у реалном времену.

Доменска адаптација Whisper Small модела показала је значајан потенцијал за побољшање препознавања српског говора у специфичној области. На издвојеном пољопривредном тест скупу корпусни WER смањен је са 31,01% на 17,32%, односно за 44,15% релативно. Остварено побољшање на говору новог говорника указује на успешност прилагођавања циљном домену, док различити резултати на скуповима општег говора потврђују потребу за провером генерализације на независним подацима.

Главни допринос рада огледа се у систематској експерименталној анализи Whisper система за српски језик, развоју поступка за избор конфигурације на основу више критеријума и практичној провери доменске адаптације на сопственом говорном скупу. Добијени резултати пружају основу за даље унапређење тачности и ефикасности ASR система у условима ограничених рачунарских ресурса.

Будући рад могао би да обухвати проширење говорних скупова већим бројем говорника, дијалеката и снимака насталих у реалним акустичким условима. Посебан правац представља оптимизација сегментне транскрипције кроз ефикасније управљање акустичким и текстуалним контекстом, смањење латенције и испитивање рада на различитим хардверским платформама. У области доменске адаптације значајно би било проширити скуп података и испитати поступке који омогућавају побољшање препознавања стручне терминологије уз очување способности модела да поуздано препознаје општи говор.

На основу спроведеног истраживања може се закључити да је Whisper систем могуће прилагодити захтевима препознавања српског говора, али да избор оптималног решења зависи од конкретне примене, расположивих ресурса и карактеристика говорних података. Резултати рада показују да систематска оптимизација и циљана доменска адаптација представљају значајне правце развоја ефикаснијих и прецизнијих система за аутоматско препознавање говора на српском језику.

12. ЛИТЕРАТУРА

[1] SYSTRAN, “Faster-Whisper: Faster Whisper transcription with CTranslate2,” GitHub repository. [Онлајн]. Доступно: https://github.com/SYSTRAN/faster-whisper (приступљено: 10. 6. 2026).

[2] OpenNMT, “CTranslate2,” documentation. [Онлајн]. Доступно: https://opennmt.net/CTranslate2/ (приступљено: 18. 9. 2026).

[3] S. Hochreiter and J. Schmidhuber, “Long short-term memory,” Neural Comput., vol. 9, no. 8, pp. 1735-1780, Nov. 1997, doi: 10.1162/neco.1997.9.8.1735.

[4] A. Vaswani et al., “Attention is all you need,” in Proc. Adv. Neural Inf. Process. Syst. (NeurIPS), Long Beach, CA, USA, 2017, vol. 30, pp. 5998-6008.

[5] A. Radford, J. W. Kim, T. Xu, G. Brockman, C. McLeavey, and I. Sutskever, “Robust speech recognition via large-scale weak supervision,” in Proc. 40th Int. Conf. Mach. Learn. (ICML), Honolulu, HI, USA, 2023, vol. 202, pp. 28492-28518. [Онлајн]. Доступно: https://proceedings.mlr.press/v202/radford23a.html

[6] OpenAI, “Whisper,” GitHub repository. [Онлајн]. Доступно: https://github.com/openai/whisper (приступљено: 10. 6. 2026).

[7] A. Graves, S. Fernández, F. Gomez, and J. Schmidhuber, “Connectionist temporal classification: Labelling unsegmented sequence data with recurrent neural networks,” in Proc. 23rd Int. Conf. Mach. Learn. (ICML), Pittsburgh, PA, USA, 2006, pp. 369-376, doi: 10.1145/1143844.1143891.

[8] A. Conneau, A. Baevski, R. Collobert, A. Mohamed, and M. Auli, “Unsupervised cross-lingual representation learning for speech recognition,” in Proc. Interspeech, Brno, Czechia, 2021, pp. 2426-2430, doi: 10.21437/Interspeech.2021-329.

[9] A. Gulati et al., “Conformer: Convolution-augmented Transformer for speech recognition,” in Proc. Interspeech, Shanghai, China, 2020, pp. 5036-5040, doi: 10.21437/Interspeech.2020-3015.

[10] M. Sečujski et al., “Retrospective and perspectives of TTS & STT technology development and implementation for South Slavic under-resourced languages,” in Speech and Computer (SPECOM 2024), Lecture Notes in Computer Science, vol. 15299. Cham, Switzerland: Springer, 2024, pp. 23-42.

[11] N. Ljubešić, P. Rupnik, and D. Koržinek, “The ParlaSpeech collection of automatically generated speech and text datasets from parliamentary proceedings,” in Speech and Computer (SPECOM 2024), Lecture Notes in Computer Science, vol. 15299. Cham, Switzerland: Springer, 2024, pp. 137-150, doi: 10.1007/978-3-031-77961-9_10.

[12] N. Ljubešić, P. Rupnik, and D. Koržinek, “Parliamentary spoken corpus of Serbian ParlaSpeech-RS 1.0,” Slovenian language resource repository CLARIN.SI, Jožef Stefan Institute, 2024. [Онлајн]. Доступно: http://hdl.handle.net/11356/1834

[13] A. Conneau et al., “FLEURS: Few-shot learning evaluation of universal representations of speech,” in Proc. IEEE Spoken Lang. Technol. Workshop (SLT), Doha, Qatar, 2023, pp. 798-805, doi: 10.1109/SLT54892.2023.10023141.

[14] R. Ardila et al., “Common Voice: A massively-multilingual speech corpus,” in Proc. 12th Lang. Resour. Eval. Conf. (LREC), Marseille, France, 2020, pp. 4218-4222.

[15] V. Stanojev, T. V. Nosek, S. Suzić, D. Pekar, V. Delić, and M. Sečujski, “Improving Whisper-based Serbian ASR using synthetic speech,” in Speech and Computer (SPECOM 2025), Lecture Notes in Computer Science, vol. 16188. Cham, Switzerland: Springer, 2025, pp. 118-129, doi: 10.1007/978-3-032-07959-6_9.

[16] E. Pakoci, D. Pekar, B. M. Popović, M. Sečujski, and V. Delić, “Overcoming data sparsity in automatic transcription of dictated medical findings,” in Proc. 30th Eur. Signal Process. Conf. (EUSIPCO), Belgrade, Serbia, 2022, pp. 454-458.

[17] D. Pawlowicz, J. Weber, and C. Dukino, “Effectiveness of Whisper’s fine-tuning for domain-specific use cases in the industry,” in Proc. 17th Int. Conf. Agents Artif. Intell. (ICAART), 2025, doi: 10.5220/0013378100003890.

[18] A. Gholami, S. Kim, Z. Dong, Z. Yao, M. W. Mahoney, and K. Keutzer, “A survey of quantization methods for efficient neural network inference,” 2021, arXiv:2103.13630.

[19] Silero Team, “Silero VAD,” GitHub repository. [Онлајн]. Доступно: https://github.com/snakers4/silero-vad (приступљено: 30. 8. 2026).

[20] D. Macháček, R. Dabre, and O. Bojar, “Turning Whisper into real-time transcription system,” in Proc. IJCNLP-AACL: Syst. Demonstrations, Bali, Indonesia, 2023, pp. 17-24, doi: 10.18653/v1/2023.ijcnlp-demo.3.

[21] A. Koenecke, A. S. G. Choi, K. X. Mei, H. Schellmann, and M. Sloane, “Careless Whisper: Speech-to-text hallucination harms,” in Proc. ACM Conf. Fairness, Accountability, Transparency (FAccT), Rio de Janeiro, Brazil, 2024, pp. 1672-1681, doi: 10.1145/3630106.3658996.

[22] M. Barański, J. Jasiński, J. Bartolewska, S. Kacprzak, M. Witkowski, and K. Kowalczyk, “Investigation of Whisper ASR hallucinations induced by non-speech audio,” in Proc. IEEE Int. Conf. Acoust., Speech, Signal Process. (ICASSP), Hyderabad, India, 2025, doi: 10.1109/ICASSP49660.2025.10890105.

[23] S. Gandhi, “Fine-tune Whisper for multilingual ASR with Transformers,” Hugging Face Blog, 2022. [Онлајн]. Доступно: https://huggingface.co/blog/fine-tune-whisper (приступљено: 14. 09. 2026).

[24] Hugging Face, “Fine-tuning the ASR model,” Hugging Face Audio Course, documentation. [Онлајн]. Доступно: https://huggingface.co/learn/audio-course/chapter5/fine-tuning (приступљено: 14. 09. 2026).